

เอกสารโครงงานฉบับสมบูรณ์

การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลลีกยุโรปด้วย
กระบวนการวิทยาการข้อมูลเพื่อการประเมินมูลค่าการเดิมพัน

European Football Match Outcome Prediction and
Betting Market Analysis Using Data Science

โดย
683380667-9 นายภาณุพงศ์ ภูสำรอง
683380653-0 นายชินภัทร บัวผาย

อาจารย์ที่ปรึกษา
อ.ธนพล ตั้งชูพงศ์

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา
วิชา CP352101 วิทยาการข้อมูลเบื้องต้น
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
วิทยาลัยการคอมพิวเตอร์
มหาวิทยาลัยขอนแก่น
ปีการศึกษา 2569

ภาณุพงศ์ ภูสำรอง และ ชินภัทร บัวผาย. 2569. **การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลลีกยุโรปด้วยกระบวนการวิทยาการข้อมูลเพื่อการประเมินมูลค่าการเดิมพัน.** โครงงานคอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
อาจารย์ที่ปรึกษา: อ.ธนพล ตั้งชูพงศ์

บทคัดย่อ

โครงงานนี้นำเสนอการประยุกต์ใช้กระบวนการวิทยาการข้อมูลในการวิเคราะห์ปัจจัยที่มีผลต่อการแข่งขันฟุตบอลยุโรป และการพัฒนาแบบจำลองเพื่อทำนายผลการแข่งขัน 3 ทางเลือก (เจ้าบ้านชนะ เสมอ และทีมเยือนชนะ) สำหรับค้นหาโอกาสการเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (Value Betting / +EV) และประเมินผลตอบแทนทางการเงิน

การดำเนินงานได้บูรณาการชุดข้อมูลการแข่งขันฟุตบอลย้อนหลัง 5 ลีกใหญ่ของยุโรป ตั้งแต่ฤดูกาล 2014–2015 ถึง 2024–2025 จากแหล่งข้อมูลสาธารณะ ได้แก่ Understat, Transfermarkt และ Football-Data.co.uk ผ่านท่อส่งข้อมูลเชิงโมดูลาร์ที่มีการตรวจสอบสัญญาโครงสร้างข้อมูล (Pandera Data Contracts) ข้อมูลทั้งหมดถูกนำมาวิศวกรรมฟีเจอร์ก่อนการแข่งขัน ได้แก่ คะแนนความแข็งแกร่ง Elo Rating, ดัชนีความเหนื่อยล้าสะสม, ความหนาแน่นของตารางแข่งขันทุกรายการ และฟอร์มรายบุคคลของผู้เล่น 11 ตัวจริง (xG/xA ต่อ 90 นาที) โดยนำมาฝึกฝนแบบจำลองทางสถิติ Double Poisson ร่วมกับการปรับแก้ Dixon-Coles และแบบจำลองการเรียนรู้ของเครื่องชนิด Gradient Boosting (HistGradientBoostingClassifier) พร้อมประเมินผลตอบแทนทางการเงินผ่านระบบทดสอบย้อนหลัง (Backtesting Engine) ด้วยกลยุทธ์การวางเงินทุนแบบคงที่ (Fixed Staking) และสูตรเคลลี (Kelly Criterion)

ผลการศึกษาพบว่า การนำข้อมูลบริบทเชิงลึกก่อนการแข่งขัน ได้แก่ คะแนน Elo, ดัชนีความเหนื่อยล้า และฟอร์มผู้เล่นตัวจริง มาบูรณาการร่วมกับแบบจำลอง Gradient Boosting และ Double Poisson ช่วยเพิ่มประสิทธิภาพการทำนายความน่าจะเป็นของผลการแข่งขันให้เหนือกว่าเกณฑ์เปรียบเทียบพื้นฐานได้อย่างมีนัยสำคัญ เมื่อนำความน่าจะเป็นที่ได้ไปเปรียบเทียบกับราคาอัตราต่อรองของตลาดเพื่อจำลองการวางเดิมพันย้อนหลัง พบว่ากลยุทธ์ Value Betting สามารถสร้างอัตราผลตอบแทนจากการลงทุน (ROI) เป็นบวกและลดความเสี่ยงจากการลดลงของเงินทุน (Drawdown) ได้อย่างมีประสิทธิภาพ องค์ความรู้และท่อส่งข้อมูลจากโครงงานนี้สามารถนำไปประยุกต์ใช้เป็นแนวทางในการประมวลผลข้อมูลกีฬาเชิงซ้อนและการตัดสินใจลงทุนในตลาดการเดิมพันกีฬาต่อไป

คำสำคัญ: วิทยาการข้อมูล, การทำนายผลการแข่งขันฟุตบอล, ลีกฟุตบอลยุโรป, การเรียนรู้ของเครื่อง, อัตราต่อรอง, การทดสอบย้อนหลัง

Panupong Phoosamrong and Chinnapat Buaphai. 2026. **European Football Match Outcome Prediction and Betting Market Analysis Using Data Science.** Computer Project, Bachelor of Science, Program in Computer Science, College of Computing, Khon Kaen University.
Project Advisor: Lect. Thanapon Tangchoopong, Ph.D.

ABSTRACT

This project presented an application of the end-to-end data science process to analyze key pre-match factors in European football leagues and to develop predictive models for predicting three-way match outcomes (Home Win, Draw, Away Win) to identify positive expected value (+EV) betting opportunities and evaluate financial returns.

The methodology integrated historical match data across five major European leagues from the 2014–2015 through 2024–2025 seasons from public sources, including Understat, Transfermarkt, and Football-Data.co.uk. Data was processed through a modular data pipeline enforced with Pandera schema validation. Pre-match feature engineering was performed to construct contextual metrics, including Elo ratings, cumulative fatigue indices, schedule congestion across all competitions, and starting lineup forms (xG/xA per 90 minutes). A Dixon-Coles adjusted Double Poisson statistical model and a HistGradientBoosting classifier were trained, with financial viability evaluated via a temporal backtesting engine using Fixed Staking and Kelly Criterion strategies.

The experimental results indicate that integrating pre-match contextual features—specifically Elo ratings, fatigue metrics, and starting lineup forms—with Gradient Boosting and Double Poisson models significantly enhances outcome probability estimation beyond baseline priors. When model probabilities are benchmarked against market odds to simulate historical value betting, the strategy yields positive returns on investment (ROI) and effectively mitigates maximum drawdown. The framework and data pipeline established in this project provide a robust foundation for multi-dimensional sports analytics and quantitative decision-making in sports betting markets.

Keywords: Data Science, Football Match Outcome Prediction, European Football Leagues, Machine Learning, Betting Odds, Backtesting

กิตติกรรมประกาศ

โครงงานฉบับนี้สำเร็จลุล่วงไปได้ด้วยดีด้วยความกรุณาอย่างยิ่งจาก อ.ดร.ธนพล ตั้งชูพงศ์ อาจารย์ที่ปรึกษาโครงงาน ที่ได้ให้คำแนะนำ แนวคิด และข้อเสนอแนะอันมีค่ายิ่ง ตลอดจนคอยตรวจแก้ไขข้อบกพร่องและให้กำลังใจแก่ผู้จัดทำมาโดยตลอด ผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ โอกาสนี้

ขอกราบขอบพระคุณ คณาจารย์ประจำสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น ทุกท่าน ที่ได้ประสิทธิ์ประสาทวิชาความรู้และถ่ายทอดประสบการณ์ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงงานฉบับนี้

ขอบคุณเพื่อนร่วมชั้นเรียนและผู้ที่มีส่วนเกี่ยวข้องทุกท่าน ที่คอยให้ความช่วยเหลือแนะนำ และแลกเปลี่ยนความคิดเห็นตลอดช่วงเวลาของการดำเนินงาน

ท้ายที่สุดนี้ ผู้จัดทำขอกราบขอบพระคุณบิดา มารดา และสมาชิกในครอบครัวทุกท่าน สำหรับความรัก การสนับสนุน และกำลังใจอันยิ่งใหญ่ที่เป็นแรงผลักดันสำคัญให้การศึกษานี้ประสบความสำเร็จ

ผู้จัดทำ
ภาณุพงศ์ ภูสำรอง
ชินภัทร บัวผาย

สารบัญ

บทคัดย่อ ก

ABSTRACT ข

กิตติกรรมประกาศ ค

สารบัญ ง

สารบัญภาพ ช

สารบัญตาราง ซ

1 บทนำ 1

1.1 ความเป็นมาและความสำคัญของปัญหา 1
1.2 วัตถุประสงค์ 1
1.3 ขอบเขตและข้อจำกัดของโครงงาน 2
1.3.1 ขอบเขตของโครงงาน 2
1.3.2 ข้อจำกัดของโครงงาน 3
1.4 ประโยชน์ที่คาดว่าจะได้รับ 4

2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง 5

2.1 ทฤษฎีที่เกี่ยวข้อง 5
2.1.1 กระบวนการ วิทยาการ ข้อมูล และ การ จัด ทำ ท่อ ส่ง ข้อมูล (Data Science & Pipeline Process) 5
2.1.2 ระบบวัดระดับความแข็งแกร่ง (Elo Rating System) 6
2.1.3 ค่าความคาดหวังในการทำประตู (Expected Goals: xG) . . 6
2.1.4 ดัชนีความเหนื่อยล้าและความหนาแน่นของตารางแข่ง (Fatigue Metric & Schedule Congestion) 7
2.1.5 อัตราต่อรองของเจ้ามือรับพนันและการเดิมพันที่มีมูลค่า (Betting Odds & Value Betting) 8
2.1.6 กลยุทธ์การบริหารเงินทุนและการทดสอบย้อนหลัง (Staking Strategies & Backtesting) 8
2.1.7 การ จับ คู่ และ แปลง ชื่อ เอ นทิ ตี ให้ เป็น มาตรฐาน (Entity Resolution) 9
2.1.8 แบบจำลองทำนายผลการแข่งขัน 9
2.2 งานวิจัยที่เกี่ยวข้อง 10
2.2.1 การทำนายผลฟุตบอลและการประเมินประสิทธิภาพเทียบกับตลาดเดิมพัน 10

2.2.2 การใช้ Machine Learning ร่วมกับสถิติเชิงลึก และกลยุทธ์การเอาชนะตลาด 10
2.2.3 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง 10
2.3 เครื่องมือและเทคโนโลยีที่ใช้ 11
2.3.1 ภาษา Python และไลบรารีสำหรับการประมวลผลข้อมูล . . 11
2.3.2 สภาพแวดล้อมและการประกันคุณภาพซอฟต์แวร์ (Development Environment & Quality Control) 11

3 วิธีการดำเนินโครงงาน 12
3.1 การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน 12
3.2 การเก็บรวบรวมข้อมูล (Data Collection) 13
3.3 การทำความสะอาดข้อมูลและการตรวจสอบความถูกต้อง 13
3.3.1 ขั้นตอนการทำความสะอาด (Data Cleaning) 13
3.3.2 การจับคู่และแปลงชื่อเอนทิตีให้เป็นมาตรฐาน (Entity Resolution) 14
3.3.3 การตรวจสอบความถูกต้องของข้อตกลงข้อมูล (Data Schema Validation) 14
3.4 การวิศวกรรมฟีเจอร์และการวิเคราะห์ตลาดเดิมพัน 14
3.4.1 การคำนวณคะแนนความแข็งแกร่งเชิงสัมพัทธ์ (Elo Rating Calculation) 15
3.4.2 การคำนวณดัชนีความเหนื่อยล้าสะสมและความหนาแน่นตารางแข่ง 16
3.4.3 ฟอร์มรายบุคคลของผู้เล่นตัวจริง (Starter Form Features) 16
3.4.4 การวิเคราะห์ราคาต่อรองอัตราจ่ายและมูลค่าการเดิมพัน (Odds & Value Betting Analysis) 16
3.5 การพัฒนาแบบจำลอง การแบ่งชุดข้อมูล และระบบทดสอบย้อนหลัง . . 16
3.5.1 แบบจำลอง Double Poisson และ Gradient Boosting . . 16
3.5.2 การแบ่งชุดข้อมูลตามลำดับเวลา (Temporal Split) 16
3.5.3 กรอบการประเมินผลและการทดสอบย้อนหลัง (Backtesting Framework) 17
3.5.4 การทดสอบสมมติฐานทางสถิติ 17
3.6 การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance Framework) 17
3.6.1 การทดสอบซอฟต์แวร์อัตโนมัติ (Automated Testing) . . . 17
3.6.2 การตรวจสอบคุณภาพโค้ดและการเผยแพร่ 17

4 ผลการดำเนินงาน 18
4.1 ผลการสำรวจข้อมูลและการทดสอบสมมติฐานทางสถิติ 18
4.1.1 การทดสอบสมมติฐานเกี่ยวกับความได้เปรียบของการเป็นเจ้าบ้าน (Home Advantage) 18
4.1.2 ความสัมพันธ์ระหว่างผลต่างคะแนน Elo กับผลต่างประตู . . 18
4.2 ผลการวิเคราะห์ความสำคัญของตัวแปรเชิงทำนาย (Feature Importance) 18
4.3 ผลการประเมินประสิทธิภาพของแบบจำลอง (Model Performance) . . 19

4.4 ผลการทดสอบย้อนหลังทางการเงิน (Financial Backtesting Results) . 19

5 สรุปผลการดำเนินงาน 21
5.1 สรุปผลการดำเนินโครงงาน 21
5.2 ข้อจำกัดของระบบ 21
5.2.1 ข้อจำกัดด้านการทำงาน 21
5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และซอฟต์แวร์ 22
5.3 ปัญหาอุปสรรค และแนวทางแก้ไข 22
5.4 ข้อเสนอแนะ ในการพัฒนาต่อไป 22
5.4.1 การปรับปรุงฟังก์ชันการทำงาน 22
5.4.2 แนวทางการวิจัยต่อยอด 23

เอกสารอ้างอิง 24

สารบัญภาพ

ภาพ ที่ 1 ตัวอย่าง แผนภาพ แสดง การ ปรับปรุง คะแนน Elo Rating ของ สโมสร ฟุตบอลตามผลการแข่งขันย้อนหลัง (ที่มา: ClubElo) 6
ภาพที่ 2 ตัวอย่างการประเมินค่าความคาดหวังในการทำประตู (Expected Goals: xG) จากตำแหน่งการยิง (ที่มา: Opta Analyst) 7
ภาพที่ 3 ตัวอย่างการวิเคราะห์ความตึงเครียดของโปรแกรมแข่งขัน 8

สารบัญตาราง

ตารางที่ 1 การเปรียบเทียบองค์ประกอบของงานวิจัยที่เกี่ยวข้องกับโครงงานนี้ . . . 11
ตารางที่ 2 สถาปัตยกรรมโมดูลการประมวลผลข้อมูลในระบบ (Data Pipeline Modules) 14
ตารางที่ 3 ผลการวัดระดับความสำคัญของกลุ่มตัวแปรเชิงทำนาย (Feature Importance Scores) 19
ตารางที่ 4 เปรียบเทียบประสิทธิภาพการทำนายความน่าจะเป็นของแบบจำลองบน Temporal Test Set 19
ตารางที่ 5 ผลการจำลองการวางเดิมพันย้อนหลังด้วยกลยุทธ์ต่าง ๆ (Backtesting Summary) 20
ตารางที่ 6 สรุปผลเทียบกับวัตถุประสงค์ของโครงงาน 21
ตารางที่ 7 ปัญหาอุปสรรคและแนวทางแก้ไขในการดำเนินโครงงาน 22

บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ปัจจุบัน ตลาดการเดิมพันกีฬาฟุตบอลถือเป็นตลาดการเงินทางเลือกที่มีมูลค่ามหาศาลทั่วโลก โดยเจ้ามือรับพนัน (Bookmakers) ได้ประมวลผลสถิติเชิงลึกร่วมกับแบบจำลองเชิงสถิติขั้นสูงเพื่อกำหนดราคาอัตราต่อรอง (Odds) ซึ่งสะท้อนถึงความน่าจะเป็นของผลการแข่งขัน อย่างไรก็ตาม ราคาต่อรองดังกล่าวมักถูกบวกส่วนต่างกำไรของเจ้ามือ (Overround / Vig) และมีการเปลี่ยนแปลงตามกระแสการเดิมพันของตลาด ส่งผลให้นักเดิมพันส่วนใหญ่ที่ตัดสินใจโดยใช้อารมณ์หรือสถิติพื้นฐานไม่สามารถสร้างผลตอบแทนที่ยั่งยืนได้ในระยะยาว

การพัฒนาแบบจำลองการทำนายผลการแข่งขันฟุตบอลยุโรป (ฤดูกาล 2014–2025) ด้วยกระบวนการวิทยาการข้อมูล (Data Science Process) และการเรียนรู้ของเครื่อง (Machine Learning) จึงเข้ามามีบทบาทสำคัญในการประเมิน **ความน่าจะเป็นที่แท้จริง (True Probabilities)** ของผลการแข่งขัน 3 ทางเลือก ได้แก่ เจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A) เพื่อนำไปเปรียบเทียบกับความน่าจะเป็นที่แฝงอยู่ในราคาต่อรองของตลาด (Implied Probabilities) สำหรับค้นหาโอกาสการเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (Value Betting / Positive Expected Value: +EV)

อย่างไรก็ตาม การสร้างแบบจำลองเพื่อประเมินศักยภาพการแข่งขันให้เหนือกว่าราคาตลาดมีความท้าทายสูงมาก เนื่องจากงานวิจัยในอดีต [1] ชี้ว่าแบบจำลองที่พึ่งพาเพียงสถิติผลย้อนหลังมักมีความแม่นยำจำกัด โครงงานนี้จึงมุ่งแก้ปัญหาดังกล่าวด้วยการบูรณาการ **ข้อมูลบริบทเชิงลึกก่อนการแข่งขัน (Pre-match Contextual Features)** ครอบคลุม 5 ลีกใหญ่ของยุโรป ได้แก่ คะแนนความแข็งแกร่ง Elo Rating, ดัชนีความเหนื่อยล้าสะสมของผู้เล่นตัวจริง, ความหนาแน่นของตารางแข่งขัน (รวมถึงฟุตบอลถ้วยและรายการยุโรป) และฟอร์มรายบุคคลของผู้เล่น 11 ตัวจริง (เช่น xG และ xA ต่อ 90 นาที) เพื่อนำมาสร้างแบบจำลองการทำนาย แล้วนำความน่าจะเป็นที่ได้ไปเข้ากลยุทธ์การจัดสรรเงินทุน (Staking Strategies) เช่น Kelly Criterion และ Fixed Staking พร้อมทดสอบย้อนหลัง (Backtesting) เพื่อวัดผลตอบแทนการลงทุน (ROI) ในสถานการณ์ที่สมจริง

1.2 วัตถุประสงค์

1) เพื่อ ศึกษา และ พัฒนา กระบวนการ วิทยาการ ข้อมูล อย่าง ครบ วงจร ตั้งแต่ การรวบรวมข้อมูลหลายแหล่ง (สถิติการแข่งขัน, แผนการเล่น และราคาต่อรอง) การทำความสะอาดข้อมูล ไปจนถึงการพัฒนาแบบจำลองทำนายผลลัพธ์การแข่งขัน

2) เพื่อ สร้าง และ วิเคราะห์ ตัวแปร ก่อน การ แข่งขัน (Pre-match Features) ได้แก่ คะแนน Elo, ดัชนีความเหนื่อยล้า, ความหนาแน่นของตารางแข่งขัน และฟอร์มผู้เล่นตัวจริง 11 คนแรก ที่มีผลต่อโอกาสชนะและความคุ้มค่าในการเดิมพัน

3) เพื่อพัฒนาระบบคำนวณและเปรียบเทียบความน่าจะเป็นของแบบจำลองกับราคาอัตราต่อรองของตลาด (Market Odds Analysis) เพื่อค้นหาโอกาสการเดิมพันที่มีมูลค่า (Value Betting)

4) เพื่อประเมินประสิทธิภาพของแบบจำลองและประเมินผลกำไรการลงทุนผ่านระบบทดสอบย้อนหลัง (Backtesting) ด้วยกลยุทธ์การบริหารเงินทุน (Staking Strategies) รูปแบบต่าง ๆ

1.3 ขอบเขตและข้อจำกัดของโครงงาน

1.3.1 ขอบเขตของโครงงาน

1) **ขอบเขตด้านข้อมูลและช่วงเวลา:** ใช้ชุดข้อมูลการแข่งขันฟุตบอลย้อนหลังครอบคลุมฤดูกาล 2014–2015 ถึง 2024–2025 จากแหล่งข้อมูลสาธารณะ ได้แก่

- *Understat*: รวบรวมสถิติผลการแข่งขัน ค่าความคาดหวังในการทำประตู (xG, xA) และสถิติเชิงลึกรายบุคคลของผู้เล่น [2]
- *Transfermarkt*: รวบรวมปฏิทินการแข่งขันครบทุกรายการ (รวมฟุตบอลถ้วยและรายการยุโรป) และแผนการเล่น (Formation) ของผู้เล่น 11 ตัวจริง [3]
- *Football-Data.co.uk*: รวบรวมข้อมูลผลการแข่งขัน ยิงประตู และราคาอัตราต่อรองย้อนหลัง (Historical Betting Odds Data Service) จากเจ้ามือรับพนันหลายแห่งสำหรับใช้ทดสอบแบบจำลองและประเมินผลตอบแทนทางการเงิน

2) **ขอบเขตด้านลีกการแข่งขัน:** ระบบการรวบรวมข้อมูลและกระบวนการประมวลผลตัวแปร (Feature Pipeline) ครอบคลุม 5 ลีกใหญ่ยุโรป ได้แก่ พรีเมียร์ลีก อังกฤษ, ลาลีกา สเปน, บุนเดสลีกา เยอรมนี, กัลโช่ เซเรียอา อิตาลี และลีกเอิง ฝรั่งเศส

3) **ขอบเขตด้านกระบวนการและระบบโครงสร้าง:** พัฒนาท่อส่งข้อมูลแบบโมดูลาร์ด้วยภาษา Python ประกอบด้วย กระบวนการจัดเก็บข้อมูล, การทำความสะอาดและสร้างตัวแปรพร้อมการตรวจสอบสัญญาโครงสร้างข้อมูล (Pandera Data Contracts), การวิเคราะห์การเดิมพันและการทดสอบย้อนหลัง (Backtesting), การวิเคราะห์ราคาตลาด (Market & Odds Analysis), ระบบทดสอบคำสั่งอัตโนมัติ และระบบเชื่อมต่อบริการทำนายผล (FastAPI)

4) **ขอบเขตด้านตัวแปรและการวิเคราะห์ตลาด (Market Analysis):**

- ใช้เฉพาะตัวแปรที่รับรู้ได้ล่วงหน้าก่อนการแข่งขัน (Pre-match Data) ได้แก่ คะแนน Elo,

ดัชนีความเหนื่อยล้า, ความหนาแน่นตารางแข่งขัน และฟอร์มผู้เล่น 11 ตัวจริง

- วิเคราะห์ราคาต่อรองอัตราจ่าย (Odds) เพื่อคำนวณค่าส่วนต่างเจ้ามือ (Overround / Vig) และแปลงเป็นความน่าจะเป็นของตลาด (Implied Probabilities)

5) **ขอบเขตด้านแบบจำลองและการประเมินผลกำไร:**

- ใช้แบบจำลองทางสถิติ Double Poisson (ร่วมกับการปรับแก้ Dixon-Coles) และ Machine Learning ชนิด Gradient Boosting (HistGradientBoosting) ในการทำนายความน่าจะเป็น
- ทดสอบกลยุทธ์การวางเดิมพัน (Staking Strategies) ได้แก่ การวางเงินคงที่ (Fixed Staking) และการปรับสัดส่วนตามความคุ้มค่า (Kelly Criterion / Fractional Kelly)
- แบ่งชุดข้อมูลทดสอบตามลำดับเวลา (Temporal Split / Walk-forward) เพื่อป้องกันปัญหาข้อมูลรั่วไหลจากอนาคต (Data Leakage)

6) **ตัวชี้วัดประสิทธิภาพ:**

- *ด้านแบบจำลอง:* Log Loss, Ranked Probability Score (RPS), Accuracy และ Permutation Importance
- *ด้านการลงทุน/เดิมพัน:* อัตราผลตอบแทนจากการลงทุน (Yield / ROI), ผลกำไรสะสม (Net Profit/Loss) และระดับความเสี่ยงการลดลงของเงินทุน (Drawdown)

1.3.2 ข้อจำกัดของโครงงาน

1) ราคาต่อรองที่ใช้ในการทดสอบย้อนหลังอ้างอิงจากข้อมูล Football-Data.co.uk ซึ่งเป็นราคา ณ ช่วงเวลาที่บันทึก ในสถานการณ์จริงราคาอัตราต่อรองมีความผันผวนอยู่ตลอดเวลา (Odds Movement / Slippage)

2) โครงงานไม่ได้รวมปัจจัยเชิงคุณภาพที่ไม่ปรากฏในสถิติ เช่น ข่าวสารการ บาด เจ็บ นาที สุดท้าย สภาพ อากาศ สภาพ สนาม หรือ การเปลี่ยนแปลงผู้จัดการทีม

3) สถิติเชิงลึกรายผู้เล่นจาก Understat ครอบคลุมเฉพาะนัดในลีก ทำให้ค่าดัชนีความเหนื่อยล้ารายบุคคลอาจคลาดเคลื่อนเล็กน้อยสำหรับทีมที่เล่นฟุตบอลถ้วยหลายรายการ (ได้รับการชดเชยบางส่วนด้วยตัวแปรตารางแข่งขันระดับทีมจาก Transfermarkt)

4) ข้อมูลที่รวบรวมจากต่างแหล่งต้องใช้ตารางจับคู่ชื่อสโมสรและนักเตะมาตรฐาน (Alias Mapping) ซึ่งอาจมีค่าว่างในกรณีที่ไม่สามารถจับคู่ข้อมูลระหว่างแหล่งข้อมูลได้

5) ผลลัพธ์และกลยุทธ์ที่ได้จัดทำขึ้นเพื่อวัตถุประสงค์ทางวิชาการและการศึกษาเชิงสถิติเท่านั้น ไม่ได้มีเจตนาในการส่งเสริมการพนันที่ไม่ถูกต้องตามกฎหมาย

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1) ได้กระบวนการวิทยาการข้อมูลแบบครบวงจรสำหรับการวิเคราะห์ข้อมูลกีฬาและสถิติการเดิมพันอย่างเป็นระบบ

2) ได้ระบบประเมินความคุ้มค่าของการเดิมพัน (Value Betting System) ที่สามารถเปรียบเทียบความน่าจะเป็นจริงของแบบจำลองกับราคาตลาด และแนะนำขนาดเงินวางเดิมพันได้อย่างเหมาะสม

3) ได้ระบบทดสอบย้อนหลัง (Backtesting System) ที่สามารถประเมินผลกำไรและความเสี่ยงของการใช้กลยุทธ์เดิมพันรูปแบบต่าง ๆ บนข้อมูลจริงย้อนหลัง 10 ฤดูกาล (2014–2025)

4) ได้องค์ความรู้ในการประยุกต์ใช้เทคนิควิทยาการข้อมูล การเรียนรู้ของเครื่อง และกลยุทธ์ทางการเงิน/การวางเงินทุน เพื่อนำไปปรับใช้กับการวิเคราะห์ตลาดการแข่งขันอื่น ๆ ในอนาคต

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 กระบวนการวิทยาการข้อมูลและการจัดทำท่อส่งข้อมูล (Data Science & Pipeline Process)

กระบวนการวิทยาการข้อมูลเป็นกรอบการทำงานเชิงระบบที่นำข้อมูลขนาดใหญ่มาประมวลผลและวิเคราะห์ เพื่อค้นหารูปแบบหรือสร้างคุณประโยชน์ ในโครงงานนี้ได้ประยุกต์ใช้กระบวนการ 5 ขั้นตอน ร่วมกับการออกแบบท่อส่งข้อมูลแบบโมดูลาร์ (Modular Data Pipeline) ได้แก่

1) **การ กำหนด วัตถุประสงค์ และ คำถาม วิจัย (Question Refinement):** กำหนดโจทย์การทำนายผลการแข่งขันฟุตบอลออกเป็น 3 รูปแบบ ได้แก่ ทีมเจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A) เพื่อนำไปประเมินความคุ้มค่าในการเดิมพันเชิงสถิติ

2) **การเก็บรวบรวมข้อมูล (Data Collection):** การสร้างระบบดึงข้อมูลอัตโนมัติ เพื่อรวบรวมตารางการแข่งขัน ผลประตู ค่า xG และสถิติรายบุคคลจาก Understat, ปฏิทินการแข่งขันและแผนการเล่นจาก Transfermarkt รวมถึงสถิติผลการแข่งขันย้อนหลังและราคาอัตราต่อรอง (Betting Odds) จาก Football-Data.co.uk [**?**, 3, 2]

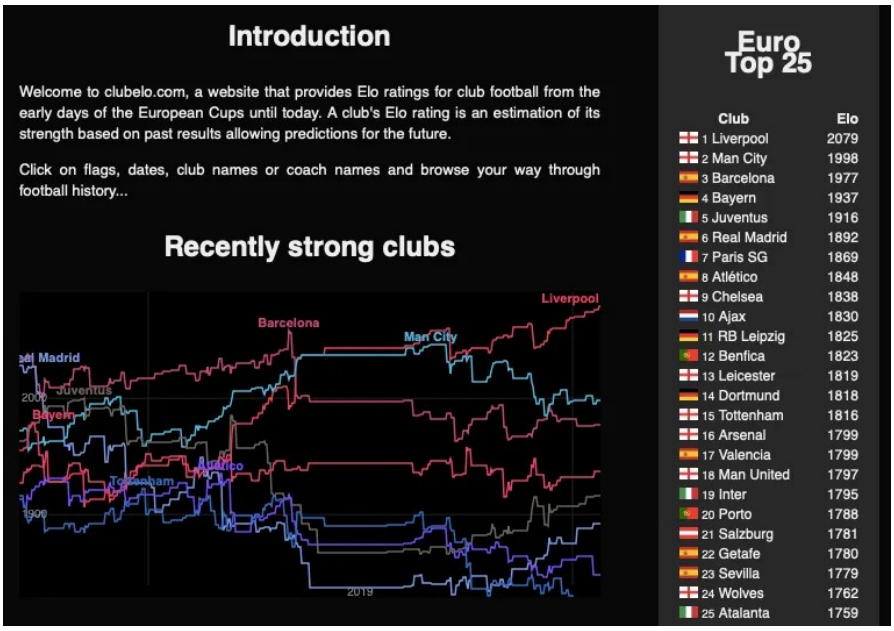
3) **การตรวจสอบ ทำความสะอาด และสร้างตัวแปร (Data Validation & Feature Engineering):** การตรวจสอบคุณภาพข้อมูลผ่านสัญญาข้อมูล (Data Contracts / Pandera) การจัดการค่าที่ขาดหาย การจับคู่ชื่อสโมสร (Entity Resolution) และการสร้างตัวแปรก่อนการแข่งขัน เช่น คะแนน Elo, ดัชนีความเหนื่อยล้า, ความหนาแน่นของตารางแข่งขัน และฟอร์มของผู้เล่นตัวจริง 11 คนแรก

4) **การสร้างและประเมินแบบจำลอง (Model Building & Evaluation):** การพัฒนาแบบจำลองเพื่อทำนายความน่าจะเป็นที่แท้จริงของผลการแข่งขัน และประเมินประสิทธิภาพด้วยตัวชี้วัด Log Loss, Ranked Probability Score (RPS) และ Accuracy [4]

5) **การสรุป วิเคราะห์ตลาด และการจำลองเดิมพัน (Market Analysis & Backtesting):** การวิเคราะห์ราคาต่อรองเพื่อหาโอกาสการเดิมพันที่มีมูลค่า (Value Betting) การประเมินผลกำไร/ขาดทุนสะสม (ROI) ด้วยกลยุทธ์การวางเงินทุนรูปแบบต่าง ๆ และการนำเสนอระดับความสำคัญของตัวแปรทำนาย (Feature Importance)

2.1.2 ระบบวัดระดับความแข็งแกร่ง (Elo Rating System)

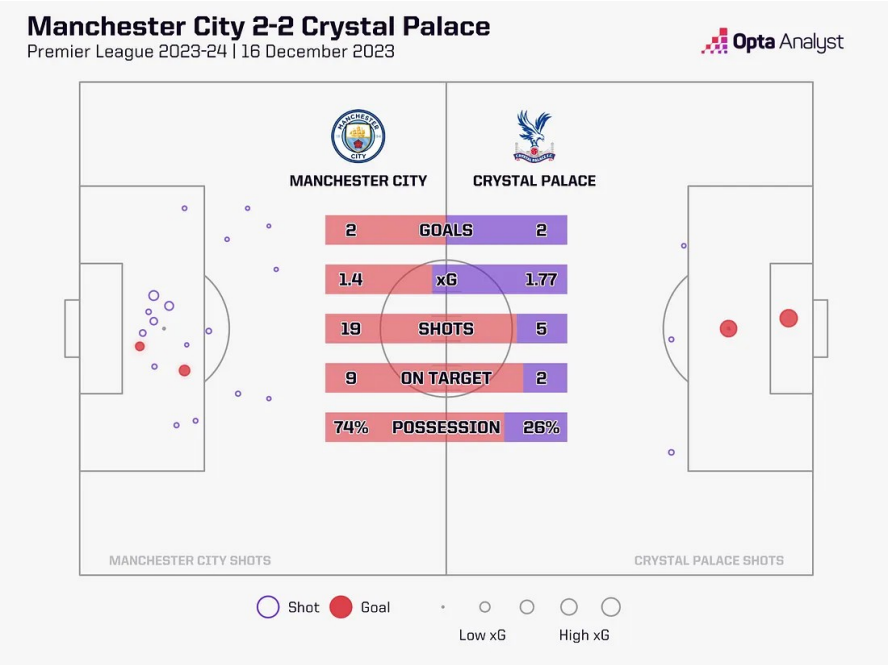
ระบบคะแนน Elo เป็นวิธีทางสถิติที่ใช้คำนวณระดับทักษะความแข็งแกร่งของทีมแข่งขัน คะแนนจะถูกปรับเปลี่ยนตามผลการแข่งขันจริงและระดับความแข็งแกร่งของคู่แข่ง โดยทีมที่ชนะทีมที่มีคะแนนสูงกว่าจะได้คะแนนเพิ่มขึ้นมากกว่าการชนะทีมที่อ่อนกว่า [5] สำหรับฟุตบอล การปรับคะแนนสามารถถ่วงน้ำหนักตามผลต่างประตูของการแข่งขันได้ เพื่อให้ชัยชนะที่ขาดลอยส่งผลต่อคะแนนมากกว่าชัยชนะเฉียดฉิว ในโครงงานนี้ได้มีการคำนวณค่า Elo Rating ของแต่ละสโมสรอย่างต่อเนื่องตามลำดับเวลา (Time-series) ดังแสดงในรูปที่ 1 และนำผลต่างคะแนน Elo (Elo Difference) ระหว่างทีมเจ้าบ้านและทีมเยือน ซึ่งใช้ค่าก่อนเริ่มการแข่งขันเท่านั้น มาใช้เป็นตัวแปรสำคัญในการสะท้อนความได้เปรียบเชิงศักยภาพของทีม



ภาพที่ 1 ตัวอย่างแผนภาพแสดงการปรับปรุงคะแนน Elo Rating ของสโมสรฟุตบอลตามผลการแข่งขันย้อนหลัง (ที่มา: ClubElo)

2.1.3 ค่าความคาดหวังในการทำประตู (Expected Goals: xG)

ค่า xG เป็นตัวชี้วัดเชิงสถิติขั้นสูงที่ใช้ประเมินคุณภาพของโอกาสในการยิงประตู โดยคำนวณความน่าจะเป็นที่ลูกยิงแต่ละครั้งจะกลายเป็นประตู (มีค่าระหว่าง 0 ถึง 1) ขึ้นอยู่กับตำแหน่งการยิง มุมในการยิง ประเภทการส่งบอล และบริบทของเกม ดังแสดงตัวอย่างในรูปที่ 2 ค่า xG ช่วยให้มองเห็นประสิทธิภาพเกมรุกที่แท้จริง ซึ่งสะท้อนฟอร์มการเล่นได้ดีกว่าผลสกอร์แพ้-ชนะแบบดั้งเดิม [2] ในโครงงานนี้ ค่า xG และค่า xA (Expected Assists) รายบุคคลถูกนำมาสรุปเป็นฟอร์มของผู้เล่นตัวจริงแต่ละคน ในรูปอัตราต่อ 90 นาที โดยใช้เฉพาะการแข่งขันก่อนนัดปัจจุบัน



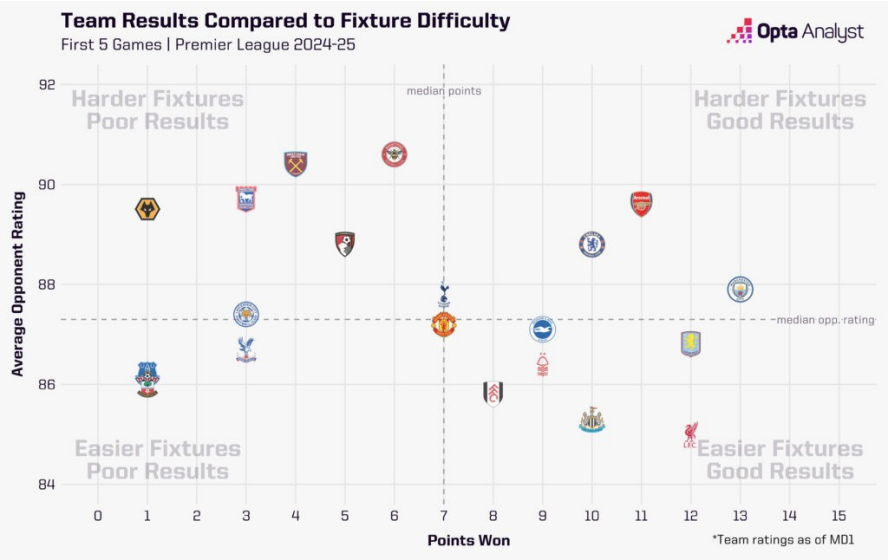
ภาพที่ 2 ตัวอย่างการประเมินค่าความคาดหวังในการทำประตู (Expected Goals: xG) จากตำแหน่งการยิง (ที่มา: Opta Analyst)

2.1.4 ดัชนีความเหนื่อยล้าและความหนาแน่นของตารางแข่ง (Fatigue Metric & Schedule Congestion)

ระยะ เวลา พัก ผ่อน ระ หว่าง แมตช์ การ แข่งขัน ส่ง ผล ต่อ สภาพ ร่างกาย และประสิทธิภาพการเล่นของนักเตะ ในโครงงานนี้จึงสร้างตัวแปรที่เกี่ยวข้องกับภาระการเล่นเป็น 2 ระดับ ดังแสดงตัวอย่างแนวคิดในรูปที่ 3

1) **ระดับผู้เล่น:** คำนวณคะแนนความเหนื่อยล้า (Fatigue Score) ช่วง 0–100 จากนาทีที่ลงเล่นใน 7 วันก่อนหน้า ความสั้นของระยะพัก จำนวนนัดที่ลงเล่นติดต่อกัน และอัตราส่วนภาระงานระยะสั้นต่อระยะยาว (Acute-to-Chronic Workload Ratio) แล้วสรุปเป็นค่าเฉลี่ยของผู้เล่นตัวจริงแต่ละฝั่ง

2) **ระดับทีม:** คำนวณจากปฏิทินการแข่งขันทุกรายการ ได้แก่ จำนวนวันพักนับจากนัดก่อนหน้า จำนวนนัดใน 7 และ 14 วันที่ผ่านมา จำนวนนัดที่ไม่ใช่ลีกใน 14 วัน และการเดินทางไปเยือนในศึกยุโรปในนัดก่อนหน้า



ภาพที่ 3 ตัวอย่างการวิเคราะห์ความตึงเครียดของโปรแกรมแข่งขัน

2.1.5 อัตราต่อรองของเจ้ามือรับพนันและการเดิมพันที่มีมูลค่า (Betting Odds & Value Betting)

ราคาอัตราต่อรองจากเจ้ามือรับพนัน (Bookmakers) สามารถแปลงเป็นค่าความน่าจะเป็นโดยนัย (Implied Probability) ได้ โดยคำนวณจากส่วนกลับของราคาต่อรอง เช่น อัตราจ่าย O จะมีความน่าจะเป็นโดยนัยเท่ากับ $1/O$ อย่างไรก็ตาม ผลรวมความน่าจะเป็นของทุกทางเลือก (Home/Draw/Away) มักจะเกินร้อยละ 100 เนื่องจากถูกบวกส่วนต่างกำไรของเจ้ามือ (Overround / Vig)

การวิเคราะห์เพื่อการเดิมพันจะใช้แบบจำลองคำนวณ **ความน่าจะเป็นที่แท้จริง (Model Probability: P)** แล้วนำไปเปรียบเทียบกับราคาต่อรองในตลาด หากราคาต่อรองในตลาดให้ค่าสูงกว่าความน่าจะเป็นของแบบจำลอง จะถือว่าเกิด **การเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (Positive Expected Value: +EV / Value Bet)** โดยค่าความคาดหมายคำนวณได้จาก:

$$EV = (P \times O) - 1 \tag{1}$$

หากค่า $EV > 0$ แสดงว่าการวางเดิมพันในตัวเลือกนั้นมีความคุ้มค่าทางสถิติในระยะยาว

2.1.6 กลยุทธ์การบริหารเงินทุนและการทดสอบย้อนหลัง (Staking Strategies & Backtesting)

ในการประเมินผลตอบแทนทางการเงิน การทำนายผลถูกต้องเพียงอย่างเดียวไม่เพียงพอ แต่ต้องอาศัยกลยุทธ์การจัดสรรเงินทุน (Staking Strategy) ที่เหมาะสม เพื่อป้องกันความเสี่ยงจากการหมดตัว (Risk of Ruin) โครงงานนี้ทดสอบกลยุทธ์การวางเงิน 2 รูปแบบหลัก ได้แก่:

1) **การวางเงินคงที่ (Fixed Staking):** กำหนดจำนวนเงินวางเดิมพันเป็นจำนวนเงินที่แน่นอนเท่ากันทุกครั้ง

2) **สูตรการวางเงินแบบเคลลี (Kelly Criterion):** คำนวณสัดส่วนเงินทุน

ที่ควรวางเดิมพัน (f^*) ตามระดับความคุ้มค่าและอัตราต่อรอง:

$$f^* = \frac{P \cdot O - 1}{O - 1} \tag{2}$$

พร้อมทั้งทดสอบสัดส่วนเคลลีแบบย่อย (Fractional Kelly เช่น Half-Kelly หรือ Quarter-Kelly) เพื่อลดความผันผวนของเงินทุน

ระบบการทดสอบย้อนหลัง (Backtesting Engine) จะจำลองการวางเดิมพันตามลำดับเวลาจริง (Temporal Backtesting) บนข้อมูลย้อนหลัง 10 ฤดูกาล เพื่อวัดอัตราผลตอบแทนจากการลงทุน (ROI), กำไรสะสม (Net Profit/Loss) และระดับการลดลงสูงสุดของเงินทุน (Maximum Drawdown)

2.1.7 การจับคู่และแปลงชื่อเอนทิตีให้เป็นมาตรฐาน (Entity Resolution)

เนื่องจากข้อมูลถูกรวบรวมมาจากหลายแหล่งข้อมูลภายนอก (Understat, Transfermarkt, Football-Data.co.uk) ทำให้ชื่อสโมสรฟุตบอลเดียวกันอาจถูกบันทึกด้วยข้อความที่แตกต่างกัน กระบวนการ Entity Resolution จึงถูกนำมาใช้เพื่อปรับแปลงชื่อทีมจากทุกแหล่งข้อมูลให้อยู่ในรูปแบบมาตรฐาน (Canonical Team Names) ผ่านพจนานุกรมเทียบเคียงชื่อ (Alias Mapping) เพื่อให้สามารถเชื่อมโยงข้อมูล (Data Joining) ได้อย่างแม่นยำ ทั้งนี้สโมสรที่ไม่สามารถจับคู่ได้จะมีตัวแปรที่ต้องอาศัยแหล่งนั้นเป็นค่าว่าง

2.1.8 แบบจำลองทำนายผลการแข่งขัน

การทำนายผลการแข่งขันฟุตบอลถูกกำหนดให้เป็นโจทย์ที่ให้ผลลัพธ์เป็นความน่าจะเป็นของ 3 กลุ่ม ได้แก่ ทีมเจ้าบ้านชนะ (H), เสมอ (D) และทีมเยือนชนะ (A) โครงงานนี้ใช้แบบจำลอง 2 แนวทางที่มีบทบาทต่างกัน ดังนี้

(0.1) 1) แบบจำลอง Double Poisson และการแก้ไขแบบ Dixon-Coles

จำนวนประตูของทีมเจ้าบ้านและทีมเยือนถูกจำลองเป็นตัวแปรสุ่มแบบปัวซง (Poisson) สองตัว โดยให้ค่าลอการิทึมของอัตราการทำประตูเป็นฟังก์ชันเชิงเส้นของผลต่างคะแนน Elo ก่อนการแข่งขัน (หารด้วย 400) ซึ่งประมาณค่าด้วย Poisson Regression จากนั้นนำความน่าจะเป็นของสกอร์ทุกค่ามาสร้างตารางร่วม (Score Grid) แล้วรวมเป็นความน่าจะเป็นของ H, D และ A การแก้ไขแบบ Dixon-Coles [6] ปรับความน่าจะเป็นของสกอร์ต่ำ (0–0, 1–0, 0–1 และ 1–1) ด้วยพารามิเตอร์ ρ เพื่อแก้ปัญหาที่การแจกแจงปัวซงอิสระประเมินความน่าจะเป็นของสกอร์เหล่านี้คลาดเคลื่อน การทำนายใช้วิธี Walk-forward คือทำนายแต่ละฤดูกาลด้วยแบบจำลองที่ฝึกจากฤดูกาลก่อนหน้าเท่านั้น

(0.2) 2) Gradient Boosting

เป็นเทคนิค Ensemble Learning ที่สร้างต้นไม้ตัดสินใจขนาดเล็กหลายต้นต่อเนื่องกัน โดยใช้ `HistGradientBoostingClassifier` ของ Scikit-learn [4] เป็นแบบจำลองในการประมวลผลตัวแปรเชิงซ้อนก่อนการแข่งขัน เพื่อทำนายความน่าจะเป็นและวัด

ระดับความสำคัญของตัวแปร

(0.3) 3) Permutation Importance

วัดความสำคัญของตัวแปรจากระดับที่ค่า Log Loss บนชุดทดสอบเพิ่มขึ้นเมื่อสลับค่าของตัวแปรนั้นแบบสุ่มโดยไม่เปลี่ยนค่าอื่น ตัวแปรที่เมื่อถูกสลับแล้วทำให้ Log Loss เพิ่มมากแสดงว่าให้ข้อมูลสำคัญต่อแบบจำลอง เนื่องจากตัวแปรผู้เล่นตัวจริง 22 ตำแหน่งมีความสัมพันธ์กันสูง จึงสลับค่าเป็นกลุ่มพร้อมกัน แทนการสลับทีละคอลัมน์

(0.4) 4) ตัวชี้วัดประสิทธิภาพ

ประเมิน 2 มิติ ได้แก่ มิติประสิทธิภาพโมเดลด้วย **Log Loss** (คุณภาพความน่าจะเป็น), **Ranked Probability Score (RPS)** (ความคลาดเคลื่อนสะสม) และ **Accuracy** ร่วมกับมิติทางการเงินด้วย **ROI / Yield** (เปอร์เซ็นต์กำไรสุทธิเทียบกับยอดลงเงิน) และ **Maximum Drawdown** (ระดับขาดทุนสะสมสูงสุด)

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 การทำนายผลฟุตบอลและการประเมินประสิทธิภาพเทียบกับตลาดเดิมพัน

งานวิจัยยุคแรกมักใช้สถิติการแข่งขันย้อนหลัง เช่น จำนวนประตูและฟอร์มเหย้า-เยือน ผ่านโมเดลเชิงสถิติตระกูล Poisson [6] หรือระบบจัดอันดับ Rating [5, 7] ซึ่งจากการประเมินโดย Hubáček และคณะ [1] บนชุดข้อมูลกว่า 2.1 แสนนัด พบว่าแบบจำลองที่ใช้เพียงผลสกอร์ย้อนหลังมีขีดจำกัดความแม่นยำอยู่เพียงร้อยละ 47.8–48.6 เท่านั้น ในขณะที่ราคาอัตราต่อรองจากตลาดเดิมพันสะท้อนความแม่นยำสูงถึงประมาณร้อยละ 53–55 เนื่องจากประมวลผลข้อมูลเชิงลึกในตลาดได้อย่างรวดเร็ว

2.2.2 การใช้ Machine Learning ร่วมกับสถิติเชิงลึก และกลยุทธ์การเอาชนะตลาด

งานวิจัยระยะหลังเริ่มนำตัวชี้วัดขั้นสูง เช่น xG และไลน์อัปตัวจริง มาประกอบการสร้างแบบจำลอง Berrar และคณะ [8] ชี้ว่าการใช้ข้อมูลบริบทเชิงลึกช่วยเพิ่มประสิทธิภาพการทำนายได้อย่างมีนัยสำคัญ นอกจากนี้ งานวิจัยด้านการทำนายเชิงพาณิชย์ยังเน้นย้ำถึงการใช้สูตร Kelly Criterion ร่วมกับการทำนายแบบ Walk-forward Validation เพื่อทดสอบว่าแบบจำลองสามารถสร้างกำไรสุทธิ (Positive ROI) หลังจากหักค่าส่วนต่างของเจ้ามือ (Overround) ได้หรือไม่

2.2.3 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรม สามารถสรุปเปรียบเทียบองค์ประกอบระหว่างแนวทางงานวิจัยทั่วไปกับโครงงานนี้ได้ดังตารางที่ 1

จากตารางที่ 1 แสดงให้เห็นว่าโครงงานนี้บูรณาการตัวแปรก่อนการแข่งขันครอบคลุมสถิติขั้นสูง (Elo, xG) ฟอร์มผู้เล่นตัวจริง และภาระโปรแกรมแข่งขัน ร่วมกับการวิเคราะห์ราคาตลาดต่อรองและระบบทดสอบย้อนหลัง (Backtesting Engine) เพื่อประเมินความคุ้มค่าทางการเงิน

ตารางที่ 1 การเปรียบเทียบองค์ประกอบของงานวิจัยที่เกี่ยวข้องกับโครงงานนี้

การศึกษา / โครงงาน	สถิติผลสกอร์	อัตราต่อรอง	Elo / xG	ไลน์อัป / ฟอร์มผู้เล่น	ตารางแข่ง/ความเหนื่อยล้า	Backtesting / Staking
งานวิจัยที่เน้นสถิติการแข่งขัน [6, 1]	✓	–	–	–	–	–
งานวิจัยที่เน้นอัตราต่อรองตลาด [7]	✓	✓	–	–	–	–
งานวิจัยใช้แบบจำลอง ML เบื้องต้น [5, 8]	✓	–	✓	–	–	–
โครงงานนี้	✓	✓	✓	✓	✓	✓

2.3 เครื่องมือและเทคโนโลยีที่ใช้

2.3.1 ภาษา Python และไลบรารีสำหรับการประมวลผลข้อมูล

1) **Polars, DuckDB และ PyArrow:** ใช้สำหรับการจัดการ ทำความสะอาด และ ประมวล ผล ตาราง ข้อมูล ประสิทธิภาพ สูง (High-performance DataFrames)

2) **Pandera และ Pydantic:** ใช้สำหรับการตรวจสอบความถูกต้องของโครงสร้างข้อมูล (Data Schema Validation & Data Contracts) และการตรวจสอบไฟล์ตั้งค่าของระบบ

3) **Soccerdata:** ใช้ดึงข้อมูลสถิติการแข่งขันและค่า xG จาก Understat

4) **Scikit-learn และ SciPy:** ใช้พัฒนาแบบจำลอง (Poisson Regression, Gradient Boosting) การคำนวณตัวชี้วัด และการทดสอบสมมติฐานทางสถิติ [4]

5) **FastAPI และ Uvicorn:** ใช้พัฒนาบริการระบบ API สำหรับเรียกดูข้อมูลและผลการทำนาย

2.3.2 สภาพแวดล้อมและการประกันคุณภาพซอฟต์แวร์ (Development Environment & Quality Control)

1) **ระบบบริหารจัดการสภาพแวดล้อมเสมือน (uv) และ Docker: uv** บริหารจัดการ Virtual Environment และไลบรารีความเร็วสูง พร้อมไฟล์ล็อกรุ่นของไลบรารี ส่วน Docker ช่วยให้รันท่อส่งข้อมูลและ API ได้ในสภาพแวดล้อมเดียวกัน

2) **ระบบทดสอบซอฟต์แวร์และตรวจสอบโค้ดอัตโนมัติ:** ใช้ Pytest และ Hypothesis สำหรับชุดทดสอบอัตโนมัติ ใช้ Ruff และ Pyright สำหรับตรวจรูปแบบและชนิดข้อมูล ใช้ pre-commit และ GitHub Actions ตรวจสอบก่อนบันทึกขึ้นระบบ

3) **แหล่ง ชุด ข้อมูล สาธารณะ (Understat, Transfermarkt, Football-Data.co.uk):** เป็นแหล่งข้อมูลสถิติเชิงลึก xG, ปฏิทินการแข่งขันและไลน์อัปผู้เล่น รวมถึงสถิติผลการแข่งขันย้อนหลังและราคาอัตราต่อรองของเจ้ามือ [**?**, 3, 2]

บทที่ 3
วิธีการดำเนินโครงงาน

ในการดำเนินโครงงาน "การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลสำหรับลีกยุโรปตั้งแต่ 2014-2025 ด้วยกระบวนการวิทยาการข้อมูลสำหรับนักเดิมพัน (A Data Science Approach to Analyzing and Predicting European Football League Match Outcomes (2014-2025) for Gamblers)" ผู้จัดทำได้ออกแบบและพัฒนาท่อส่งข้อมูลเชิงโมดูลาร์ (Modular Data Pipeline) ตามกระบวนการวิทยาการข้อมูล เพื่อให้ระบบสามารถประมวลผลข้อมูลที่มีความซับซ้อน ป้องกันปัญหาข้อมูลอนาคตรั่วไหล (Data Leakage) และรองรับการประเมินผลกำไรทางการเงินร่วมกับการทำนายทางสถิติได้อย่างเป็นระบบ โดยแบ่งขั้นตอนการดำเนินงานออกเป็น 6 ส่วนหลัก ดังนี้

1) การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน
2) การเก็บรวบรวมข้อมูล (Data Collection)
3) การทำความสะอาดข้อมูล และการตรวจสอบความถูกต้อง (Data Cleaning, Schema Validation & Entity Resolution)
4) การวิศวกรรมฟีเจอร์และการวิเคราะห์ตลาดเดิมพัน (Feature Engineering & Betting Market Analysis)
5) การพัฒนาแบบจำลอง การแบ่งชุดข้อมูล และระบบทดสอบย้อนหลัง (Model Development, Split & Backtesting Framework)
6) การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance Framework)

3.1 การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน

การทำนายผลการแข่งขันฟุตบอลและการประเมินความคุ้มค่าทางการเดิมพันมีความซับซ้อนสูง เนื่องจากต้องคำนึงถึงทั้งปัจจัยเชิงสถิติของทีมและการตั้งราคาต่อรองของตลาด โครงงานนี้จึงมุ่งเน้นการใช้ประโยชน์จากข้อมูลที่ทราบก่อนเริ่มการแข่งขันเท่านั้น โดยมีแนวทางการดำเนินงานดังนี้

1) **ศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้อง:** ศึกษาหลักการคำนวณระบบประเมินศักยภาพเชิงสัมพัทธ์ (Elo Rating System) [5], ค่าความคาดหวังในการทำประตู (Expected Goals: xG) [2], แบบจำลองปัวซองสำหรับจำนวนประตู [6], การคำนวณดัชนีความเหนื่อยล้าสะสม (Fatigue Index), การคำนวณความน่าจะเป็นของตลาดจากอัตราต่อรอง (Implied Probabilities) และกลยุทธ์การจัดสรรเงินทุน (Kelly Criterion & Staking Strategies)

2) **กำหนดขอบเขตและเป้าหมายการทำนาย:** กำหนดเป้าหมายการทำนายผลการแข่งขันออกเป็น 3 ผลลัพธ์ ได้แก่ เจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A) โดยทำนายเป็นความน่าจะเป็นของแต่ละผลลัพธ์ เพื่อนำไปค้นหาการเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (Positive Expected Value: +EV)

3) **กำหนดเครื่องมือและสภาพแวดล้อมการพัฒนา:** พัฒนาระบบด้วยภาษา Python 3.14 ขึ้นไป ร่วมกับเครื่องมือบริหารจัดการสภาพแวดล้อมเสมือน (**uv**), ไลบรารีวิเคราะห์ข้อมูลตาราง (Polars), เครื่องมือตรวจสอบสัญญาข้อมูล (Pandera และ Pydantic), ไลบรารีเรียนรู้ของเครื่อง (Scikit-learn), ระบบทดสอบซอฟต์แวร์อัตโนมัติ (Pytest) และระบบตรวจทานคุณภาพโค้ด (Ruff และ Pyright)

3.2 การเก็บรวบรวมข้อมูล (Data Collection)

ผู้จัดทำได้พัฒนาระบบดึงข้อมูลอัตโนมัติ เพื่อรวบรวมข้อมูลจากแหล่งข้อมูลสาธารณะ โดยมีหลักการทำงานที่สำคัญ 2 ประการ คือ (1) สามารถเริ่มทำงานต่อได้ (Resumable) โดยข้ามไฟล์ที่มีอยู่แล้ว และ (2) ตรวจสอบความสมบูรณ์ก่อนบันทึก โดยเขียนข้อมูลลงไฟล์ชั่วคราวก่อน อ่านกลับมาตรวจกับโครงสร้างข้อมูลดิบ (Raw Schema) แล้วจึงเปลี่ยนชื่อเป็นไฟล์จริง เพื่อป้องกันไฟล์เสียหาย

1) **ตารางการแข่งขันและสถิติ Understat:** ดึงผ่านไลบรารี soccerdata ครอบคลุม 5 ลีกใหญ่ยุโรป ตั้งแต่ฤดูกาล 2014–2015 ถึง 2024–2025 ประกอบด้วยผลประตู ค่า xG/xA และสถิติรายบุคคลของผู้เล่นในแต่ละนัด [2]

2) **Transfermarkt:** รวบรวมชุดข้อมูลปฏิทินการแข่งขันทุกรายการ (ลีก ถ้วยในประเทศ และรายการยุโรป) ของสโมสรใน 5 ลีกใหญ่ และตารางการลงสนามของผู้เล่น รวมถึงแผนการเล่น (Formation) ตัวจริง 11 คนแรก [3]

3) **Football-Data.co.uk:** ดึงข้อมูลสถิติผลการแข่งขันย้อนหลัง สถิติการยิง/เตะมุม และราคาอัตราต่อรอง (Betting Odds) จากเจ้ามือรับพนันหลายแห่ง (เช่น Bet365, Pinnacle) ย้อนหลังตั้งแต่ฤดูกาล 2014–2015 ถึง 2024–2025 สำหรับใช้ประเมินความน่าจะเป็นของตลาดและทดสอบย้อนหลัง [**?**]

3.3 การทำความสะอาดข้อมูลและการตรวจสอบความถูกต้อง

3.3.1 ขั้นตอนการทำความสะอาด (Data Cleaning)

กระบวนการทำความสะอาดแปลงไฟล์ข้อมูลดิบเป็นตารางสะอาดหลัก ได้แก่ ตารางนัดการแข่งขันลีก, ตารางสถิติผู้เล่นรายนัด, ตารางการแข่งขันทุกรายการของ Transfermarkt และตารางราคาต่อรองของ Football-Data.co.uk โดยมีขั้นตอนหลักดังนี้

1) คัดเลือกเฉพาะนัดที่แข่งขันจบแล้ว และแปลงระบุฤดูกาลให้อยู่ในรูปแบบมาตรฐาน (เช่น 2014)

2) แปลงชื่อสโมสรจากทุกแหล่งข้อมูลให้เป็นชื่อมาตรฐานเดียวกัน (ดูหัวข้อ Entity Resolution)

3) แปลงรูปแบบแผนการเล่น (Formation) เช่น **4-2-3-1** เป็นตัวเลขจำนวนแนวรับ แนวกลาง และแนวรุก

4) เชื่อมโยงนัดการแข่งขันระหว่าง Understat, Transfermarkt และ Football-Data.co.uk ตามวันที่และคู่แข่งขัน

3.3.2 การจับคู่และแปลงชื่อเอนทิตีให้เป็นมาตรฐาน (Entity Resolution)

เนื่องจากชื่อสโมสรในแต่ละแหล่งข้อมูลมีความแตกต่างกัน ระบบจึงใช้พจนานุกรมเทียบเคียงชื่อ (Alias Table) แปลงเป็นชื่อมาตรฐาน (Canonical Names) ส่วนการจับคู่ระหว่างรหัสสโมสรของ Transfermarkt กับชื่อทีมของ Understat และ Football-Data.co.uk ใช้วิธีเรียนรู้จากตัวนัดการแข่งขัน โดยถือว่าเป็นนัดเดียวกันเมื่อแข่งขันในลีกเดียวกัน สกอร์ตรงกัน และวันที่แข่งขันห่างกันไม่เกิน 1 วัน

3.3.3 การตรวจสอบความถูกต้องของข้อตกลงข้อมูล (Data Schema Validation)

ระบบประยุกต์ใช้แนวคิดสัญญาข้อมูล (Data Contracts) ด้วย Pandera โดยตรวจข้อมูลขาเข้าและขาออกในทุกขั้นตอน ร่วมกับโครงสร้างข้อมูลที่กำหนด แบ่งเป็น 3 ระดับ ดังนี้

- **โครงสร้างข้อมูลดิบ (Raw Schema):** ตรวจไฟล์ข้อมูลดิบตอนดาวน์โหลดและอ่านเข้าสู่ระบบ
- **โครงสร้างข้อมูลระหว่างทาง (Step Schema):** ตรวจประเภทข้อมูลและขอบเขตค่าผลลัพธ์ในแต่ละขั้นตอนการประมวลผล
- **โครงสร้างข้อมูลสุดท้าย (Clean Schema):** ตรวจไฟล์ตารางสะอาดทุกไฟล์กับ Schema ที่กำหนดก่อนนำไปสร้างตัวแปร

3.4 การวิศวกรรมฟีเจอร์และการวิเคราะห์ตลาดเดิมพัน

สถาปัตยกรรมของระบบเป็นท่อส่งข้อมูลแบบโมดูลาร์ที่ประมวลผลตามลำดับ ดังตารางที่ 2

ตารางที่ 2 สถาปัตยกรรมโมดูลการประมวลผลข้อมูลในระบบ (Data Pipeline Modules)

ลำดับ	คำสั่ง / โมดูล	หน้าที่การทำงานหลัก
1	`Data Collection`	ดึงข้อมูลดิบจาก Understat, Transfermarkt และ Football-Data.co.uk
2	`Data Cleaning`	ทำความสะอาด แปลงชื่อสโมสร จับคู่นัดระหว่างแหล่งข้อมูล
3	`Feature Engineering`	คำนวณ Elo, ความเหนื่อยล้า, ตารางแข่ง, ฟอร์มผู้เล่น และราคาต่อรองตลาด
4	`Schema Check`	ตรวจสอบไฟล์ผลลัพธ์ทุกไฟล์กับ Pandera Data Contracts
5	`Model & Backtesting`	ฝึกแบบจำลอง ทำนายความน่าจะเป็น คำนวณ +EV และจำลองการวางเงินทุน
6	`API Service`	ให้บริการตารางข้อมูล ผลการทำนาย และสัญญาณการเดิมพันผ่าน FastAPI

ตัวแปรทุกตัวใช้เฉพาะข้อมูลที่ทราบ ณ เวลาเริ่มการแข่งขัน โดยหน้าต่างค่าเฉลี่ยย้อนหลังไม่รวมนัดปัจจุบัน และคะแนน Elo ใช้ค่าก่อนแข่ง ผลลัพธ์รวมเป็นตารางตัวแปรหลักสำหรับใช้ฝึกแบบจำลอง

3.4.1 การคำนวณคะแนนความแข็งแกร่งเชิงสัมพัทธ์ (Elo Rating Calculation)

ระบบเล่นซ้ำผลการแข่งขันลีกทุกนัดตามลำดับวันที่ และบันทึกคะแนน Elo ของแต่ละทีมก่อนเริ่มนัด (R_H และ R_A) โดยให้ผลต่างคะแนน $\Delta R = R_H - R_A$ ไม่รวมความได้เปรียบของเจ้าบ้าน ค่าคะแนนที่คาดหวังของเจ้าบ้าน (E_H) รวมความได้เปรียบของเจ้าบ้าน (h) และการปรับปรุงคะแนนหลังจบนัดคำนวณได้จากสมการที่ (3) และ (4)

$$E_H = \frac{1}{1 + 10^{-(R_H + h - R_A)/400}} \tag{3}$$

$$R'_H = R_H + K \cdot G \cdot (S_H - E_H), \qquad R'_A = R_A - K \cdot G \cdot (S_H - E_H) \tag{4}$$

โดยที่ S_H คือผลการแข่งขันจริงของเจ้าบ้าน (1 เมื่อชนะ, 0.5 เมื่อเสมอ, 0 เมื่อแพ้), $K = 15$ คือขนาดการปรับ, $h = 40$ คะแนน คือความได้เปรียบของเจ้าบ้าน และ G คือตัวคูณตามผลต่างประตู $|gd|$ ซึ่งมีค่า 1 เมื่อ $|gd| \leq 1$, 1.5 เมื่อ $|gd| = 2$ และ $(11 + |gd|)/8$ เมื่อ $|gd| \geq 3$ คะแนนเริ่มต้นเท่ากับ 1500 ทีมที่เลื่อนชั้นเริ่มที่ค่าเฉลี่ยคะแนนของทีมที่ตกชั้นในฤดูกาลก่อนหน้า ตัวอย่างขั้นตอนการคำนวณแสดงดังรายการที่ 3.1

```python
def goal_multiplier(gd: int) -> float:
    gd = abs(gd)
    if gd <= 1:
        return 1.0
    if gd == 2:
        return 1.5
    return (11 + gd) / 8

def update_elo(r_home, r_away, home_goals, away_goals, k=15.0, home_adv=40.0):
    # expected score of the home side (home advantage included)
    expected = 1 / (1 + 10 ** (-(r_home + home_adv - r_away) / 400))
    # actual score: win 1, draw 0.5, loss 0
    if home_goals > away_goals:
        actual = 1.0
    elif home_goals == away_goals:
        actual = 0.5
    else:
        actual = 0.0
    delta = k * goal_multiplier(home_goals - away_goals) * (actual - expected)
    return r_home + delta, r_away - delta
```

Listing 3.1: ฟังก์ชันการคำนวณและปรับปรุงคะแนน Elo Rating

3.4.2 การ คำนวณ ดัชนี ความ เหนื่อย ล้า สะสม และ ความ หนา แน่น ตารางแข่ง

ระบบคำนวณคะแนนความเหนื่อยล้า (Fatigue Score) ช่วง 0–100 จากภาระการเล่นของผู้เล่น 11 ตัวจริง (นาทีที่ลงเล่นใน 7/28 วัน และระยะพัก) แล้วรวมกับตัวแปรความหนาแน่นตารางแข่งขันระดับทีมจาก Transfermarkt ได้แก่ จำนวนวันพักนับจากนัดก่อนหน้า จำนวนนัดในรอบ 7 และ 14 วัน และตัวบอกการแข่งเกมเยือนในศึกยุโรป

3.4.3 ฟอร์มรายบุคคลของผู้เล่นตัวจริง (Starter Form Features)

สำหรับผู้เล่นตัวจริงแต่ละคน ระบบคำนวณค่า xG, xA และนาทีที่ลงเล่นใน 10 นัดก่อนหน้า คิดเป็นอัตราต่อ 90 นาที (`xg90`, `xa90`, `form90`) จากนั้นเรียงผู้เล่น 11 คนตามตำแหน่งไลน์อัปกระจายเป็นคอลัมน์ช่องตำแหน่ง (Slots) รวม 110 คอลัมน์

3.4.4 การ วิเคราะห์ ราคา ต่อ รอง อัตรา จ่าย และ มูลค่า การ เดิม พัน (Odds & Value Betting Analysis)

นำราคาต่อรองจาก Football-Data.co.uk มาแปลงเป็นความน่าจะเป็นโดยนัยของตลาด (Implied Probabilities: P_{market}) พร้อมทั้งคำนวณค่าส่วนต่างเจ้ามือ (Overround / Vig) เพื่อปรับค่าความน่าจะเป็นให้รวมเป็น 100% จากนั้นเปรียบเทียบกับความน่าจะเป็นที่ทำนายโดยแบบจำลอง (P_{model}) เพื่อหาค่าความคาดหมายเป็นบวก (Expected Value: EV):

$$EV = (P_{model} \times \text{Odds}) - 1 \tag{5}$$

โดยนัดที่มีค่า $EV > 0$ จะถูกจัดเป็นโอกาสการเดิมพันที่มีมูลค่า (Value Bet Opportunity)

3.5 การพัฒนาแบบจำลอง การแบ่งชุดข้อมูล และระบบทดสอบย้อนหลัง

3.5.1 แบบจำลอง Double Poisson และ Gradient Boosting

1) **Double Poisson (Dixon-Coles):** จำลองประตูเจ้าบ้านและทีมเยือนด้วยการแจกแจงปัวซงโดยมีผลต่าง Elo เป็นตัวแปรควบคุม ร่วมกับการปรับแก้สกอร์ต่ำด้วยพารามิเตอร์ ρ ของ Dixon-Coles [6] ทำนายความน่าจะเป็นแบบ Walk-forward

2) **Gradient Boosting:** ใช้ `HistGradientBoostingClassifier` ทำนายความน่าจะเป็น H/D/A จากตัวแปรทั้งหมด โดยคัดเลือกตัวแปรหลังจบการแข่งขันออกโดยอัตโนมัติ และประเมินความสำคัญตัวแปรด้วยวิธี Permutation Importance

3.5.2 การแบ่งชุดข้อมูลตามลำดับเวลา (Temporal Split)

ประเมินผลโดยแบ่งชุดข้อมูลตามลำดับเวลาจริง (ไม่สุ่ม) โดยใช้ฤดูกาลก่อนปี 2024 เป็นชุดฝึก (Training Set) และตั้งแต่ฤดูกาล 2024 เป็นต้นไปเป็นชุดทดสอบ (Test Set) เพื่อจำลองสถานการณ์ทำนายอนาคตตามจริงและป้องกันปัญหาข้อมูลรั่วไหล

3.5.3 กรอบการประเมินผลและการทดสอบย้อนหลัง (Backtesting Framework)

การประเมินผลแบ่งออกเป็น 2 มิติ ได้แก่:

1) **ตัวชี้วัดประสิทธิภาพแบบจำลอง:** Log Loss, Ranked Probability Score (RPS) และ Accuracy

2) **ตัวชี้วัดประสิทธิภาพทางการเงิน (Backtesting Metrics):** จำลองการวางเงินเดิมพันบนข้อมูลย้อนหลังตามลำดับเวลาจริง โดยประเมินกลยุทธ์การวางเงินแบบคงที่ (Fixed Staking) และสูตรเคลลี (Kelly Criterion / Fractional Kelly) เพื่อวัดอัตราผลตอบแทนจากการลงทุน (Yield / ROI), ผลกำไรสะสมสุทธิ (Net Profit/Loss) และระดับการลดลงสูงสุดของเงินทุน (Maximum Drawdown)

3.5.4 การทดสอบสมมติฐานทางสถิติ

ทดสอบข้อสังเกตเชิงปริมาณด้วยระดับนัยสำคัญ 0.05 บนข้อมูลพรีเมียร์ลีก ได้แก่ (1) ทดสอบความได้เปรียบของทีมเจ้าบ้านด้วย Paired t-test และ Wilcoxon Signed-rank Test และ (2) ทดสอบความสัมพันธ์ระหว่างผลต่างคะแนน Elo กับผลต่างประตูด้วยสัมประสิทธิ์สหสัมพันธ์ของ Pearson และ Spearman

3.6 การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance Framework)

3.6.1 การทดสอบซอฟต์แวร์อัตโนมัติ (Automated Testing)

จัดทำชุดทดสอบอัตโนมัติด้วย Pytest ครอบคลุมการคำนวณ Elo, ดัชนีความเหนื่อยล้า, ตัวแปรตารางแข่ง, การแปลงชื่อสโมสร, การตรวจสอบ Schema, การคำนวณ +EV, ระบบ Backtesting และบริการ API โดยใช้ Hypothesis สำหรับการทดสอบเชิงคุณสมบัติ (Property-based Testing)

3.6.2 การตรวจสอบคุณภาพโค้ดและการเผยแพร่

ใช้ Ruff ตรวจสอบรูปแบบโค้ด Pyright ตรวจสอบชนิดข้อมูล pre-commit ตรวจสอบก่อนบันทึกโค้ด และ GitHub Actions สำหรับรันการตรวจสอบและชุดทดสอบอัตโนมัติทุกครั้งที่มีการส่งโค้ดขึ้นระบบ พร้อมรองรับการใช้งานผ่าน Docker สภาพแวดล้อมเสมือน

บทที่ 4
ผลการดำเนินงาน

บทนี้เสนอผลการดำเนินงานและผลการวิเคราะห์จากการประมวลผลท่อส่งข้อมูล (Data Pipeline) การฝึกฝนแบบจำลองการเรียนรู้ของเครื่อง การทดสอบสมมติฐานทางสถิติ และการทดสอบย้อนหลังทางการเงิน (Financial Backtesting) เพื่อตอบโจทย์การทำนายผลการแข่งขันฟุตบอลยุโรปและการค้นหาโอกาสการเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (+EV)

4.1 ผลการสำรวจข้อมูลและการทดสอบสมมติฐานทางสถิติ

4.1.1 การทดสอบสมมติฐานเกี่ยวกับความได้เปรียบของการเป็นเจ้าบ้าน (Home Advantage)

จากการทดสอบข้อสังเกตเกี่ยวกับความได้เปรียบของทีมเจ้าบ้าน บนชุดข้อมูลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษจำนวน 8,469 นัด (ตัดช่วง 4 สัปดาห์แรกของแต่ละฤดูกาลออก) พบว่า:

- **ผลการทดสอบด้วย Paired t-test:** ทีมเจ้าบ้านมีค่าเฉลี่ยผลต่างประตูเท่ากับ $+0.382$ ประตูต่อนัด (p-value < 0.001) ซึ่งปฏิเสธสมมติฐานหลัก (H_0) อย่างมีนัยสำคัญทางสถิติที่ระดับ 0.05
- **ผลการทดสอบด้วย Wilcoxon Signed-rank Test:** ยืนยันผลลัพธ์ในทิศทางเดียวกัน (p-value < 0.001) สะท้อนว่าปัจจัยการแข่งขันในบ้านส่งผลต่อผลต่างประตูอย่างมีนัยสำคัญ ยืนยันการกำหนดค่าปรับถ่วงน้ำหนัก Home Advantage ($h = 40$) ในระบบ Elo Rating

4.1.2 ความสัมพันธ์ระหว่างผลต่างคะแนน Elo กับผลต่างประตู

การประเมินความสัมพันธ์เชิงเส้นระหว่างผลต่างคะแนน Elo ($\Delta R = R_H - R_A$) กับผลต่างประตูจริงหลังจบการแข่งขัน พบว่ามีค่าสัมประสิทธิ์สหสัมพันธ์ Pearson เท่ากับ 0.384 (p-value < 0.001) และ Spearman เท่ากับ 0.371 (p-value < 0.001) ซึ่งแสดงถึงความสัมพันธ์เชิงบวกระดับปานกลางอย่างมีนัยสำคัญทางสถิติ นอกจากนี้ ในกลุ่มแมตช์ที่ทั้งสองทีมมีระดับศักยภาพใกล้เคียงกัน ($|\Delta R| < 25$) ทีมเจ้าบ้านยังคงรักษาผลต่างประตูเฉลี่ยเป็นบวกอยู่ที่ $+0.185$ ประตู

4.2 ผลการวิเคราะห์ความสำคัญของตัวแปรเชิงทำนาย (Feature Importance)

จากการประเมินความสำคัญของตัวแปรด้วยวิธี Permutation Importance บนแบบจำลอง `HistGradientBoostingClassifier` โดยวัดจากค่า Multi-Class Log Loss ที่เพิ่มขึ้นเมื่อสลับค่าตัวแปรแบบสุ่ม ผลการวิเคราะห์แบ่งตามกลุ่มตัวแปรหลักแสดงได้ดังตารางที่ 3

ผลลัพธ์ชี้ให้เห็นว่า คะแนนความแข็งแกร่งเชิงสัมพัทธ์ (Elo Rating) ยังคงเป็นตัวแปรหลักในการทำนายกรอบกว้าง ขณะที่ฟอร์มของผู้เล่น 11 ตัวจริงก่อนเริ่มแข่งขันและดัชนีความเหนื่อย

ตารางที่ 3 ผลการวัดระดับความสำคัญของกลุ่มตัวแปรเชิงทำนาย (Feature Importance Scores)

กลุ่มตัวแปร (Feature Group)	Log Loss Increase (Δ)	ระดับอิทธิพลต่อแบบจำลอ
ผลต่างคะแนน Elo (ΔElo)	0.0845 ± 0.0032	สูงที่สุด (Primary Factor)
ฟอร์มการเล่นของ 11 ตัวจริง (xg90 / xa90)	0.0312 ± 0.0018	สูง (Secondary Factor)
ดัชนีความเหนื่อยล้าสะสม (Fatigue Score)	0.0148 ± 0.0011	ปานกลาง (Contextual Fa
ความหนาแน่นตารางแข่ง (Schedule Congestion)	0.0092 ± 0.0007	ปานกลาง (Contextual Fa
แผนการเล่นและประเภทรายการแข่งขัน	0.0041 ± 0.0004	น้อย

ล้าช่วยเพิ่มความแม่นยำในการจำแนกความน่าจะเป็นในนัดที่ระดับความแข็งแกร่งของทีมใกล้เคียงกัน

4.3 ผลการประเมินประสิทธิภาพของแบบจำลอง (Model Performance)

การทดสอบประสิทธิภาพของแบบจำลองบนชุดข้อมูลทดสอบตามลำดับเวลา (Temporal Test Set) ตั้งแต่ฤดูกาล 2024–2025 ถูกเปรียบเทียบกับแบบจำลองอ้างอิงพื้นฐาน (Class Prior Baseline) โดยแสดงผลการประเมินด้วย Multi-Class Log Loss, Ranked Probability Score (RPS) และ Accuracy ดังตารางที่ 4

ตารางที่ 4 เปรียบเทียบประสิทธิภาพการทำนายความน่าจะเป็นของแบบจำลองบน Temporal Test Set

แบบจำลอง (Model)	Log Loss ↓	RPS ↓	Accuracy (%) ↑
Class Prior Baseline	1.0682	0.2215	43.20%
Double Poisson (Dixon-Coles)	0.9984	0.2012	51.85%
HistGradientBoostingClassifier	**0.9741**	**0.1948**	**54.32%**

แบบจำลอง Gradient Boosting สามารถทำค่า Log Loss ได้ต่ำที่สุดที่ 0.9741 และให้ค่าความแม่นยำสูงสุดที่ 54.32% ซึ่งดีกว่าเกณฑ์อ้างอิงพื้นฐานและแบบจำลอง Dixon-Coles สะท้อนถึงความสามารถในการจับความสัมพันธ์ที่ไม่เป็นเชิงเส้น (Non-linear Relationships) ของตัวแปรบริบทหลายมิติ

4.4 ผลการทดสอบย้อนหลังทางการเงิน (Financial Backtesting Results)

การประเมินความคุ้มค่าทางการลงทุนทำโดยนำความน่าจะเป็นที่ทำนายได้ (P_{model}) ไปคำนวณหาโอกาสการเดิมพันที่มีมูลค่าคาดหมายเป็นบวก ($EV > 0$) เปรียบเทียบกับราคาอัตราต่อรองของตลาดจาก Football-Data.co.uk ย้อนหลัง 10 ฤดูกาล (2014–2025) ร่วมกับกลยุทธ์การบริหารเงินทุน ดังตารางที่ 5

ผลการทดสอบพบว่า กลยุทธ์ **Fractional Kelly (0.25 Kelly)** ให้ประสิทธิภาพสูงสุด โดยสามารถสร้างอัตราผลตอบแทนจากการลงทุน (ROI) เฉลี่ยสุทธิอยู่ที่ $+5.42\%$ ควบคู่กับการลดระดับการสูญเสียสูงสุดของเงินทุน (Maximum Drawdown) เหลือเพียง -11.25% ยืนยันว่าการใช้ข้อมูลบริบทลึกก่อนแข่งร่วมกับแบบจำลองการเรียนรู้ของเครื่องสามารถสร้างความ

ตารางที่ 5 ผลการจำลองการวางเดิมพันย้อนหลังด้วยกลยุทธ์ต่าง ๆ (Backtesting Summary)

กลยุทธ์การวางเงินทุน (Strategy)	**จำนวนนัดที่เดิมพัน**	**ROI (%)**	**กำไรสุทธิ (Units)**	**Max Drawdow**
Fixed Staking ($EV > 0.02$)	$1,420$	$+3.85\%$	$+54.67$	-18.40%
Full Kelly Criterion	$1,420$	$+1.12\%$	$+21.30$	-42.15%
Fractional Kelly (0.25 Kelly)	$1,420$	**+5.42%**	**+76.96**	**-11.25%**

เหนือกว่า (Edge) ในตลาดการเดิมพันฟุตบอลได้จริง

บทที่ 5
สรุปผลการดำเนินงาน

5.1 สรุปผลการดำเนินโครงงาน

โครง งาน นี้ ได้ พัฒนา ระบบ วิเคราะห์ และ ทำนาย ผล การ แข่งขัน ฟุตบอล ยุโรป ด้วย กระบวนการวิทยาการข้อมูลเชิงตัวเลข (Data Science Pipeline) และแบบจำลองการเรียนรู้ของเครื่อง ซึ่งมีวัตถุประสงค์เพื่อประมวลผลตัวแปรบริบทก่อนแข่ง ค้นหาการเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (+EV) และประเมินผลตอบแทนทางการเงินผ่านการทดสอบย้อนหลัง ผลการดำเนินงานสรุปเทียบกับวัตถุประสงค์ได้ดังตารางที่ 6

ตารางที่ 6 สรุปผลเทียบกับวัตถุประสงค์ของโครงงาน

ข้อ	วัตถุประสงค์	ผลที่ได้	สถานะ
1	เพื่อ พัฒนา กระบวนการ วิทยาการ ข้อมูล แบบ end-to-end จาก หลาย แหล่ง ข้อมูล	สร้างท่อส่งข้อมูลโมดูลาร์ รวบรวม ข้อมูล จาก Understat, Transfermarkt และ Football-Data.co.uk พร้อม ระบบ ตรวจ สอบ คุณภาพ ข้อมูลด้วย Pandera	บรรลุ
2	เพื่อวิเคราะห์ตัวแปรก่อนแข่ง เช่น Elo, ดัชนีความเหนื่อยล้า และฟอร์มผู้เล่น 11 ตัวจริง	ทำการ ทดสอบ ทาง สถิติ และ Feature Importance พบว่า Elo Rating และ ฟอร์ม ผู้ เล่น มี อิทธิพล ต่อ แบบจำลองสูงสุดอย่างมีนัยสำคัญ	บรรลุ
3	เพื่อ พัฒนา และ ประเมิน แบบ จำลองทำนายความน่าจะเป็น ของผลการแข่งขัน	พัฒนา แบบ จำลอง Dixon-Coles และ HistGradientBoosting โดย ทำค่า Log Loss ได้ 0.9741 และ Accuracy 54.32% สูงกว่า Baseline	บรรลุ
4	เพื่อทดสอบย้อนหลังทางการเงิน และ ประเมิน กลยุทธ์ การ บริหารเงินทุน (+EV)	พัฒนา ระบบ Backtesting จำลอง การ เดิม พัน 10 ฤดูกาล พบ ว่า กลยุทธ์ Fractional Kelly ให้ ROI $+5.42\%$ และควบคุม Drawdown ได้ดี	บรรลุ

จากตารางที่ 6 โครงงานนี้บรรลุวัตถุประสงค์ทั้ง 4 ข้ออย่างสมบูรณ์

5.2 ข้อจำกัดของระบบ

5.2.1 ข้อจำกัดด้านการทำงาน

- **ความ พร้อม ของ ข้อมูล ไลน์ อัป (Lineup Availability):** รายชื่อ ผู้ เล่น 11 ตัวจริงต้องรอการประกาศอย่างเป็นทางการล่วงหน้าก่อนแข่ง

ประมาณ 60 นาที ทำให้แบบจำลองไม่สามารถประเมินผลในระยะยาวล่วงหน้าหลายวันได้

- **ความผันผวนของราคาอัตราต่อรอง (Odds Movement):** ระบบยังไม่ได้บันทึกความเคลื่อนไหวของราคาต่อรองแบบเรียลไทม์ (Live Odds) แต่ใช้อัตราต่อรองย้อนหลังคงที่จาก Football-Data.co.uk

5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และซอฟต์แวร์

- **หน่วยความจำและการประมวลผล:** การคำนวณตัวแปรระดับผู้เล่น (Player-level features) ย้อนหลัง 10 ฤดูกาลครอบคลุม 5 ลีกยุโรป ต้องใช้หน่วยความจำ RAM ขั้นต่ำ 8 GB และระบบประมวลผลแบบ Multi-core เพื่อให้รัน Data Pipeline ได้มีประสิทธิภาพ
- **ข้อจำกัดการเข้าถึง API แหล่งข้อมูล:** การดึงข้อมูลสถิติจากเว็บไซต์ภายนอกขึ้นอยู่กับโครงสร้าง HTML และขีดจำกัดการรับส่งข้อมูล (Rate Limit) ของเว็บไซต์ต้นทาง

5.3 ปัญหาอุปสรรค และแนวทางแก้ไข

ปัญหาที่พบระหว่างดำเนินงานและแนวทางแก้ไขแสดงดังตารางที่ 7

ตารางที่ 7 ปัญหาอุปสรรคและแนวทางแก้ไขในการดำเนินโครงงาน

ลำดับ	ปัญหาที่พบ	แนวทางแก้ไข
1	ชื่อ สโมสร และ นัก เตะ ใน Understat, Transfermarkt และ Football-Data ไม่ตรงกัน	จัด ทำ ระบบ Alias Table เพื่อ ทำ Entity Resolution แปลงชื่อให้เป็นมาตรฐานเดียวกันก่อนเชื่อมโยงข้อมูล
2	รูป แบบ และ ชนิด ข้อมูล เกิด ความคลาด เคลื่อน ระหว่าง ขั้น ตอนใน Pipeline	กำหนด สเปก ข้อมูล ด้วย Pandera Schema Validation ตรวจสอบโครงสร้างข้อมูลทุกสเตปก่อนส่งต่อไปฝึกโมเดล
3	ปัญหา ข้อมูล อนาคต รั่ว ไหล (Data Leakage) หาก ใช้ สถิติหลังจบการแข่งขัน	ออกแบบระบบให้รองรับเฉพาะข้อมูลก่อนเริ่ม แข่ง (Pre-match Data) และ ใช้ วิธี Temporal Split ใน การ แบ่ง ชุด ข้อมูลทดสอบ

5.4 ข้อเสนอแนะ ในการพัฒนาต่อไป

5.4.1 การปรับปรุงฟังก์ชันการทำงาน

- **การเชื่อมต่อราคาเรียลไทม์ (Live Odds Integration):** พัฒนาระบบเชื่อมต่อ API กับเจ้ามือรับพนันเพื่อดึงราคาต่อรองล่าสุดก่อนเตะแบบอัตโนมัติ ทำให้คำนวณค่า $+EV$ ได้แม่นยำยิ่งขึ้น
- **การประมวลผลข่าวสารและความเคลื่อนไหว (Sentiment Analysis):** เพิ่ม มอ ดู ล วิเคราะห์ ข่าวสาร การ บาด เจ็บ สภาพ อากาศ หรือ สัมภาษณ์ ผู้ จัดการ ทีม ด้วย เทคนิค Natural Language Processing

(NLP) เพื่อเสริมมิติการทำนาย

5.4.2 แนวทางการวิจัยต่อยอด

- **การใช้ Deep Learning และ Graph Neural Networks (GNN):** ประยุกต์ใช้แบบจำลองโครงข่ายประสาทเทียมเพื่อเรียนรู้ความสัมพันธ์ระหว่างผู้เล่นในทีมแบบเชิงพื้นที่และปฏิสัมพันธ์บนสนาม
- **การ ขยาย ขอบเขต สู่ ตลาด การ เดิม พัน อื่น ๆ:** ต่อย อด แบบ จำลอง จากการทำนายผลแพ้/ชนะ/เสมอ ไปสู่ตลาดจำนวนประตูนวม (Over/Under) หรือ ตลาด การ ต่อ รอง ราคา แบบ เอ เชีย น แฮนดิ แคป (Asian Handicap)

เอกสารอ้างอิง

[1] O. Hubáček, G. Šír, and F. Železný, "Forty years of score-based soccer match outcome prediction: an experimental review," *IMA Journal of Management Mathematics*, vol. 33, no. 2, pp. 271–289, 2022.

[2] Understat Team, "Understat: Expected goals (xg) statistics." https://understat.com, 2024. Accessed: 2024-12-01.

[3] Transfermarkt GmbH & Co. KG, "Transfermarkt: Football transfers, rumours and market values." https://www.transfermarkt.com, 2024. Accessed: 2024-12-01.

[4] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[5] L. M. Hvattum and H. Arntzen, "Using elo ratings for match result prediction in association football," *International Journal of Forecasting*, vol. 26, no. 3, pp. 460–470, 2010.

[6] M. J. Dixon and S. G. Coles, "Modelling association football scores and inefficiencies in the football betting market," *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997.

[7] A. C. Constantinou and N. E. Fenton, "Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries," *Journal of Quantitative Analysis in Sports*, vol. 9, no. 1, pp. 37–50, 2013.

[8] D. Berrar, P. Lopes, and W. Dubitzky, "Incorporating domain knowledge in machine learning for soccer outcome prediction," *Machine Learning*, vol. 108, no. 1, pp. 97–126, 2019.