

เอกสารโครงงานฉบับสมบูรณ์

การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลลีกยุโรปด้วย
กระบวนการวิทยาการข้อมูลเพื่อการประเมินมูลค่าการเดิมพัน

European Football Match Outcome Prediction and
Betting Market Analysis Using Data Science

โดย
683380667-9 นายภาณุพงศ์ ภูสำรอง
683380653-0 นายชินภัทร บัวผาย

อาจารย์ที่ปรึกษา
อ.ดร.ธนพล ตั้งชูพงศ์

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา
วิชา CP352101 วิทยาการข้อมูลเบื้องต้น
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
วิทยาลัยการคอมพิวเตอร์
มหาวิทยาลัยขอนแก่น
ปีการศึกษา 2569

ภาณุพงศ์ ภูสำรอง และ ชินภัทร บัวผาย. 2569. **การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลลีกยุโรปด้วยกระบวนการวิทยาการข้อมูลเพื่อการประเมินมูลค่าการเดิมพัน.** โครงงานคอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
อาจารย์ที่ปรึกษา: อ.ดร.ธนพล ตั้งชูพงศ์

บทคัดย่อ

โครงงานนี้มีวัตถุประสงค์เพื่อประยุกต์ใช้กระบวนการวิทยาการข้อมูลแบบครบวงจรในการวิเคราะห์ปัจจัยก่อนการแข่งขันฟุตบอลลีกยุโรป พัฒนาแบบจำลองทำนายผลการแข่งขัน 3 ทางเลือก (เจ้าบ้านชนะ เสมอ และทีมเยือนชนะ) และตอบคำถามว่าผู้เดิมพันที่ใช้ข้อมูลสาธารณะสามารถเอาชนะตลาดเดิมพันได้หรือไม่

การดำเนินงานได้รวบรวมข้อมูล 5 ลีกใหญ่ของยุโรป ฤดูกาล 2014–2015 ถึง 2025–2026 จาก Understat, Transfermarkt และ Football-Data.co.uk ผ่านท่อส่งข้อมูลเชิงโมดูลาร์ที่ตรวจสอบโครงสร้างข้อมูลด้วย Pandera แล้วสร้างตัวแปรก่อนแข่ง ได้แก่ คะแนน Elo ดัชนีความเหนื่อยล้า ความหนาแน่นของตารางแข่ง และฟอร์มผู้เล่น 11 ตัวจริง คัดเลือกตัวแปรแบบเดินหน้า และเปรียบเทียบแบบจำลอง Logistic Regression, Gradient-boosted Trees และแบบจำลองจำนวนประตู Poisson โดยทำนายทุกฤดูกาลจากฤดูกาลก่อนหน้าเท่านั้น จากนั้นเปรียบเทียบกับราคาของ Pinnacle ทดสอบกลยุทธ์การเดิมพัน 18 กลยุทธ์ที่ลงทะเบียนไว้ล่วงหน้าพร้อมการปรับแก้แบบ Benjamini–Hochberg และจำลองแผนการวางเงิน 5 แบบ

ผลการศึกษาพบว่า จากข้อมูลพรีเมียร์ลีกฤดูกาล 2000–2001 ถึง 2024–2025 ความได้เปรียบของเจ้าบ้าน ($+0.362$ ประตูต่อนัด) และความสัมพันธ์ของคะแนน Elo กับผลต่างประตู ($r = 0.441$) มีนัยสำคัญทางสถิติ ตัวแปรที่ช่วยทำนายได้คือคะแนน Elo และฟอร์มผู้เล่นตัวจริง ส่วนดัชนีความเหนื่อยล้าไม่ช่วยเมื่อมีคะแนน Elo อยู่แล้ว Logistic Regression ให้ผลดีที่สุด (Log Loss 0.9848, Accuracy 52.41%) แต่ยังด้อยกว่าราคาเจ้ามือ (0.9695) การวางเดิมพันตามแบบจำลองขาดทุนประมาณร้อยละ 4–5.5 และไม่มีกลยุทธ์ใดใน 252 กรณีที่มีกำไรอย่างมีนัยสำคัญ ความได้เปรียบตามคาดหมายมีเพียงการเลือกราคาดีที่สุดระหว่างเจ้ามือ (Line Shopping) ซึ่งต้องใช้เวลาหลายฤดูกาลกว่าจะเห็นผล และเจ้ามือที่ให้ราคานั้นปิดบัญชีผู้ชนะ ส่วน Martingale และ Kelly เต็มทำให้เงินทุนหมดได้ง่าย ผลเหล่านี้ชี้ว่าตลาดเดิมพันของ 5 ลีกใหญ่มีประสิทธิภาพสูง และท่อส่งข้อมูลที่สร้างซ้ำได้นี้ใช้เป็นแนวทางประเมินกลยุทธ์การเดิมพันกีฬาอย่างเป็นระบบได้

คำสำคัญ: วิทยาการข้อมูล, การทำนายผลการแข่งขันฟุตบอล, ลีกฟุตบอลยุโรป, การเรียนรู้ของเครื่อง, อัตราต่อรอง, การทดสอบย้อนหลัง

Panupong Phoosamrong and Chinnapat Buaphai. 2026. **European Football Match Outcome Prediction and Betting Market Analysis Using Data Science.** Computer Project, Bachelor of Science, Program in Computer Science, College of Computing, Khon Kaen University.
Project Advisor: Lect. Thanapon Tangchoopong, Ph.D.

ABSTRACT

This project applied an end-to-end data science process to pre-match factors in European football, built models that predict three-way match outcomes (home win, draw, away win), and asked whether a bettor using public data can beat the betting market.

Match data for the five major European leagues from 2014–2015 to 2025–2026 was collected from Understat, Transfermarkt and Football-Data.co.uk through a modular pipeline validated with Pandera schemas. Pre-match features were built, including Elo ratings, fatigue indices, schedule congestion and the form of the eleven starters, and selected by forward selection. Logistic regression, gradient-boosted trees and a Poisson goals model were compared, with every season predicted only from the seasons before it. The forecasts were compared with Pinnacle's prices, 18 betting strategies registered before any was run were tested with a Benjamini–Hochberg correction, and five staking plans were simulated.

On Premier League matches from 2000–2001 to 2024–2025, home advantage (+0.362 goals per game) and the link between Elo difference and goal difference ($r = 0.441$) are statistically significant. Elo and the starters' form carry the predictive signal; fatigue adds nothing once Elo is known. Logistic regression performs best (log loss 0.9848, accuracy 52.41%) but remains behind the bookmaker's prices (0.9695). Betting on the model's positive expected value picks loses 4 to 5.5 percent, and none of the 252 strategy-by-league cells is significant after correction. The only expected edge comes from taking the best price across bookmakers (line shopping), which takes many seasons to show as profit and is offered by bookmakers that close winning accounts. Martingale and full Kelly staking ruin the bankroll easily. The results indicate that the betting markets of the five major leagues are highly efficient, and the reproducible pipeline provides a framework for evaluating sports betting strategies systematically.

Keywords: Data Science, Football Match Outcome Prediction, European Football Leagues, Machine Learning, Betting Odds, Backtesting

กิตติกรรมประกาศ

โครงงานฉบับนี้สำเร็จลุล่วงไปได้ด้วยดีด้วยความกรุณาอย่างยิ่งจาก อ.ดร.ธนพล ตั้งชูพงศ์ อาจารย์ที่ปรึกษาโครงงาน ที่ได้ให้คำแนะนำ แนวคิด และข้อเสนอแนะอันมีค่ายิ่ง ตลอดจนคอยตรวจแก้ไขข้อบกพร่องและให้กำลังใจแก่ผู้จัดทำมาโดยตลอด ผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ โอกาสนี้

ขอกราบขอบพระคุณ คณาจารย์ประจำสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น ทุกท่าน ที่ได้ประสิทธิ์ประสาทวิชาความรู้และถ่ายทอดประสบการณ์ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงงานฉบับนี้

ขอบคุณเพื่อนร่วมชั้นเรียนและผู้ที่มีส่วนเกี่ยวข้องทุกท่าน ที่คอยให้ความช่วยเหลือแนะนำ และแลกเปลี่ยนความคิดเห็นตลอดช่วงเวลาของการดำเนินงาน

ท้ายที่สุดนี้ ผู้จัดทำขอกราบขอบพระคุณบิดา มารดา และสมาชิกในครอบครัวทุกท่าน สำหรับความรัก การสนับสนุน และกำลังใจอันยิ่งใหญ่ที่เป็นแรงผลักดันสำคัญให้การศึกษานี้ประสบความสำเร็จ

ผู้จัดทำ
ภาณุพงศ์ ภูสำรอง
ชินภัทร บัวผาย

สารบัญ

บทคัดย่อ ก

ABSTRACT ข

กิตติกรรมประกาศ ค

สารบัญ ง

สารบัญภาพ ช

สารบัญตาราง ซ

1 บทนำ 1

1.1 ความเป็นมาและความสำคัญของปัญหา 1
1.2 วัตถุประสงค์ 1
1.3 ขอบเขตและข้อจำกัดของโครงงาน 2
1.3.1 ขอบเขตของโครงงาน 2
1.3.2 ข้อจำกัดของโครงงาน 3
1.4 ประโยชน์ที่คาดว่าจะได้รับ 4

2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง 5

2.1 ทฤษฎีที่เกี่ยวข้อง 5
2.1.1 กระบวนการ วิทยาการ ข้อมูล และ การ จัด ทำ ท่อ ส่ง ข้อมูล (Data Science & Pipeline Process) 5
2.1.2 ระบบวัดระดับความแข็งแกร่ง (Elo Rating System) 6
2.1.3 ค่าความคาดหวังในการทำประตู (Expected Goals: xG) . . 6
2.1.4 ดัชนีความเหนื่อยล้าและความหนาแน่นของตารางแข่ง (Fatigue Metric & Schedule Congestion) 7
2.1.5 อัตราต่อรองของเจ้ามือรับพนันและการเดิมพันที่มีมูลค่า (Betting Odds & Value Betting) 8
2.1.6 กลยุทธ์การบริหารเงินทุนและการทดสอบย้อนหลัง (Staking Strategies & Backtesting) 8
2.1.7 การ จับ คู่ และ แปลง ชื่อ เอ นทิ ตี ให้ เป็น มาตรฐาน (Entity Resolution) 9
2.1.8 แบบจำลองทำนายผลการแข่งขัน 9
2.2 งานวิจัยที่เกี่ยวข้อง 10
2.2.1 การทำนายผลฟุตบอลและการประเมินประสิทธิภาพเทียบกับตลาดเดิมพัน 10

2.2.2 การใช้ Machine Learning ร่วมกับสถิติเชิงลึก และกลยุทธ์การเอาชนะตลาด 10
2.2.3 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง 11
2.3 เครื่องมือและเทคโนโลยีที่ใช้ 11
2.3.1 ภาษา Python และไลบรารีสำหรับการประมวลผลข้อมูล . . 11
2.3.2 สภาพแวดล้อมและการประกันคุณภาพซอฟต์แวร์ (Development Environment & Quality Control) 11

3 วิธีการดำเนินโครงงาน 13
3.1 การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน 13
3.2 การเก็บรวบรวมข้อมูล (Data Collection) 14
3.3 การทำความสะอาดข้อมูลและการตรวจสอบความถูกต้อง 14
3.3.1 ขั้นตอนการทำความสะอาด (Data Cleaning) 14
3.3.2 การจับคู่และแปลงชื่อเอนทิตีให้เป็นมาตรฐาน (Entity Resolution) 15
3.3.3 การตรวจสอบความถูกต้องของข้อตกลงข้อมูล (Data Schema Validation) 15
3.4 การวิศวกรรมฟีเจอร์และการวิเคราะห์ตลาดเดิมพัน 15
3.4.1 การคำนวณคะแนนความแข็งแกร่งเชิงสัมพัทธ์ (Elo Rating Calculation) 16
3.4.2 การคำนวณดัชนีความเหนื่อยล้าสะสมและความหนาแน่นตารางแข่ง 17
3.4.3 ฟอร์มรายบุคคลของผู้เล่นตัวจริง (Starter Form Features) 17
3.4.4 การวิเคราะห์ราคาต่อรองอัตราจ่ายและมูลค่าการเดิมพัน (Odds & Value Betting Analysis) 17
3.5 การพัฒนาแบบจำลอง การเปรียบเทียบกับตลาด และระบบทดสอบย้อนหลัง 18
3.5.1 การคัดเลือกตัวแปร (Feature Selection) 18
3.5.2 แบบจำลองทำนายผลการแข่งขัน 18
3.5.3 การแบ่งชุดข้อมูลตามลำดับเวลา (Temporal Split) 18
3.5.4 การเปรียบเทียบกับตลาดเดิมพัน (Market Test) 19
3.5.5 กรอบการทดสอบย้อนหลังและชุดกลยุทธ์ (Backtesting Framework) 19
3.5.6 การทดสอบสมมติฐานทางสถิติ 20
3.6 การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance Framework) 20
3.6.1 การทดสอบซอฟต์แวร์อัตโนมัติ (Automated Testing) . . . 20
3.6.2 การตรวจสอบคุณภาพโค้ดและการเผยแพร่ 20

4 ผลการดำเนินงาน 21
4.1 ผลการทดสอบสมมติฐานทางสถิติ 21
4.1.1 ความได้เปรียบของการเป็นเจ้าบ้าน (Home Advantage) . . 21
4.1.2 ความสัมพันธ์ระหว่างผลต่างคะแนน Elo กับผลต่างประตู . . 21
4.2 ผลการสำรวจและคัดเลือกตัวแปร 22

4.2.1 สัดส่วนผลการแข่งขันในแต่ละฤดูกาล 22
4.2.2 ความสัมพันธ์ของตัวแปรแต่ละตัวกับผลการแข่งขัน 22
4.2.3 ความซ้ำซ้อนระหว่างตัวแปร 23
4.2.4 การคัดเลือกตัวแปรแบบเดินหน้า (Forward Selection) . . 25
4.3 ผลการประเมินประสิทธิภาพของแบบจำลอง 25
4.3.1 เส้นโค้งการเรียนรู้ (Learning Curve) 25
4.3.2 เปรียบเทียบตัวชี้วัดหลายมิติ 26
4.4 ผลการทดสอบย้อนหลังของแบบจำลอง (Model Backtest) 27
4.5 ผลการเปรียบเทียบกับตลาดเดิมพัน 28
4.6 ผลการทดสอบชุดกลยุทธ์การเดิมพัน 29
4.7 ผลของกลยุทธ์การบริหารเงินทุน (Staking) 31
4.8 ความเป็นไปได้ในการนำความได้เปรียบไปใช้จริง 32
4.9 สรุปผลการวิเคราะห์ 33

5 สรุปผลการดำเนินงาน **34**
5.1 สรุปผลการดำเนินโครงงาน 34
5.1.1 บทเรียนที่ได้จากโครงงาน 34
5.2 ข้อจำกัดของระบบ 36
5.2.1 ข้อจำกัดด้านการทำงาน 36
5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และซอฟต์แวร์ 36
5.3 ปัญหาอุปสรรค และแนวทางแก้ไข 36
5.4 ข้อเสนอแนะในการพัฒนาต่อไป 37
5.4.1 การปรับปรุงฟังก์ชันการทำงาน 37
5.4.2 แนวทางการวิจัยต่อยอด 37

เอกสารอ้างอิง **38**

สารบัญภาพ

ภาพที่ 1 คะแนน Elo ก่อนแข่งของ 4 สโมสรพรีเมียร์ลีกที่คำนวณในโครงงานนี้ (เส้นประคือคะแนนเริ่มต้น 1500 ช่วงที่เส้นขาดคือฤดูกาลที่สโมสรไม่ได้อยู่ใน 5 ลีกใหญ่) 6
ภาพที่ 2 ตัวอย่างการประเมินค่าความคาดหวังในการทำประตู (Expected Goals: xG) จากตำแหน่งการยิง 7
ภาพที่ 3 ดัชนีความเหนื่อยล้าเฉลี่ยของผู้เล่นตัวจริงและจำนวนนัดทุกรายการใน 14 วันก่อนแต่ละนัดในลีกของ Liverpool ฤดูกาล 2018–2019 8
ภาพที่ 4 สัดส่วนผล H/D/A ของแต่ละลีกตามฤดูกาล (ชุดฝึก แถบสีเทาคือฤดูกาล 2020–2021) 22
ภาพที่ 5 สัดส่วนผล H/D/A ตามช่วงเดไซล์ของตัวแปรผลต่างก่อนแข่งแต่ละตัว (ชุดฝึก) 23
ภาพที่ 6 เมทริกซ์สหสัมพันธ์ของตัวแปรผลต่างหลัก (16,242 นัด) 24
ภาพที่ 7 Log Loss บนชุดทดสอบเทียบกับจำนวนนัดที่ใช้ฝึกของแบบจำลองทั้ง 4 แบบ 26
ภาพที่ 8 กำไรสะสมจากการวางเดิมพันตามแบบจำลองที่เกณฑ์ EV ต่าง ๆ 28
ภาพที่ 9 กำไรคาดหมายต่อการเดิมพัน ณ ราคาปิด พร้อมช่วงความเชื่อมั่น 95% ของทุกกลยุทธ์ (รวม 5 ลีก) สีน้ำเงินคือกลยุทธ์ที่ช่วงทั้งหมดอยู่เหนือศูนย์ 30

สารบัญตาราง

ตารางที่ 1 การเปรียบเทียบองค์ประกอบของงานวิจัยที่เกี่ยวข้องกับโครงงานนี้ . . . 11
ตารางที่ 2 สถาปัตยกรรมโมดูลการประมวลผลข้อมูลในระบบ (Data Pipeline Modules) . . . 15
ตารางที่ 3 ผลการทดสอบความได้เปรียบของทีมเจ้าบ้าน (พรีเมียร์ลีก 8,469 นัด) . . 21
ตารางที่ 4 Log Loss บนฤดูกาล 2023 ที่ลดลงเมื่อเพิ่มตัวแปรหนึ่งตัวเข้าไปในแบบจำลองที่มีคะแนน Elo อยู่แล้ว . . . 24
ตารางที่ 5 ผลการคัดเลือกกลุ่มตัวแปรแบบเดินหน้า (Walk-forward Log Loss ฤดูกาล 2021–2023) . . . 25
ตารางที่ 6 Log Loss บนชุดทดสอบ (ฤดูกาล 2024 เป็นต้นไป) ตามชุดตัวแปร . . . 25
ตารางที่ 7 ประสิทธิภาพของแบบจำลองบนชุดทดสอบ (ฤดูกาล 2024 เป็นต้นไป) . . 27
ตารางที่ 8 ผลการวางเดิมพันตามแบบจำลองที่เกณฑ์ EV ต่าง ๆ (ฤดูกาล 2017–2025, เดิมพันละ 1 หน่วย) . . . 27
ตารางที่ 9 คะแนนเฉลี่ยของผู้ทำนายแต่ละแบบบนนัดชุดเดียวกัน 17,063 นัด . . . 28
ตารางที่ 10 ผลต่าง Log Loss แบบจับคู่รายนัด (ค่าติดลบหมายถึงผู้ทำนายตัวแรกดีกว่า) 29
ตารางที่ 11 ผลของกลยุทธ์ที่สำคัญ (รวม 5 ลีก ฤดูกาล 2016–2025) . . . 31
ตารางที่ 12 ผลของแผนการวางเงิน: เงินทุนสุดท้ายในประวัติจริง และโอกาสเสียเงินทุนครึ่งหนึ่งในประวัติจำลอง 3 ฤดูกาล . . . 32
ตารางที่ 13 จำนวนฤดูกาลที่ต้องเดิมพันกว่าความได้เปรียบจะปรากฏเป็นกำไร (5 ลีก) 33
ตารางที่ 14 สรุปผลเทียบกับวัตถุประสงค์ของโครงงาน . . . 35
ตารางที่ 15 ปัญหาอุปสรรคและแนวทางแก้ไขในการดำเนินโครงงาน . . . 37

บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ปัจจุบัน ตลาดการเดิมพันกีฬาฟุตบอลถือเป็นตลาดการเงินทางเลือกที่มีมูลค่ามหาศาลทั่วโลก โดยเจ้ามือรับพนัน (Bookmakers) ได้ประมวลผลสถิติเชิงลึกร่วมกับแบบจำลองเชิงสถิติขั้นสูงเพื่อกำหนดราคาอัตราต่อรอง (Odds) ซึ่งสะท้อนถึงความน่าจะเป็นของผลการแข่งขัน อย่างไรก็ตาม ราคาต่อรองดังกล่าวมักถูกบวกส่วนต่างกำไรของเจ้ามือ (Overround / Vig) และมีการเปลี่ยนแปลงตามกระแสการเดิมพันของตลาด ส่งผลให้นักเดิมพันส่วนใหญ่ที่ตัดสินใจโดยใช้อารมณ์หรือสถิติพื้นฐานไม่สามารถสร้างผลตอบแทนที่ยั่งยืนได้ในระยะยาว

การพัฒนาแบบจำลองการทำนายผลการแข่งขันฟุตบอลยุโรป (ฤดูกาล 2014–2015 ถึง 2025–2026) ด้วยกระบวนการวิทยาการข้อมูล (Data Science Process) และการเรียนรู้ของเครื่อง (Machine Learning) จึงเข้ามามีบทบาทสำคัญในการประเมิน **ความน่าจะเป็นที่แท้จริง (True Probabilities)** ของผลการแข่งขัน 3 ทางเลือก ได้แก่ เจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A) เพื่อนำไปเปรียบเทียบกับความน่าจะเป็นที่แฝงอยู่ในราคาต่อรองของตลาด (Implied Probabilities) สำหรับค้นหาโอกาสการเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (Value Betting / Positive Expected Value: +EV)

อย่างไรก็ตาม การสร้างแบบจำลองเพื่อประเมินศักยภาพการแข่งขันให้เหนือกว่าราคาตลาดมีความท้าทายสูงมาก เนื่องจากงานวิจัยในอดีต [1] ชี้ว่าแบบจำลองที่พึ่งพาเพียงสถิติผลย้อนหลังมักมีความแม่นยำจำกัด โครงงานนี้จึงมุ่งแก้ปัญหาดังกล่าวด้วยการบูรณาการ **ข้อมูลบริบทเชิงลึกก่อนการแข่งขัน (Pre-match Contextual Features)** ครอบคลุม 5 ลีกใหญ่ของยุโรป ได้แก่ คะแนนความแข็งแกร่ง Elo Rating, ดัชนีความเหนื่อยล้าสะสมของผู้เล่นตัวจริง, ความหนาแน่นของตารางแข่งขัน (รวมถึงฟุตบอลถ้วยและรายการยุโรป) และฟอร์มรายบุคคลของผู้เล่น 11 ตัวจริง (เช่น xG และ xA ต่อ 90 นาที) เพื่อนำมาสร้างแบบจำลองการทำนาย แล้วนำความน่าจะเป็นที่ได้ไปเข้ากลยุทธ์การจัดสรรเงินทุน (Staking Strategies) เช่น Kelly Criterion และ Fixed Staking พร้อมทดสอบย้อนหลัง (Backtesting) เพื่อวัดผลตอบแทนการลงทุน (ROI) ในสถานการณ์ที่สมจริง

1.2 วัตถุประสงค์

1) เพื่อ ศึกษา และ พัฒนา กระบวนการ วิทยาการ ข้อมูล อย่าง ครบ วงจร ตั้งแต่ การรวบรวมข้อมูลหลายแหล่ง (สถิติการแข่งขัน, แผนการเล่น และราคาต่อรอง) การทำความสะอาดข้อมูล ไปจนถึงการพัฒนาแบบจำลองทำนายผลลัพธ์การแข่งขัน

2) เพื่อ สร้าง และ วิเคราะห์ ตัวแปร ก่อน การ แข่งขัน (Pre-match Features) ได้แก่ คะแนน Elo, ดัชนีความเหนื่อยล้า, ความหนาแน่นของตารางแข่งขัน และฟอร์มผู้เล่นตัวจริง 11 คนแรก ที่มีผลต่อโอกาสชนะและความคุ้มค่าในการเดิมพัน

3) เพื่อพัฒนาระบบคำนวณและเปรียบเทียบความน่าจะเป็นของแบบจำลองกับราคา

อัตราต่อรองของตลาด (Market Odds Analysis) เพื่อค้นหาโอกาสการเดิมพันที่มีมูลค่า (Value Betting)

4) เพื่อประเมินประสิทธิภาพของแบบจำลองและประเมินผลกำไรการลงทุนผ่านระบบทดสอบย้อนหลัง (Backtesting) ด้วยกลยุทธ์การบริหารเงินทุน (Staking Strategies) รูปแบบต่าง ๆ

1.3 ขอบเขตและข้อจำกัดของโครงงาน

1.3.1 ขอบเขตของโครงงาน

1) **ขอบเขตด้านข้อมูลและช่วงเวลา:** ใช้ชุดข้อมูลการแข่งขันฟุตบอลย้อนหลังครอบคลุมฤดูกาล 2014–2015 ถึง 2025–2026 (ฤดูกาลปัจจุบันเท่าที่แข่งไปแล้ว) จากแหล่งข้อมูลสาธารณะ ได้แก่

- *Understat*: รวบรวมสถิติผลการแข่งขัน ค่าความคาดหวังในการทำประตู (xG, xA) และสถิติเชิงลึกรายบุคคลของผู้เล่น [2]
- *Transfermarkt*: รวบรวมปฏิทินการแข่งขันครบทุกรายการ (รวมฟุตบอลถ้วยและรายการยุโรป) และแผนการเล่น (Formation) ของผู้เล่น 11 ตัวจริง [3]
- *Football-Data.co.uk*: รวบรวม ข้อมูล ผล การ แข่งขัน ยิง ประตู และ ราคา อัตรา ต่อ รอง ย้อน หลัง (Historical Betting Odds Data Service) จากเจ้ามือรับพนันหลายแห่งสำหรับใช้ทดสอบแบบจำลองและประเมินผลตอบแทนทางการเงิน

ยกเว้นการทดสอบสมมติฐานทางสถิติ (ความได้เปรียบของเจ้าบ้านและความสัมพันธ์ของคะแนน Elo กับผลต่างประตู) ซึ่งใช้ผลการแข่งขันพรีเมียร์ลีกอังกฤษฤดูกาล 2000–2001 ถึง 2024–2025 เพื่อให้มีจำนวนนัดมากพอ

2) **ขอบเขต ด้าน ลีก การ แข่งขัน:** ระบบ การ รวบรวม ข้อมูล และ กระบวนการ ประมวล ผล ตัวแปร (Feature Pipeline) ครอบคลุม 5 ลีกใหญ่ยุโรป ได้แก่ พรีเมียร์ลีก อังกฤษ, ลาลีกา สเปน, บุนเดสลีกา เยอรมนี, กัลโช่ เซเรียอา อิตาลี และลีกเอิง ฝรั่งเศส

3) **ขอบเขตด้านกระบวนการและระบบโครงสร้าง:** พัฒนาท่อส่งข้อมูลแบบโมดูลาร์ด้วยภาษา Python ประกอบด้วย กระบวนการจัดเก็บข้อมูล, การทำความสะอาดและสร้างตัวแปรพร้อมการตรวจสอบสัญญาโครงสร้างข้อมูล (Pandera Data Contracts), การวิเคราะห์การเดิมพันและการทดสอบย้อนหลัง (Backtesting), การวิเคราะห์ราคาตลาด (Market & Odds Analysis), ระบบทดสอบคำสั่งอัตโนมัติ และระบบเชื่อมต่อบริการทำนายผล (FastAPI)

4) **ขอบเขตด้านตัวแปรและการวิเคราะห์ตลาด (Market Analysis):**

- ใช้เฉพาะตัวแปรที่รับรู้ได้ล่วงหน้าก่อนการแข่งขัน (Pre-match Data) ได้แก่ คะแนน Elo, ดัชนีความเหนื่อยล้า, ความหนาแน่นตารางแข่งขัน และฟอร์มผู้เล่น 11 ตัวจริง
- วิเคราะห์ราคาต่อรองอัตราจ่าย (Odds) เพื่อคำนวณค่าส่วนต่างเจ้ามือ (Overround / Vig) และแปลงเป็นความน่าจะเป็นของตลาด (Implied Probabilities)

5) **ขอบเขตด้านแบบจำลองและการประเมินผลกำไร:**

- เปรียบเทียบแบบจำลอง Multinomial Logistic Regression, Gradient-boosted Trees (HistGradientBoosting) และแบบจำลองจำนวนประตู Poisson ในการทำนายความน่าจะเป็น และเปรียบเทียบกับความน่าจะเป็นจากราคาของ Pinnacle
- ทดสอบชุดกลยุทธ์การเดิมพันที่ลงทะเบียนไว้ล่วงหน้า พร้อมการปรับแก้การทดสอบหลายครั้ง และแผนการวางเงิน (Staking Plans) ได้แก่ การวางเงินคงที่ (Fixed Staking), Kelly Criterion / Fractional Kelly และ Martingale
- แบ่งชุดข้อมูลทดสอบตามลำดับเวลา (Temporal Split / Walk-forward) เพื่อป้องกันปัญหาข้อมูลรั่วไหลจากอนาคต (Data Leakage)

6) **ตัวชี้วัดประสิทธิภาพ:**

- *ด้านแบบจำลอง:* Log Loss, Ranked Probability Score (RPS), Accuracy และ Permutation Importance
- *ด้านการลงทุน/เดิมพัน:* อัตราผลตอบแทนจากการลงทุน (Yield / ROI), ผลกำไรสะสม (Net Profit/Loss) และระดับความเสี่ยงการลดลงของเงินทุน (Drawdown)

1.3.2 ข้อจำกัดของโครงงาน

1) ราคาต่อรองที่ใช้ในการทดสอบย้อนหลังอ้างอิงจากข้อมูล Football-Data.co.uk ซึ่งเป็นราคา ณ ช่วงเวลาที่บันทึก ในสถานการณ์จริงราคาอัตราต่อรองมีความผันผวนอยู่ตลอดเวลา (Odds Movement / Slippage)

2) โครงงานไม่ได้รวมปัจจัยเชิงคุณภาพที่ไม่ปรากฏในสถิติ เช่น ข่าวสารการ บาด เจ็บ นาที สุดท้าย สภาพ อากาศ สภาพ สนาม หรือ การเปลี่ยนแปลงผู้จัดการทีม

3) สถิติเชิงลึกรายผู้เล่นจาก Understat ครอบคลุมเฉพาะนัดในลีก ทำให้ค่าดัชนีความเหนื่อยล้ารายบุคคลอาจคลาดเคลื่อนเล็กน้อยสำหรับทีมที่เล่นฟุตบอลถ้วยหลายรายการ (ได้รับการชดเชยบางส่วนด้วยตัวแปรตารางแข่งขันระดับทีมจาก Transfermarkt)

4) ข้อมูลที่รวบรวมจากต่างแหล่งต้องใช้ตารางจับคู่ชื่อสโมสรและนักเตะมาตรฐาน (Alias Mapping) ซึ่งอาจมีค่าว่างในกรณีที่ไม่สามารถจับคู่ข้อมูลระหว่างแหล่งข้อมูลได้

5) ผลลัพธ์และกลยุทธ์ที่ได้จัดทำขึ้นเพื่อวัตถุประสงค์ทางวิชาการและการศึกษาเชิงสถิติเท่านั้น ไม่ได้มีเจตนาในการส่งเสริมการพนันที่ไม่ถูกต้องตามกฎหมาย

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1) ได้กระบวนการวิทยาการข้อมูลแบบครบวงจรสำหรับการวิเคราะห์ข้อมูลกีฬาและสถิติการเดิมพันอย่างเป็นระบบ

2) ได้ระบบประเมินความคุ้มค่าของการเดิมพัน (Value Betting System) ที่สามารถเปรียบเทียบความน่าจะเป็นจริงของแบบจำลองกับราคาตลาด และแนะนำขนาดเงินวางเดิมพันได้อย่างเหมาะสม

3) ได้ระบบทดสอบย้อนหลัง (Backtesting System) ที่สามารถประเมินผลกำไรและความเสี่ยงของการใช้กลยุทธ์เดิมพันรูปแบบต่าง ๆ บนข้อมูลจริงย้อนหลังฤดูกาล 2014–2015 ถึง 2025–2026

4) ได้องค์ความรู้ในการประยุกต์ใช้เทคนิควิทยาการข้อมูล การเรียนรู้ของเครื่อง และกลยุทธ์ทางการเงิน/การวางเงินทุน เพื่อนำไปปรับใช้กับการวิเคราะห์ตลาดการแข่งขันอื่น ๆ ในอนาคต

บทที่ 2
ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 กระบวนการวิทยาการข้อมูลและการจัดทำท่อส่งข้อมูล (Data Science & Pipeline Process)

กระบวนการวิทยาการข้อมูลเป็นกรอบการทำงานเชิงระบบที่นำข้อมูลขนาดใหญ่มาประมวลผลและวิเคราะห์ เพื่อค้นหารูปแบบหรือสร้างคุณประโยชน์ ในโครงงานนี้ได้ประยุกต์ใช้กระบวนการ 5 ขั้นตอน ร่วมกับการออกแบบท่อส่งข้อมูลแบบโมดูลาร์ (Modular Data Pipeline) ได้แก่

1) **การ กำหนด วัตถุประสงค์ และ คำถาม วิจัย (Question Refinement):** กำหนดโจทย์การทำนายผลการแข่งขันฟุตบอลออกเป็น 3 รูปแบบ ได้แก่ ทีมเจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A) เพื่อนำไปประเมินความคุ้มค่าในการเดิมพันเชิงสถิติ

2) **การเก็บรวบรวมข้อมูล (Data Collection):** การสร้างระบบดึงข้อมูลอัตโนมัติ เพื่อรวบรวมตารางการแข่งขัน ผลประตู ค่า xG และสถิติรายบุคคลจาก Understat, ปฏิทินการแข่งขันและแผนการเล่นจาก Transfermarkt รวมถึงสถิติผลการแข่งขันย้อนหลังและราคาอัตราต่อรอง (Betting Odds) จาก Football-Data.co.uk [4, 3, 2]

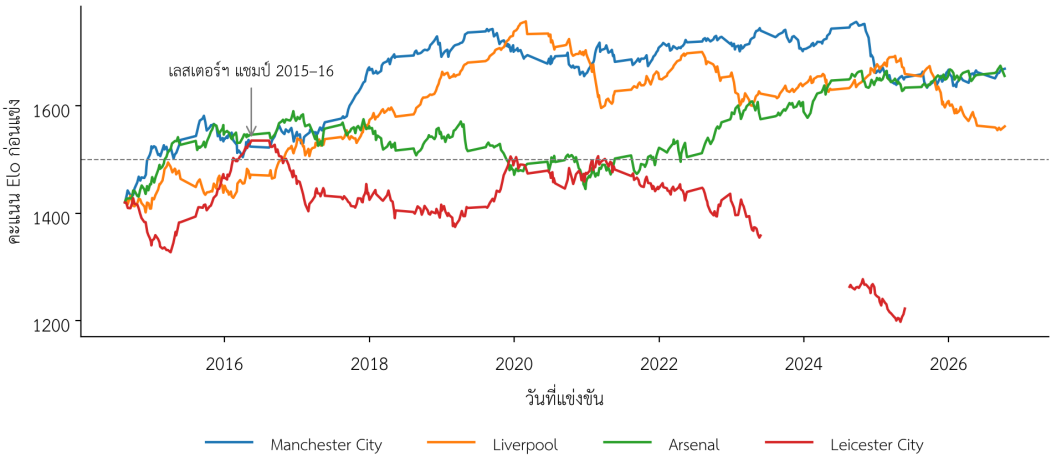
3) **การตรวจสอบ ทำความสะอาด และสร้างตัวแปร (Data Validation & Feature Engineering):** การตรวจสอบคุณภาพข้อมูลผ่านสัญญาข้อมูล (Data Contracts / Pandera) การจัดการค่าที่ขาดหาย การจับคู่ชื่อสโมสร (Entity Resolution) และการสร้างตัวแปรก่อนการแข่งขัน เช่น คะแนน Elo, ดัชนีความเหนื่อยล้า, ความหนาแน่นของตารางแข่งขัน และฟอร์มของผู้เล่นตัวจริง 11 คนแรก

4) **การสร้างและประเมินแบบจำลอง (Model Building & Evaluation):** การพัฒนาแบบจำลองเพื่อทำนายความน่าจะเป็นที่แท้จริงของผลการแข่งขัน และประเมินประสิทธิภาพด้วยตัวชี้วัด Log Loss, Ranked Probability Score (RPS) และ Accuracy [5]

5) **การสรุป วิเคราะห์ตลาด และการจำลองเดิมพัน (Market Analysis & Backtesting):** การวิเคราะห์ราคาต่อรองเพื่อหาโอกาสการเดิมพันที่มีมูลค่า (Value Betting) การประเมินผลกำไร/ขาดทุนสะสม (ROI) ด้วยกลยุทธ์การวางเงินทุนรูปแบบต่าง ๆ และการนำเสนอระดับความสำคัญของตัวแปรทำนาย (Feature Importance)

2.1.2 ระบบวัดระดับความแข็งแกร่ง (Elo Rating System)

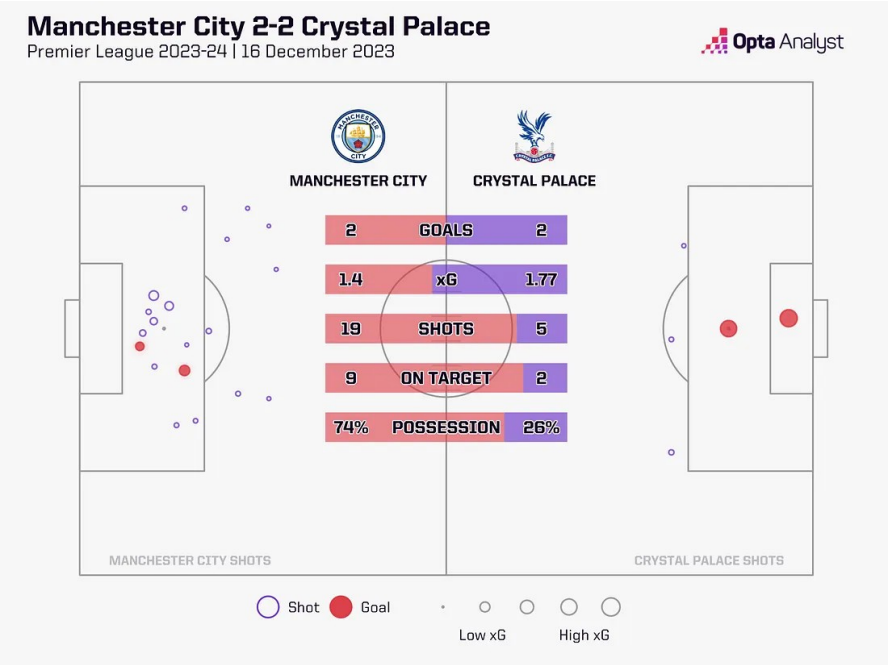
ระบบคะแนน Elo เป็นวิธีทางสถิติที่ใช้คำนวณระดับทักษะความแข็งแกร่งของทีมแข่งขัน คะแนนจะถูกปรับเปลี่ยนตามผลการแข่งขันจริงและระดับความแข็งแกร่งของคู่แข่ง โดยทีมที่ชนะทีมที่มีคะแนนสูงกว่าจะได้คะแนนเพิ่มขึ้นมากกว่าการชนะทีมที่อ่อนกว่า [6] สำหรับฟุตบอล การปรับคะแนนสามารถถ่วงน้ำหนักตามผลต่างประตูของการแข่งขันได้ เพื่อให้ชัยชนะที่ขาดลอยส่งผลต่อคะแนนมากกว่าชัยชนะเฉียดฉิว ในโครงงานนี้ได้มีการคำนวณค่า Elo Rating ของแต่ละสโมสรอย่างต่อเนื่องตามลำดับเวลา (Time-series) ดังแสดงในรูปที่ 1 และนำผลต่างคะแนน Elo (Elo Difference) ระหว่างทีมเจ้าบ้านและทีมเยือน ซึ่งใช้ค่าก่อนเริ่มการแข่งขันเท่านั้น มาใช้เป็นตัวแปรสำคัญในการสะท้อนความได้เปรียบเชิงศักยภาพของทีม



ภาพที่ 1 คะแนน Elo ก่อนแข่งของ 4 สโมสรพรีเมียร์ลีกที่คำนวณในโครงงานนี้ (เส้นประคือคะแนนเริ่มต้น 1500 ช่วงที่เส้นขาดคือฤดูกาลที่สโมสรไม่ได้อยู่ใน 5 ลีกใหญ่)

2.1.3 ค่าความคาดหวังในการทำประตู (Expected Goals: xG)

ค่า xG เป็นตัวชี้วัดเชิงสถิติขั้นสูงที่ใช้ประเมินคุณภาพของโอกาสในการยิงประตู โดยคำนวณความน่าจะเป็นที่ลูกยิงแต่ละครั้งจะกลายเป็นประตู (มีค่าระหว่าง 0 ถึง 1) ขึ้นอยู่กับตำแหน่งการยิง มุมในการยิง ประเภทการส่งบอล และบริบทของเกม ดังแสดงตัวอย่างในรูปที่ 2 ค่า xG ช่วยให้มองเห็นประสิทธิภาพเกมรุกที่แท้จริง ซึ่งสะท้อนฟอร์มการเล่นได้ดีกว่าผลสกอร์แพ้-ชนะแบบดั้งเดิม [2] ในโครงงานนี้ ค่า xG และค่า xA (Expected Assists) รายบุคคลถูกนำมาสรุปเป็นฟอร์มของผู้เล่นตัวจริงแต่ละคน ในรูปอัตราต่อ 90 นาที โดยใช้เฉพาะการแข่งขันก่อนนัดปัจจุบัน



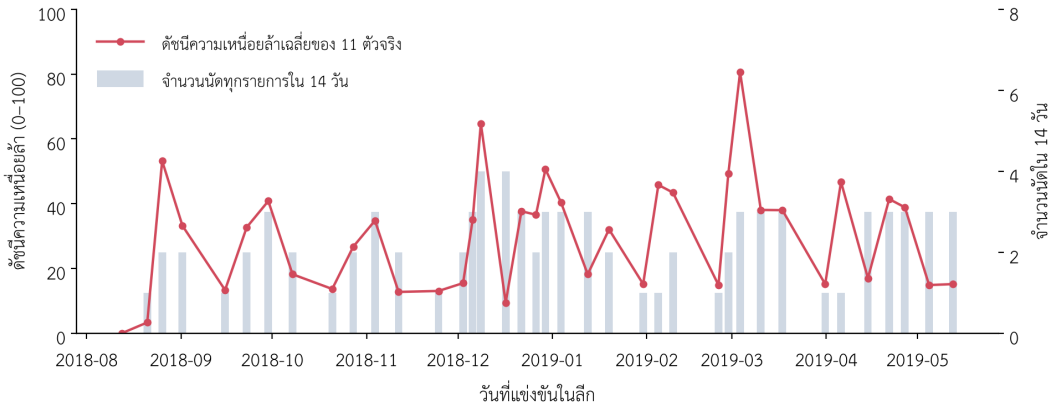
ภาพที่ 2 ตัวอย่างการประเมินค่าความคาดหวังในการทำประตู (Expected Goals: xG) จากตำแหน่งการยิง (ที่มา: Opta Analyst [7])

2.1.4 ดัชนีความเหนื่อยล้าและความหนาแน่นของตารางแข่ง (Fatigue Metric & Schedule Congestion)

ระยะ เวลา พัก ผ่อน ระ หว่าง แมตช์ การ แข่งขัน ส่ง ผล ต่อ สภาพ ร่างกาย และประสิทธิภาพการเล่นของนักเตะ ในโครงงานนี้จึงสร้างตัวแปรที่เกี่ยวข้องกับภาระการเล่นเป็น 2 ระดับ ดังแสดงตัวอย่างแนวคิดในรูปที่ 3

1) **ระดับผู้เล่น:** คำนวณคะแนนความเหนื่อยล้า (Fatigue Score) ช่วง 0–100 จากนาทีที่ลงเล่นใน 7 และ 28 วันก่อนหน้า (ภาระงานระยะสั้นเทียบกับระยะยาว) และความสั้นของระยะพัก แล้วสรุปเป็นค่าเฉลี่ยของผู้เล่นตัวจริงแต่ละฝั่ง

2) **ระดับทีม:** คำนวณจากปฏิทินการแข่งขันทุกรายการ ได้แก่ จำนวนวันพักนับจากนัดก่อนหน้า จำนวนนัดใน 7 และ 14 วันที่ผ่านมา จำนวนนัดที่ไม่ใช่ลีกใน 14 วัน และการเดินทางไปเยือนในศึกยุโรปในนัดก่อนหน้า



ภาพที่ 3 ดัชนีความเหนื่อยล้าเฉลี่ยของผู้เล่นตัวจริงและจำนวนนัดทุกรายการใน 14 วันก่อนแต่ละนัดในลีกของ Liverpool ฤดูกาล 2018–2019

2.1.5 อัตราต่อรองของเจ้ามือรับพนันและการเดิมพันที่มีมูลค่า (Betting Odds & Value Betting)

ราคาอัตราต่อรองจากเจ้ามือรับพนัน (Bookmakers) สามารถแปลงเป็นค่าความน่าจะเป็นโดยนัย (Implied Probability) ได้ โดยคำนวณจากส่วนกลับของราคาต่อรอง เช่น อัตราจ่าย O จะมีความน่าจะเป็นโดยนัยเท่ากับ $1/O$ อย่างไรก็ตาม ผลรวมความน่าจะเป็นของทุกทางเลือก (Home/Draw/Away) มักจะเกินร้อยละ 100 เนื่องจากถูกบวกส่วนต่างกำไรของเจ้ามือ (Overround / Vig)

การวิเคราะห์เพื่อการเดิมพันจะใช้แบบจำลองคำนวณ **ความน่าจะเป็นที่แท้จริง (Model Probability: P)** แล้วนำไปเปรียบเทียบกับราคาต่อรองในตลาด หากราคาต่อรองในตลาดให้ค่าสูงกว่าความน่าจะเป็นของแบบจำลอง จะถือว่าเกิด **การเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (Positive Expected Value: +EV / Value Bet)** โดยค่าความคาดหมายคำนวณได้จาก:

$$EV = (P \times O) - 1 \tag{1}$$

หากค่า $EV > 0$ แสดงว่าการวางเดิมพันในตัวเลือกนั้นมีความคุ้มค่าทางสถิติในระยะยาว

2.1.6 กลยุทธ์การบริหารเงินทุนและการทดสอบย้อนหลัง (Staking Strategies & Backtesting)

ในการประเมินผลตอบแทนทางการเงิน การทำนายผลถูกต้องเพียงอย่างเดียวไม่เพียงพอ แต่ต้องอาศัยกลยุทธ์การจัดสรรเงินทุน (Staking Strategy) ที่เหมาะสม เพื่อป้องกันความเสี่ยงจากการหมดตัว (Risk of Ruin) โครงงานนี้ทดสอบแผนการวางเงิน 5 แบบ แบ่งเป็น 3 กลุ่ม ได้แก่:

1) **การวางเงินคงที่ (Fixed Staking):** กำหนดจำนวนเงินวางเดิมพันเป็นจำนวนเงินที่แน่นอนเท่ากันทุกครั้ง

2) **สูตรการวางเงินแบบเคลลี (Kelly Criterion):** คำนวณสัดส่วนเงินทุน

ที่ควรวางเดิมพัน (f^*) ตามระดับความคุ้มค่าและอัตราต่อรอง:

$$f^* = \frac{P \cdot O - 1}{O - 1} \tag{2}$$

พร้อมทั้งทดสอบสัดส่วนเคลลีแบบย่อย (Fractional Kelly ได้แก่ Half Kelly และ Quarter Kelly) เพื่อลดความผันผวนของเงินทุน

3) **Martingale:** เพิ่มเงินเดิมพันเป็น 2 เท่าหลังแพ้ และกลับไปที่ขนาดเริ่มต้นหลังชนะ ใช้เป็นตัวอย่างของแผนที่ดูเหมือนรับประกันกำไรแต่ไม่เปลี่ยนค่าคาดหมาย

ระบบการทดสอบย้อนหลัง (Backtesting Engine) จะจำลองการวางเดิมพันตามลำดับเวลาจริง (Temporal Backtesting) บนข้อมูลย้อนหลังหลายฤดูกาล (ทำนายแต่ละฤดูกาลจากฤดูกาลก่อนหน้าเท่านั้น) เพื่อวัดอัตราผลตอบแทนจากการลงทุน (ROI), กำไรสะสม (Net Profit/Loss) และระดับการลดลงสูงสุดของเงินทุน (Maximum Drawdown)

2.1.7 การจับคู่และแปลงชื่อเอนทิตีให้เป็นมาตรฐาน (Entity Resolution)

เนื่องจากข้อมูลถูกรวบรวมมาจากหลายแหล่งข้อมูลภายนอก (Understat, Transfermarkt, Football-Data.co.uk) ทำให้ชื่อสโมสรฟุตบอลเดียวกันอาจถูกบันทึกด้วยข้อความที่แตกต่างกัน กระบวนการ Entity Resolution จึงถูกนำมาใช้เพื่อปรับแปลงชื่อทีมจากทุกแหล่งข้อมูลให้อยู่ในรูปแบบมาตรฐาน (Canonical Team Names) ผ่านพจนานุกรมเทียบเคียงชื่อ (Alias Mapping) เพื่อให้สามารถเชื่อมโยงข้อมูล (Data Joining) ได้อย่างแม่นยำ ทั้งนี้สโมสรที่ไม่สามารถจับคู่ได้จะมีตัวแปรที่ต้องอาศัยแหล่งนั้นเป็นค่าว่าง

2.1.8 แบบจำลองทำนายผลการแข่งขัน

การทำนายผลการแข่งขันฟุตบอลถูกกำหนดให้เป็นโจทย์ที่ให้ผลลัพธ์เป็นความน่าจะเป็นของ 3 กลุ่ม ได้แก่ ทีมเจ้าบ้านชนะ (H), เสมอ (D) และทีมเยือนชนะ (A) โครงงานนี้เปรียบเทียบแบบจำลองหลายแนวทาง ดังนี้

1) Multinomial Logistic Regression

ขยาย Logistic Regression ไปสู่ผลลัพธ์มากกว่า 2 กลุ่ม โดยให้ความน่าจะเป็นของแต่ละผล $k \in \{H, D, A\}$ เป็น $P(y = k \mid x) = \exp(\beta_k^\top x) / \sum_j \exp(\beta_j^\top x)$ แบบจำลองนี้เรียบง่าย ตีความได้ และให้ความน่าจะเป็นที่ปรับเทียบดีเมื่อความสัมพันธ์ระหว่างตัวแปรกับผลลัพธ์ใกล้เคียงเชิงเส้น จึงใช้เป็นแบบจำลองพื้นฐานที่แบบจำลองอื่นต้องเอาชนะ

2) แบบจำลอง Double Poisson และการแก้ไขแบบ Dixon-Coles

จำนวนประตูของทีมเจ้าบ้านและทีมเยือนถูกจำลองเป็นตัวแปรสุ่มแบบปัวซง (Poisson) สองตัว โดยให้ค่าลอการิทึมของอัตราการทำประตูเป็นฟังก์ชันเชิงเส้นของผลต่างคะแนน Elo ก่อนการแข่งขัน (หารด้วย 400) ซึ่งประมาณค่าด้วย Poisson Regression จากนั้นนำความน่าจะเป็นของสกอร์ทุกค่ามาสร้างตารางร่วม (Score Grid) แล้วรวมเป็นความน่าจะเป็น

ของ H, D และ A การแก้ไขแบบ Dixon-Coles [8] ปรับความน่าจะเป็นของสกอร์ต่ำ (0–0, 1–0, 0–1 และ 1–1) ด้วยพารามิเตอร์ ρ เพื่อแก้ปัญหาที่การแจกแจงปัวซงอิสระประเมินความน่าจะเป็นของสกอร์เหล่านี้คลาดเคลื่อน การทำนายใช้วิธี Walk-forward คือทำนายแต่ละฤดูกาลด้วยแบบจำลองที่ฝึกจากฤดูกาลก่อนหน้าเท่านั้น

3) Gradient Boosting

เป็นเทคนิค Ensemble Learning ที่สร้างต้นไม้ตัดสินใจขนาดเล็กหลายต้นต่อเนื่องกัน โดยใช้ `HistGradientBoostingClassifier` ของ Scikit-learn [5] เป็นแบบจำลองในการประมวลผลตัวแปรเชิงซ้อนก่อนการแข่งขัน เพื่อทำนายความน่าจะเป็นและวัดระดับความสำคัญของตัวแปร

4) Permutation Importance

วัดความสำคัญของตัวแปรจากระดับที่ค่า Log Loss บนชุดทดสอบเพิ่มขึ้นเมื่อสลับค่าของตัวแปรนั้นแบบสุ่มโดยไม่เปลี่ยนค่าอื่น ตัวแปรที่เมื่อถูกสลับแล้วทำให้ Log Loss เพิ่มมากแสดงว่าให้ข้อมูลสำคัญต่อแบบจำลอง เนื่องจากตัวแปรผู้เล่นตัวจริง 22 ตำแหน่งมีความสัมพันธ์กันสูง จึงสลับค่าเป็นกลุ่มพร้อมกัน แทนการสลับทีละคอลัมน์

5) ตัวชี้วัดประสิทธิภาพ

ประเมิน 2 มิติ ได้แก่ มิติประสิทธิภาพโมเดลด้วย **Log Loss** (คุณภาพความน่าจะเป็น), **Ranked Probability Score (RPS)** (ความคลาดเคลื่อนสะสม) และ **Accuracy** ร่วมกับมิติทางการเงินด้วย **ROI / Yield** (เปอร์เซ็นต์กำไรสุทธิเทียบกับยอดลงเงิน) และ **Maximum Drawdown** (ระดับขาดทุนสะสมสูงสุด)

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 การทำนายผลฟุตบอลและการประเมินประสิทธิภาพเทียบกับตลาดเดิมพัน

งานวิจัยยุคแรกมักใช้สถิติการแข่งขันย้อนหลัง เช่น จำนวนประตูและฟอร์มเหย้า-เยือน ผ่านโมเดลเชิงสถิติตระกูล Poisson [8] หรือระบบจัดอันดับ Rating [6, 9] Hubáček และคณะ [1] นำแบบจำลองที่ใช้เพียงผลสกอร์ย้อนหลัง 9 แบบ (เช่น Double Poisson, Elo, pi-ratings และ Berrar ratings) มาทดสอบบนชุดข้อมูล Open International Soccer Database [10] จำนวน 91,155 นัด พบว่าทุกแบบให้ผลใกล้เคียงกันมาก โดยมี Accuracy อยู่ระหว่างร้อยละ 47.84–48.60 และ RPS ระหว่าง 0.2101–0.2134 ซึ่งผู้วิจัยตีความว่าเป็นขีดจำกัดของการทำนายจากผลสกอร์อย่างเดียว ทั้งนี้งานดังกล่าวไม่ได้เปรียบเทียบกับราคาของตลาดเดิมพัน

2.2.2 การใช้ Machine Learning ร่วมกับสถิติเชิงลึก และกลยุทธ์การเอาชนะตลาด

งานวิจัยระยะหลังเริ่มนำตัวชี้วัดขั้นสูง เช่น xG และไลน์อัปตัวจริง มาประกอบการสร้างแบบจำลอง Berrar และคณะ [11] ชี้ว่าการใช้ข้อมูลบริบทเชิงลึกช่วยเพิ่มประสิทธิภาพการทำนายได้อย่างมีนัยสำคัญ นอกจากนี้ งานวิจัยด้านการทำนายเชิงพาณิชย์ยังเน้นย้ำถึงการใช้สูตร Kelly Criterion ร่วมกับการทำนายแบบ Walk-forward Validation เพื่อทดสอบว่าแบบจำลองสามารถสร้างกำไรสุทธิ (Positive ROI) หลังจากหักค่าส่วนต่างของเจ้ามือ (Overround)

ได้หรือไม่

2.2.3 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรม สามารถสรุปเปรียบเทียบองค์ประกอบระหว่างแนวทางงานวิจัยทั่วไปกับโครงงานนี้ได้ดังตารางที่ 1

ตารางที่ 1 การเปรียบเทียบองค์ประกอบของงานวิจัยที่เกี่ยวข้องกับโครงงานนี้

การศึกษา / โครงงาน	สถิติผลสกอร์	อัตราต่อรอง	Elo / xG	ไลน์อัป / ฟอร์มผู้เล่น	ตารางแข่ง/ความเหนื่อยล้า	Backtesting / Staking
แบบจำลองจำนวนประตูและการทดสอบกับตลาด [8]	✓	✓	–	–	–	✓
ระบบจัดอันดับความแข็งแกร่ง (Elo, pi-rating) [6, 9]	✓	✓	✓	–	–	–
แบบจำลองจากผลสกอร์โดยไม่ใช้ราคาตลาด [11, 1]	✓	–	✓	–	–	–
Value Betting ด้วยราคาของเจ้ามือ [12]	–	✓	–	–	–	✓
โครงงานนี้	✓	✓	✓	✓	✓	✓

จากตารางที่ 1 แสดงให้เห็นว่าโครงงานนี้บูรณาการตัวแปรก่อนการแข่งขันครอบคลุมสถิติขั้นสูง (Elo, xG) ฟอร์มผู้เล่นตัวจริง และภาระโปรแกรมแข่งขัน ร่วมกับการวิเคราะห์ราคาตลาดต่อรองและระบบทดสอบย้อนหลัง (Backtesting Engine) เพื่อประเมินความคุ้มค่าทางการเงิน

2.3 เครื่องมือและเทคโนโลยีที่ใช้

2.3.1 ภาษา Python และไลบรารีสำหรับการประมวลผลข้อมูล

1) **Polars, DuckDB และ PyArrow:** ใช้สำหรับการจัดการ ทำความสะอาด และประมวลผลตาราง ข้อมูลประสิทธิภาพสูง (High-performance DataFrames)

2) **Pandera และ Pydantic:** ใช้สำหรับการตรวจสอบความถูกต้องของโครงสร้างข้อมูล (Data Schema Validation & Data Contracts) และการตรวจสอบไฟล์ตั้งค่าของระบบ

3) **Soccerdata:** ใช้ดึงข้อมูลสถิติการแข่งขันและค่า xG จาก Understat

4) **Scikit-learn และ SciPy:** ใช้พัฒนาแบบจำลอง (Poisson Regression, Gradient Boosting) การคำนวณตัวชี้วัด และการทดสอบสมมติฐานทางสถิติ [5]

5) **FastAPI และ Uvicorn:** ใช้พัฒนาบริการระบบ API สำหรับเรียกดูข้อมูลและผลการทำนาย

2.3.2 สภาพแวดล้อมและการประกันคุณภาพซอฟต์แวร์ (Development Environment & Quality Control)

1) **ระบบบริหารจัดการสภาพแวดล้อมเสมือน (uv) และ Docker:** uv บริหารจัดการ Virtual Environment และไลบรารีความเร็วสูง พร้อมไฟล์ล็อกรุ่นของไลบรารี ส่วน Docker ช่วยให้รันท่อส่งข้อมูลและ API ได้ในสภาพแวดล้อมเดียวกัน

2) **ระบบทดสอบซอฟต์แวร์และตรวจสอบโค้ดอัตโนมัติ:** ใช้ Pytest และ Hypothesis สำหรับชุดทดสอบอัตโนมัติ ใช้ Ruff และ Pyright สำหรับตรวจรูปแบบและชนิดข้อมูล ใช้ pre-commit และ GitHub Actions ตรวจสอบก่อนบันทึกขึ้นระบบ

3) **แหล่ง ชุด ข้อมูล สาธารณะ (Understat, Transfermarkt, Football-Data.co.uk):** เป็นแหล่งข้อมูลสถิติเชิงลึก xG, ปฏิทินการแข่งขันและไลน์อัปผู้เล่น รวมถึงสถิติผลการแข่งขันย้อนหลังและราคาอัตราต่อรองของเจ้ามือ [4, 3, 2]

บทที่ 3
วิธีการดำเนินโครงงาน

ในการดำเนินโครงงาน “การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลลีกยุโรปด้วยกระบวนการวิทยาการข้อมูลเพื่อการประเมินมูลค่าการเดิมพัน (European Football Match Outcome Prediction and Betting Market Analysis Using Data Science)” ผู้จัดทำได้ออกแบบและพัฒนาท่อส่งข้อมูลเชิงโมดูลาร์ (Modular Data Pipeline) ตามกระบวนการวิทยาการข้อมูล เพื่อให้ระบบสามารถประมวลผลข้อมูลที่มีความซับซ้อน ป้องกันปัญหาข้อมูลอนาคตรั่วไหล (Data Leakage) และรองรับการประเมินผลกำไรทางการเงินร่วมกับการทำนายทางสถิติได้อย่างเป็นระบบ โดยแบ่งขั้นตอนการดำเนินงานออกเป็น 6 ส่วนหลัก ดังนี้

1) การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน
2) การเก็บรวบรวมข้อมูล (Data Collection)
3) การ ทำความ สะอาด ข้อมูล และ การ ตรวจ สอบ ความ ถูก ต้อง (Data Cleaning, Schema Validation & Entity Resolution)
4) การวิศวกรรมฟีเจอร์และการวิเคราะห์ตลาดเดิมพัน (Feature Engineering & Betting Market Analysis)
5) การพัฒนาแบบจำลอง การเปรียบเทียบกับตลาด และระบบทดสอบย้อนหลัง (Model Development, Market Test & Backtesting Framework)
6) การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance Framework)

3.1 การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน

การทำนายผลการแข่งขันฟุตบอลและการประเมินความคุ้มค่าทางการเดิมพันมีความซับซ้อนสูง เนื่องจากต้องคำนึงถึงทั้งปัจจัยเชิงสถิติของทีมและการตั้งราคาต่อรองของตลาด โครงงานนี้จึงมุ่งเน้นการใช้ประโยชน์จากข้อมูลที่ทราบก่อนเริ่มการแข่งขันเท่านั้น โดยมีแนวทางการดำเนินงานดังนี้

1) **ศึกษา ทฤษฎี และ งาน วิจัย ที่ เกี่ยวข้อง:** ศึกษา หลัก การ คำนวณ ระบบ ประเมิน ศักยภาพเชิงสัมพัทธ์ (Elo Rating System) [6], ค่าความคาดหวังในการทำประตู (Expected Goals: xG) [2], แบบจำลองปัวซงสำหรับจำนวนประตู [8], การคำนวณดัชนีความเหนื่อยล้าสะสม (Fatigue Index), การคำนวณความน่าจะเป็นของตลาดจากอัตราต่อรอง (Implied Probabilities) และกลยุทธ์การจัดสรรเงินทุน (Kelly Criterion & Staking Strategies)

2) **กำหนดขอบเขตและเป้าหมายการทำนาย:** กำหนดเป้าหมายการทำนายผลการแข่งขันออกเป็น 3 ผลลัพธ์ ได้แก่ เจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A) โดยทำนายเป็นความน่าจะเป็นของแต่ละผลลัพธ์ เพื่อนำไปค้นหาการเดิมพันที่มีมูลค่าคาดหมายเป็นบวก (Positive Expected Value: +EV)

3) **กำหนดเครื่องมือและสภาพแวดล้อมการพัฒนา:** พัฒนาระบบด้วยภาษา Python 3.14 ขึ้นไป ร่วมกับเครื่องมือบริหารจัดการสภาพแวดล้อมเสมือน (**uv**), ไลบรารีวิเคราะห์ข้อมูลตาราง (Polars), เครื่องมือตรวจสอบสัญญาข้อมูล (Pandera และ Pydantic), ไลบรารีเรียนรู้ของเครื่อง (Scikit-learn), ระบบทดสอบซอฟต์แวร์อัตโนมัติ (Pytest) และระบบตรวจทานคุณภาพโค้ด (Ruff และ Pyright)

3.2 การเก็บรวบรวมข้อมูล (Data Collection)

ผู้จัดทำได้พัฒนาระบบดึงข้อมูลอัตโนมัติ เพื่อรวบรวมข้อมูลจากแหล่งข้อมูลสาธารณะ โดยมีหลักการทำงานที่สำคัญ 2 ประการ คือ (1) สามารถเริ่มทำงานต่อได้ (Resumable) โดยข้ามไฟล์ที่มีอยู่แล้ว และ (2) ตรวจสอบความสมบูรณ์ก่อนบันทึก โดยเขียนข้อมูลลงไฟล์ชั่วคราวก่อน อ่านกลับมาตรวจกับโครงสร้างข้อมูลดิบ (Raw Schema) แล้วจึงเปลี่ยนชื่อเป็นไฟล์จริง เพื่อป้องกันไฟล์เสียหาย

1) **ตารางการแข่งขันและสถิติ Understat:** ดึงผ่านไลบรารี soccerdata ครอบคลุม 5 ลีกใหญ่ยุโรป ตั้งแต่ฤดูกาล 2014–2015 ถึง 2025–2026 (ฤดูกาลปัจจุบันเท่าที่แข่งไปแล้ว) ประกอบด้วยผลประตู ค่า xG/xA และสถิติรายบุคคลของผู้เล่นในแต่ละนัด [2]

2) **Transfermarkt:** รวบรวมชุดข้อมูลปฏิทินการแข่งขันทุกรายการ (ลีกถ้วยในประเทศ และรายการยุโรป) ของสโมสรใน 5 ลีกใหญ่ และตารางการลงสนามของผู้เล่น รวมถึงแผนการเล่น (Formation) ตัวจริง 11 คนแรก [3]

3) **Football-Data.co.uk:** ดึงข้อมูลสถิติผลการแข่งขันย้อนหลัง สถิติการยิง/เตะมุม และราคาอัตราต่อรอง (Betting Odds) จากเจ้ามือรับพนันหลายแห่ง (เช่น Bet365, Pinnacle) ย้อนหลังตั้งแต่ฤดูกาล 2014–2015 ถึง 2025–2026 (ฤดูกาลปัจจุบันเท่าที่แข่งไปแล้ว) สำหรับใช้ประเมินความน่าจะเป็นของตลาดและทดสอบย้อนหลัง [4]

3.3 การทำความสะอาดข้อมูลและการตรวจสอบความถูกต้อง

3.3.1 ขั้นตอนการทำความสะอาด (Data Cleaning)

กระบวนการทำความสะอาดแปลงไฟล์ข้อมูลดิบเป็นตารางสะอาดหลัก ได้แก่ ตารางนัดการแข่งขันลีก, ตารางสถิติผู้เล่นรายนัด, ตารางการแข่งขันทุกรายการของ Transfermarkt และตารางราคาต่อรองของ Football-Data.co.uk โดยมีขั้นตอนหลักดังนี้

1) คัดเลือกเฉพาะนัดที่แข่งขันจบแล้ว และแปลงระบุฤดูกาลให้อยู่ในรูปแบบมาตรฐาน (เช่น 2014)

2) แปลงชื่อสโมสรจากทุกแหล่งข้อมูลให้เป็นชื่อมาตรฐานเดียวกัน (ดูหัวข้อ Entity Resolution)

3) แปลงรูปแบบแผนการเล่น (Formation) เช่น **4-2-3-1** เป็นตัวเลขจำนวนแนวรับ แนวกลาง และแนวรุก

4) เชื่อมโยงนัดการแข่งขันระหว่าง Understat, Transfermarkt และ Football-Data.co.uk ตามวันที่และคู่แข่งขัน

3.3.2 การจับคู่และแปลงชื่อเอนทิตีให้เป็นมาตรฐาน (Entity Resolution)

เนื่องจากชื่อสโมสรในแต่ละแหล่งข้อมูลมีความแตกต่างกัน ระบบจึงใช้พจนานุกรมเทียบเคียงชื่อ (Alias Table) แปลงเป็นชื่อมาตรฐาน (Canonical Names) ส่วนการจับคู่ระหว่างรหัสสโมสรของ Transfermarkt กับชื่อทีมของ Understat และ Football-Data.co.uk ใช้วิธีเรียนรู้จากตัวนัดการแข่งขัน โดยถือว่าเป็นนัดเดียวกันเมื่อแข่งขันในลีกเดียวกัน สกอร์ตรงกัน และวันที่แข่งขันห่างกันไม่เกิน 1 วัน

3.3.3 การ ตรวจ สอบ ความ ถูก ต้อง ของ ข้อ ตกลง ข้อมูล (Data Schema Validation)

ระบบประยุกต์ใช้แนวคิดสัญญาข้อมูล (Data Contracts) ด้วย Pandera โดยตรวจข้อมูลขาเข้าและขาออกในทุกขั้นตอน ร่วมกับโครงสร้างข้อมูลที่กำหนด แบ่งเป็น 3 ระดับ ดังนี้

- **โครงสร้าง ข้อมูล ดิบ (Raw Schema):** ตรวจไฟล์ข้อมูลดิบตอนดาวน์โหลดและอ่านเข้าสู่ระบบ
- **โครงสร้างข้อมูลระหว่างทาง (Step Schema):** ตรวจประเภทข้อมูลและขอบเขตค่าผลลัพธ์ในแต่ละขั้นตอนการประมวลผล
- **โครงสร้างข้อมูลสุดท้าย (Clean Schema):** ตรวจไฟล์ตารางสะอาดทุกไฟล์กับ Schema ที่กำหนดก่อนนำไปสร้างตัวแปร

3.4 การวิศวกรรมฟีเจอร์และการวิเคราะห์ตลาดเดิมพัน

สถาปัตยกรรมของระบบเป็นท่อส่งข้อมูลแบบโมดูลาร์ที่ประมวลผลตามลำดับ ดังตารางที่ 2

ตารางที่ 2 สถาปัตยกรรมโมดูลการประมวลผลข้อมูลในระบบ (Data Pipeline Modules)

ลำดับ	คำสั่ง / โมดูล	หน้าที่การทำงานหลัก
1	`Data Collection`	ดึงข้อมูลดิบจาก Understat, Transfermarkt และ Football-Data.co.uk
2	`Data Cleaning`	ทำความสะอาด แปลงชื่อสโมสร จับคู่นัดระหว่างแหล่งข้อมูล
3	`Feature Engineering`	คำนวณ Elo, ความเหนื่อยล้า, ตารางแข่ง, ฟอร์มผู้เล่น และราคาต่อรองตลาด
4	`Schema Check`	ตรวจสอบไฟล์ผลลัพธ์ทุกไฟล์กับ Pandera Data Contracts
5	`Model & Backtesting`	ฝึกแบบจำลอง ทำนายความน่าจะเป็น คำนวณ +EV และจำลองการวางเงินทุน
6	`API Service`	ให้บริการตารางข้อมูล ผลการทำนาย และสัญญาณการเดิมพันผ่าน FastAPI

ตัวแปรทุกตัวใช้เฉพาะข้อมูลที่ทราบ ณ เวลาเริ่มการแข่งขัน โดยหน้าต่างค่าเฉลี่ยย้อนหลังไม่รวมนัดปัจจุบัน และคะแนน Elo ใช้ค่าก่อนแข่ง ผลลัพธ์รวมเป็นตารางตัวแปรหลักสำหรับใช้ฝึกแบบจำลอง

3.4.1 การคำนวณคะแนนความแข็งแกร่งเชิงสัมพัทธ์ (Elo Rating Calculation)

ระบบเล่นซ้ำผลการแข่งขันลีกทุกนัดตามลำดับวันที่ และบันทึกคะแนน Elo ของแต่ละทีมก่อนเริ่มนัด (R_H และ R_A) โดยให้ผลต่างคะแนน $\Delta R = R_H - R_A$ ไม่รวมความได้เปรียบของเจ้าบ้าน ค่าคะแนนที่คาดหวังของเจ้าบ้าน (E_H) รวมความได้เปรียบของเจ้าบ้าน (h) และการปรับปรุงคะแนนหลังจบนัดคำนวณได้จากสมการที่ (3) และ (4)

$$E_H = \frac{1}{1 + 10^{-(R_H + h - R_A)/400}} \tag{3}$$

$$R'_H = R_H + K \cdot G \cdot (S_H - E_H), \qquad R'_A = R_A - K \cdot G \cdot (S_H - E_H) \tag{4}$$

โดยที่ S_H คือผลการแข่งขันจริงของเจ้าบ้าน (1 เมื่อชนะ, 0.5 เมื่อเสมอ, 0 เมื่อแพ้), $K = 15$ คือขนาดการปรับ, $h = 40$ คะแนน คือความได้เปรียบของเจ้าบ้าน และ G คือตัวคูณตามผลต่างประตู $|gd|$ ซึ่งมีค่า 1 เมื่อ $|gd| \leq 1$, 1.5 เมื่อ $|gd| = 2$ และ $(11 + |gd|)/8$ เมื่อ $|gd| \geq 3$ คะแนนเริ่มต้นเท่ากับ 1500 ทีมที่เลื่อนชั้นเริ่มที่ค่าเฉลี่ยคะแนนของทีมที่ตกชั้นในฤดูกาลก่อนหน้า ตัวอย่างขั้นตอนการคำนวณแสดงดังรายการที่ 3.1

```python
def goal_multiplier(gd: int) -> float:
    gd = abs(gd)
    if gd <= 1:
        return 1.0
    if gd == 2:
        return 1.5
    return (11 + gd) / 8

def update_elo(r_home, r_away, home_goals, away_goals, k=15.0, home_adv=40.0):
    # expected score of the home side (home advantage included)
    expected = 1 / (1 + 10 ** (-(r_home + home_adv - r_away) / 400))
    # actual score: win 1, draw 0.5, loss 0
    if home_goals > away_goals:
        actual = 1.0
    elif home_goals == away_goals:
        actual = 0.5
    else:
        actual = 0.0
    delta = k * goal_multiplier(home_goals - away_goals) * (actual - expected)
    return r_home + delta, r_away - delta
```

Listing 3.1: ฟังก์ชันการคำนวณและปรับปรุงคะแนน Elo Rating

3.4.2 การ คำนวณ ดัชนี ความ เหนื่อย ล้า สะสม และ ความ หนา แน่น ตารางแข่ง

ระบบคำนวณคะแนนความเหนื่อยล้า (Fatigue Score) ช่วง 0–100 จากภาระการเล่นของผู้เล่น 11 ตัวจริง (นาทีที่ลงเล่นใน 7/28 วัน และระยะพัก) แล้วรวมกับตัวแปรความหนาแน่นตารางแข่งขันระดับทีมจาก Transfermarkt ได้แก่ จำนวนวันพักนับจากนัดก่อนหน้า จำนวนนัดในรอบ 7 และ 14 วัน และตัวบอกการแข่งเกมเยือนในศึกยุโรป

3.4.3 ฟอร์มรายบุคคลของผู้เล่นตัวจริง (Starter Form Features)

สำหรับผู้เล่นตัวจริงแต่ละคน ระบบคำนวณค่า xG, xA และนาทีที่ลงเล่นใน 10 นัดก่อนหน้า คิดเป็นอัตราต่อ 90 นาที (`xg90`, `xa90`, `form90`) จากนั้นเรียงผู้เล่น 11 คนตามตำแหน่งไลน์อัปกระจายเป็นคอลัมน์ช่องตำแหน่ง (Slots) รวม 110 คอลัมน์

3.4.4 การ วิเคราะห์ ราคา ต่อ รอง อัตรา จ่าย และ มูลค่า การ เดิม พัน (Odds & Value Betting Analysis)

นำราคาต่อรองจาก Football-Data.co.uk มาแปลงเป็นความน่าจะเป็นโดยนัยของตลาด (Implied Probabilities: P_{market}) พร้อมทั้งคำนวณค่าส่วนต่างเจ้ามือ (Overround / Vig) เพื่อปรับค่าความน่าจะเป็นให้รวมเป็น 100% จากนั้นเปรียบเทียบกับความน่าจะเป็นที่ทำนายโดยแบบจำลอง (P_{model}) เพื่อหาค่าความคาดหมายเป็นบวก (Expected

Value: EV):

$$EV = (P_{model} \times \text{Odds}) - 1 \tag{5}$$

โดยนัดที่มีค่า $EV > 0$ จะถูกจัดเป็นโอกาสการเดิมพันที่มีมูลค่า (Value Bet Opportunity)

3.5 การพัฒนาแบบจำลอง การเปรียบเทียบกับตลาด และระบบทดสอบย้อนหลัง

3.5.1 การคัดเลือกตัวแปร (Feature Selection)

ตัวแปรที่แบบจำลองใช้ได้ถูกกำหนดเป็นรายชื่อกลุ่มที่อนุญาต (Allowlist) แต่ละกลุ่มประกอบด้วยค่าของทั้งสองทีมและผลต่าง ผลลัพธ์หลังจบเกม เช่น ประตูและ xG ของนัดนั้น จึงไม่สามารถรั่วเข้าสู่แบบจำลองได้ การคัดเลือกทำแบบเดินหน้า (Greedy Forward Selection) โดยเริ่มจากกลุ่มคะแนน Elo แล้วเพิ่มกลุ่มที่ลด Log Loss แบบ Walk-forward บนฤดูกาลตรวจสอบ 2021–2023 ได้มากที่สุดทีละกลุ่ม จนไม่มีกลุ่มใดลดได้เกินเกณฑ์ขั้นต่ำ ชุดทดสอบถูกใช้เพียงครั้งเดียวในตอนท้าย เพื่อเปรียบเทียบชุดที่คัดเลือกกับการใช้ Elo อย่างเดียวและการใช้ทุกกลุ่ม

3.5.2 แบบจำลองทำนายผลการแข่งขัน

แบบจำลองทุกแบบใช้ชุดตัวแปรที่คัดเลือกชุดเดียวกัน ปรับมาตรฐานตัวแปรและเติมค่าว่างด้วยค่ามัธยฐานของชุดฝึก ดังนี้

1) **Multinomial Logistic Regression:** แบบจำลองหลัก ทำนายความน่าจะเป็น H/D/A โดยตรง

2) **Logistic Regression + Sigmoid Calibration:** แบบจำลองเดียวกันที่ปรับเทียบความน่าจะเป็นด้วย Sigmoid แบบ 5-fold บนฤดูกาลฝึก

3) **Gradient-boosted Trees:** ใช้ Scikit-learn [5] คลาส `HistGradientBoostingClassifier` เพื่อตรวจว่ามีความสัมพันธ์ไม่เชิงเส้นที่ Logistic Regression จับไม่ได้หรือไม่

4) **Poisson Goals:** Poisson Regression หนึ่งตัวต่อหนึ่งฝั่งสำหรับจำนวนประตู แล้วรวมตารางสกอร์ที่เป็นอิสระต่อกันเป็นความน่าจะเป็น H/D/A ตามแนวคิดของ Dixon และ Coles [8]

นอกจากนี้ยังสร้างเส้นโค้งการเรียนรู้ (Learning Curve) โดยฝึกแต่ละแบบจำลองด้วยนัดล่าสุดจำนวน 250 นัดจนถึงทั้งหมด แล้ววัดผลบนชุดทดสอบเดียวกัน เพื่อดูว่าการเพิ่มข้อมูลยังช่วยหรือไม่ และแบบจำลองจำข้อมูล (Overfitting) หรือไม่

3.5.3 การแบ่งชุดข้อมูลตามลำดับเวลา (Temporal Split)

ประเมินผลโดยแบ่งชุดข้อมูลตามลำดับเวลาจริง (ไม่สุ่ม) ฤดูกาลก่อนปี 2024 เป็นชุดฝึก ฤดูกาล 2021–2023 ใช้ตรวจสอบแบบ Walk-forward ระหว่างคัดเลือกตัวแปร (แต่ละฤดูกาลทำนายจากแบบจำลองที่ฝึกด้วยฤดูกาลก่อนหน้าเท่านั้น) และตั้งแต่ฤดูกาล 2024 เป็นต้น

ไปเป็นชุดทดสอบที่ถูกใช้เพียงครั้งเดียว เพื่อจำลองสถานการณ์ทำนายอนาคตตามจริงและป้องกันปัญหาข้อมูลรั่วไหล

3.5.4 การเปรียบเทียบกับตลาดเดิมพัน (Market Test)

เกณฑ์ที่แบบจำลองต้องเอาชนะคือความน่าจะเป็นจากราคาของ Pinnacle ซึ่งเป็นเจ้ามือที่ราคาแม่นที่สุดในบรรดาที่เผยแพร่ หลังหักส่วนต่างของเจ้ามือด้วยวิธี Power (เปรียบเทียบกับวิธี Proportional และ Shin) โดยใช้ราคา 2 ช่วงเวลา คือ ราคาเปิด (1–2 วันก่อนแข่ง ซึ่งผู้เดิมพันนำไปใช้ได้จริง) และราคาปิด (ณ เวลาเริ่มแข่ง) ผู้ทำนาย 5 แบบ ได้แก่ ราคาเปิด ราคาปิด ราคาเปิดที่ปรับเทียบใหม่ด้วย Logistic Regression ราคาเปิดร่วมกับฟอร์มทีมและฟอร์มทีมอย่างเดียว ถูกวัดผลบนนัดชุดเดียวกัน ด้วย Log Loss และ RPS แล้วเปรียบเทียบเป็นคู่รายนัด (Paired Difference) พร้อมช่วงความเชื่อมั่น 95% แบบจำลองจะถือว่าชนะตลาดก็ต่อเมื่อช่วงความเชื่อมั่นอยู่ต่ำกว่าศูนย์ทั้งหมด

3.5.5 กรอบ การ ทดสอบ ย้อน หลัง และ ชุด กลยุทธ์ (Backtesting Framework)

การประเมินทางการเงินแบ่งเป็น 3 ส่วน ดังนี้

1) **การ ทดสอบ ย้อน หลัง ของ แบบ จำลอง:** ทำนาย แต่ละ ฤดูกาล ตั้งแต่ 2017 ด้วย Logistic Regression แบบ Walk-forward แล้วเลือกผลที่มี EV สูงสุดในแต่ละนัด วางเดิมพัน 1 หน่วยที่ราคาปิดของ Pinnacle เมื่อ EV สูงกว่าเกณฑ์ 0%, 2%, 5%, 10% และ 20%

2) **ชุด กลยุทธ์ ที่ ลง ทะเบียน ล่วง หน้า (Pre-registered Strategy Suite):** กลยุทธ์ 18 กลยุทธ์ (42 รูป แบบ) ถูก เขียน ใน ไฟล์ `strategies.toml` และ บันทึก เข้า Git ก่อน รัน กับ ข้อมูล ครอบคลุมกลยุทธ์พื้นฐาน (แทงทีมต่อ ทีมรอง ช่วงราคา และผลเดิมทุกนัด) กลยุทธ์ตามแบบจำลอง (Model EV และ Model Draw) และ Value Betting ที่ราคาดีที่สุดเทียบกับ Pinnacle [12] ในตลาด 1X2, Asian Handicap และ Over/Under 2.5 แต่ละกลยุทธ์วัด ROI และกำไรคาดหมาย ณ ราคาปิด ($p_{close} \times \text{Odds} - 1$) พร้อมช่วงความเชื่อมั่น 95% แยกรายลีก แล้วปรับแก้ p-value ของทั้ง 252 ช่องด้วยวิธี Benjamini–Hochberg [13] และทดสอบการเลือกพารามิเตอร์แต่ละฤดูกาลจากฤดูกาลก่อนหน้าเท่านั้น

3) **การบริหารเงินทุน (Staking):** เล่นซ้ำเดิมพันของกลยุทธ์ตัวแทนตามลำดับวันที่ ด้วยแผนวางเงิน 5 แบบ ได้แก่ Flat (1% ของทุนเริ่มต้น), Kelly, Half Kelly, Quarter Kelly และ Martingale วัดเงินทุนสุดท้ายและ Maximum Drawdown แล้วสุ่มเดิมพันแบบ Bootstrap สร้างประวัติจำลอง 1,000 ชุด เพื่อวัดโอกาสเสียเงินทุนครึ่งหนึ่งและร้อยละ 90

สุดท้ายประเมินความเป็นไปได้ในทางปฏิบัติของกลยุทธ์ที่มีความได้เปรียบ ได้แก่ จำนวนฤดูกาลที่ต้องใช้กว่าความได้เปรียบจะปรากฏเป็นกำไร การจำลองการปิดบัญชีของเจ้ามือ และผลตอบแทนบน Betfair Exchange หลังหักค่าคอมมิชชัน

3.5.6 การทดสอบสมมติฐานทางสถิติ

ทดสอบข้อสังเกตเชิงปริมาณด้วยระดับนัยสำคัญ 0.05 บนข้อมูลพรีเมียร์ลีกฤดูกาล 2000–2001 ถึง 2024–2025 ซึ่งยาวกว่าช่วงข้อมูลหลักเพื่อให้มีจำนวนนัดมากพอ (ตัดนัดใน 28 วันแรกของแต่ละฤดูกาล) ได้แก่ (1) ทดสอบความได้เปรียบของทีมเจ้าบ้านด้วย Paired t-test และ Wilcoxon Signed-rank Test แบบทางเดียว และ (2) ทดสอบความสัมพันธ์ระหว่างผลต่างคะแนน Elo กับผลต่างประตูด้วยสัมประสิทธิ์สหสัมพันธ์ของ Pearson และ Spearman

3.6 การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance Framework)

3.6.1 การทดสอบซอฟต์แวร์อัตโนมัติ (Automated Testing)

จัดทำชุดทดสอบอัตโนมัติด้วย Pytest ครอบคลุมการคำนวณ Elo, ดัชนีความเหนื่อยล้า, ตัวแปรตารางแข่ง, การแปลงชื่อสโมสร, การตรวจสอบ Schema, การคำนวณ +EV, ระบบ Backtesting และบริการ API โดยใช้ Hypothesis สำหรับการทดสอบเชิงคุณสมบัติ (Property-based Testing)

3.6.2 การตรวจสอบคุณภาพโค้ดและการเผยแพร่

ใช้ Ruff ตรวจสอบรูปแบบโค้ด Pyright ตรวจสอบชนิดข้อมูล pre-commit ตรวจสอบก่อนบันทึกโค้ด และ GitHub Actions สำหรับรันการตรวจสอบและชุดทดสอบอัตโนมัติทุกครั้งที่มีการส่งโค้ดขึ้นระบบ พร้อมรองรับการใช้งานผ่าน Docker สภาพแวดล้อมเสมือน

บทที่ 4
ผลการดำเนินงาน

บทนี้เสนอผลการดำเนินงานตามลำดับของกระบวนการวิทยาการข้อมูล ได้แก่ ผลการทดสอบสมมติฐานทางสถิติ ผลการสำรวจและคัดเลือกตัวแปร ผลการประเมินแบบจำลองทำนายผล ผลการทดสอบย้อนหลังของแบบจำลอง ผลการเปรียบเทียบกับตลาดเดิมพันและชุดกลยุทธ์ที่ลงทะเบียนไว้ล่วงหน้า ผลของกลยุทธ์การบริหารเงินทุน และความเป็นไปได้ในการนำไปใช้จริง ตัวเลขทุกค่าในบทนี้ได้จากการรันโค้ดของโครงงานบนข้อมูลจริง และสามารถสร้างซ้ำได้จากรหัสคอมมิตที่ระบุไว้ในรายงาน

4.1 ผลการทดสอบสมมติฐานทางสถิติ

การทดสอบในหัวข้อนี้ใช้ข้อมูลพรีเมียร์ลีกอังกฤษตั้งแต่ฤดูกาล 2000–2001 ถึง 2024–2025 ที่มีคะแนน Elo ก่อนแข่งครบทั้งสองทีม โดยตัดนัดในช่วง 28 วันแรกของแต่ละฤดูกาลออก เนื่องจากคะแนน Elo ของทีมที่เลื่อนชั้นยังไม่เข้าที่ คงเหลือ 8,469 นัด จากทั้งหมด 9,380 นัด และใช้ระดับนัยสำคัญ $\alpha = 0.05$

4.1.1 ความได้เปรียบของการเป็นเจ้าบ้าน (Home Advantage)

กำหนดสมมติฐาน $H_0 : \mu_d = 0$ และ $H_1 : \mu_d > 0$ เมื่อ μ_d คือค่าเฉลี่ยของผลต่างประตู (ประตูเจ้าบ้าน $-$ ประตูทีมเยือน) ต่อนัด ผลการทดสอบแสดงดังตารางที่ 3

ตารางที่ 3 ผลการทดสอบความได้เปรียบของทีมเจ้าบ้าน (พรีเมียร์ลีก 8,469 นัด)

รายการ	**ค่าที่ได้**
ค่าเฉลี่ยประตูทีมเจ้าบ้านต่อนัด	1.541
ค่าเฉลี่ยประตูทีมเยือนต่อนัด	1.179
ผลต่างเฉลี่ย ($\bar{d}$)	$+0.362$
Paired t-test (one-sided)	$t = 18.35$, $p = 4.39 \times 10^{-74}$
Wilcoxon Signed-rank Test (one-sided)	$p = 3.75 \times 10^{-75}$

ทั้งสองวิธีปฏิเสธ H_0 ที่ระดับนัยสำคัญ 0.05 ทีมเจ้าบ้านทำประตูได้มากกว่าทีมเยือนเฉลี่ย 0.362 ประตูต่อนัด ผลนี้สนับสนุนการกำหนดค่าความได้เปรียบของเจ้าบ้าน ($h = 40$ คะแนน) ในระบบ Elo Rating ตามที่อธิบายไว้ในบทที่ 3

4.1.2 ความสัมพันธ์ระหว่างผลต่างคะแนน Elo กับผลต่างประตู

กำหนดสมมติฐาน $H_0 : \beta = 0$ (ผลต่างคะแนน Elo ไม่มีความสัมพันธ์เชิงเส้นกับผลต่างประตู) และ $H_1 : \beta \neq 0$ ผลการวิเคราะห์บนชุดข้อมูลเดียวกันพบว่า

- สัมประสิทธิ์สหสัมพันธ์ของ Pearson $r = 0.441$ และของ Spearman $\rho = 0.429$ โดย p-value ของทั้งสองค่าต่ำกว่าความละเอียดของการ

คำนวณ ($p \approx 0$) จึงปฏิเสธ H_0 ผลต่างคะแนน Elo มีความสัมพันธ์เชิงบวกระดับปานกลางกับผลต่างประตู

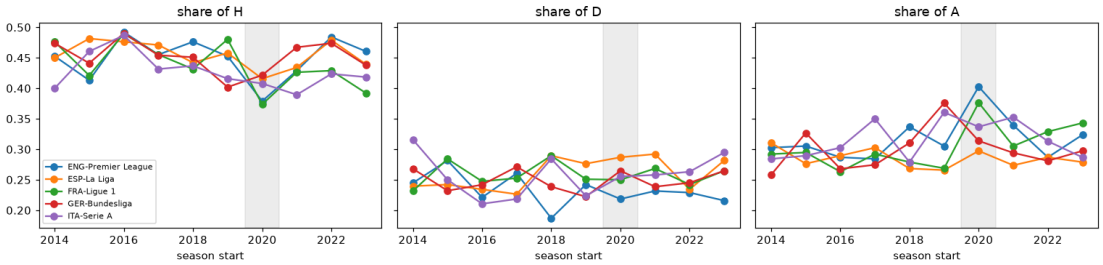
- ในกลุ่มนัดที่สองทีมมีคะแนนใกล้เคียงกัน ($|\Delta R| < 25$) จำนวน 1,406 นัด ทีมเจ้าบ้านยังมีผลต่างประตูเฉลี่ย $+0.394$ ประตู ($t = 9.20$, $p = 1.2 \times 10^{-19}$) แสดงว่าความได้เปรียบของเจ้าบ้านยังคงอยู่แม้ความแข็งแกร่งของสองทีมเท่ากัน

4.2 ผลการสำรวจและคัดเลือกตัวแปร

ตารางตัวแปรรายนัด (`match_features`) ของ 5 ลีกมี 21,882 นัด และตัวแปรก่อนแข่ง 140 คอลัมน์ ผลลัพธ์หลังจบเกม เช่น ประตูและ xG ของนัดนั้น ถูกกันออกจากรายชื่อตัวแปรที่อนุญาต (Allowlist) จึงไม่สามารถรั่วเข้าสู่แบบจำลองได้ การสำรวจใช้เฉพาะชุดฝึก (18,085 นัด 10 ฤดูกาล) โดยไม่เปิดดูชุดทดสอบ 3,797 นัด

4.2.1 สัดส่วนผลการแข่งขันในแต่ละฤดูกาล

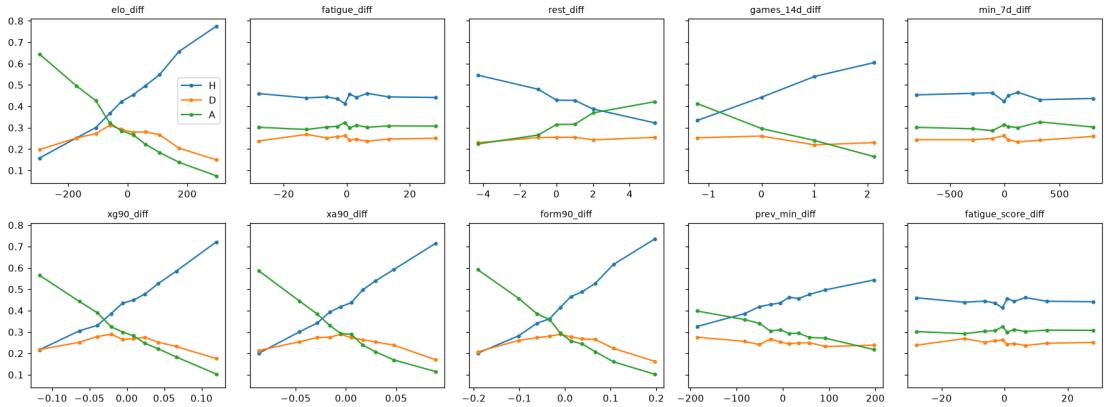
ภาพที่ 4 แสดงสัดส่วนเจ้าบ้านชนะ (H) เสมอ (D) และทีมเยือนชนะ (A) ของแต่ละลีกในชุดฝึก เจ้าบ้านชนะประมาณร้อยละ 39–49 ในฤดูกาลปกติ ยกเว้นฤดูกาล 2020–2021 (แถบสีเทา) ที่แข่งขันโดยไม่มีผู้ชมเนื่องจากการระบาดของ COVID-19 สัดส่วนเจ้าบ้านชนะลดลงเหลือร้อยละ 37–42 และในพรีเมียร์ลีกทีมเยือนชนะ (ร้อยละ 40.3) มากกว่าเจ้าบ้านชนะ (ร้อยละ 37.9) สัดส่วนผลจึงเปลี่ยนไปตามฤดูกาลและลีก การทายจากสัดส่วนผล (Class Prior) ที่ใช้เป็นเกณฑ์ขั้นต่ำจึงคำนวณจากฤดูกาลก่อนหน้าเท่านั้น



ภาพที่ 4 สัดส่วนผล H/D/A ของแต่ละลีกตามฤดูกาล (ชุดฝึก แถบสีเทาคือฤดูกาล 2020–2021)

4.2.2 ความสัมพันธ์ของตัวแปรแต่ละตัวกับผลการแข่งขัน

ภาพที่ 5 แบ่งตัวแปรผลต่าง (ทีมเจ้าบ้าน − ทีมเยือน) แต่ละตัวออกเป็น 10 ช่วงเท่ากัน แล้วแสดงสัดส่วนเจ้าบ้านชนะ (H) เสมอ (D) และทีมเยือนชนะ (A) ในแต่ละช่วง เส้นที่ชันแสดงว่าตัวแปรนั้นเปลี่ยนโอกาสของผลการแข่งขัน ส่วนเส้นที่แบนแสดงว่าตัวแปรนั้นแทบไม่บอกอะไร

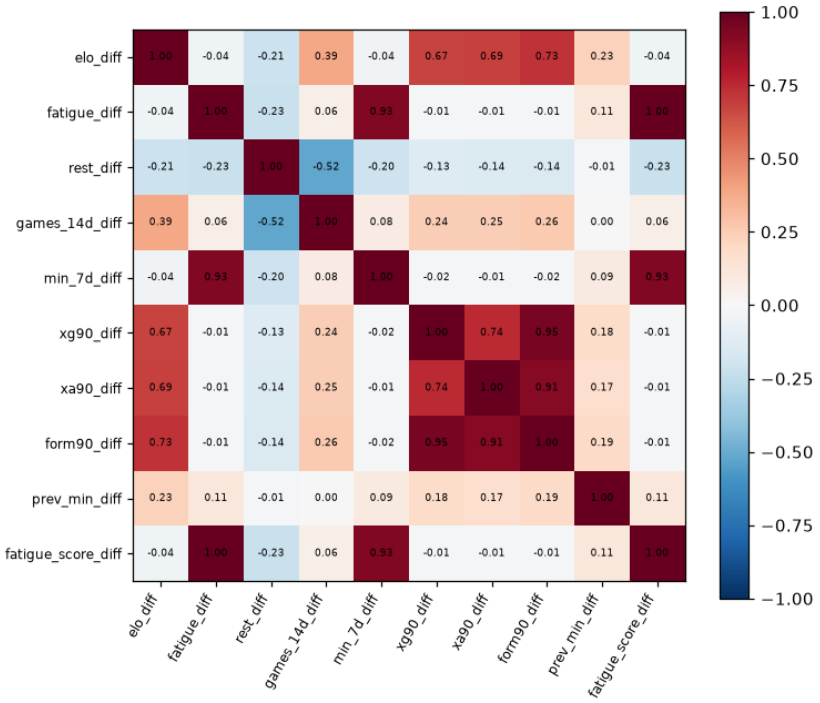


ภาพที่ 5 สัดส่วนผล H/D/A ตามช่วงเดไซล์ของตัวแปรผลต่างก่อนแข่งแต่ละตัว (ชุดฝึก)

ผลต่างคะแนน Elo ให้ความชันมากที่สุด โอกาสเจ้าบ้านชนะเปลี่ยนจากประมาณ 0.16 ในช่วงต่ำสุดเป็น 0.78 ในช่วงสูงสุด (ช่วงห่าง 0.62) ตามด้วยฟอร์มผู้เล่นตัวจริง `form90` (0.53) `xa90` (0.51) และ `xg90` (0.50) ในทางกลับกัน ดัชนีความเหนื่อยล้า (`fatigue_diff`) และนาทีที่ลงเล่นใน 7 วัน (`min_7d_diff`) ให้เส้นเกือบแบน (ช่วงห่างไม่ถึง 0.05)

4.2.3 ความซ้ำซ้อนระหว่างตัวแปร

ภาพที่ 6 แสดงค่าสหสัมพันธ์ระหว่างตัวแปรหลักบน 16,242 นัดที่มีครบทุกตัว พบว่า `fatigue_score_diff` กับ `fatigue_diff` เป็นตัวแปรเดียวกัน ($r = 1.00$) `fatigue_diff` กับ `min_7d_diff` เคลื่อนไหวไปด้วยกัน ($r = 0.93$) และ `form90_diff` ครอบคลุมทั้ง `xg90_diff` ($r = 0.95$) และ `xa90_diff` ($r = 0.91$) จึงควรเลือกใช้เพียงตัวเดียวในแต่ละกลุ่ม นอกจากนี้ `form90_diff` มีสหสัมพันธ์กับ `elo_diff` สูงถึง 0.73



ภาพที่ 6 เมทริกซ์สหสัมพันธ์ของตัวแปรผลต่างหลัก (16,242 นัด)

เพื่อตรวจว่าตัวแปรอื่นให้ข้อมูลเพิ่มจากคะแนน Elo จริงหรือไม่ ได้เปรียบเทียบ Logistic Regression ที่ใช้ `elo_diff` อย่างเดียว (Log Loss 0.9740) กับที่เพิ่มตัวแปรครั้งละหนึ่งตัว โดยฝึกด้วยฤดูกาล 2015–2022 และวัดผลบนฤดูกาล 2023 ของชุดฝึก (ใช้เฉพาะนัดที่มีค่าครบทั้งสองตัวแปร ประมาณ 16,250 นัด) ค่าในตารางนี้จึงไม่ใช่ค่าเดียวกับ Log Loss แบบ Walk-forward ในตารางที่ 5 ผลแสดงดังตารางที่ 4

ตารางที่ 4 Log Loss บนฤดูกาล 2023 ที่ลดลงเมื่อเพิ่มตัวแปรหนึ่งตัวเข้าไปในแบบจำลองที่มีคะแนน Elo อยู่แล้ว

ตัวแปรที่เพิ่ม	Log Loss (Elo + ตัวแปร)	ส่วนที่ลดลง
`form90_diff`	0.97002	+0.00395
`xa90_diff`	0.97010	+0.00387
`xg90_diff`	0.97161	+0.00236
`games_14d_diff`	0.97401	−0.00006
`rest_diff`	0.97405	−0.00009
`fatigue_diff`	0.97411	−0.00015
`prev_min_diff`	0.97419	−0.00023
`min_7d_diff`	0.97437	−0.00041

มีเพียงฟอร์มผู้เล่นตัวจริงเท่านั้นที่ช่วยลด Log Loss ได้เมื่อมีคะแนน Elo อยู่แล้ว ตัวแปรด้านความเหนื่อยล้าและตารางแข่งในรูปผลต่าง กลับทำให้แบบจำลองแย่ลงเล็กน้อย ส่วนหนึ่งเป็นเพราะสโมสรใหญ่ที่มีคะแนน Elo สูงมักเป็นทีมที่ลงแข่งรายการยุโรปและมีตารางแข่งหนาแน่น ข้อมูลตารางแข่งจึงซ้ำกับสิ่งที่ Elo บอกอยู่แล้ว

4.2.4 การคัดเลือกตัวแปรแบบเดินหน้า (Forward Selection)

การคัดเลือกตัวแปรขั้นสุดท้ายทำบนตารางสำหรับฝึกแบบจำลอง 20,054 นัด และ 18 กลุ่มตัวแปร โดยเริ่มจากคะแนน Elo แล้วเพิ่มกลุ่มที่ลด Log Loss แบบ Walk-forward บนฤดูกาล 2021–2023 ได้มากที่สุดทีละกลุ่ม จนไม่มีกลุ่มใดลดได้เกินเกณฑ์ขั้นต่ำ ผลแสดงดังตารางที่ 5

ตารางที่ 5 ผลการคัดเลือกกลุ่มตัวแปรแบบเดินหน้า (Walk-forward Log Loss ฤดูกาล 2021–2023)

ลำดับ	กลุ่มตัวแปรที่เพิ่ม	ความหมาย	Log Loss	ส่วนที่ลดลง
1	`elo`	คะแนน Elo ก่อนแข่ง	0.9842	–
2	`player_form90`	ฟอร์มผู้เล่นตัวจริงต่อ 90 นาที	0.9828	0.0014
3	`games_14d_all`	จำนวนนัดทุกรายการใน 14 วัน	0.9818	0.0010
4	`player_prev_min`	นาทีที่ผู้เล่นตัวจริงลงเล่นก่อนหน้า	0.9811	0.0007

เมื่อนำไปวัดผลครั้งเดียวบนชุดทดสอบตั้งแต่ฤดูกาล 2024 ได้ผลดังตารางที่ 6 ชุดตัวแปรที่คัดเลือกดีกว่าการใช้ Elo อย่างเดียว และดีกว่าการใส่ทุกกลุ่มตัวแปร ซึ่งยืนยันว่ากลุ่มที่ไม่ถูกเลือก (รวมถึงดัชนีความเหนื่อยล้า วันพัก และแผนการเล่น) เพิ่มแต่สัญญาณรบกวน

ตารางที่ 6 Log Loss บนชุดทดสอบ (ฤดูกาล 2024 เป็นต้นไป) ตามชุดตัวแปร

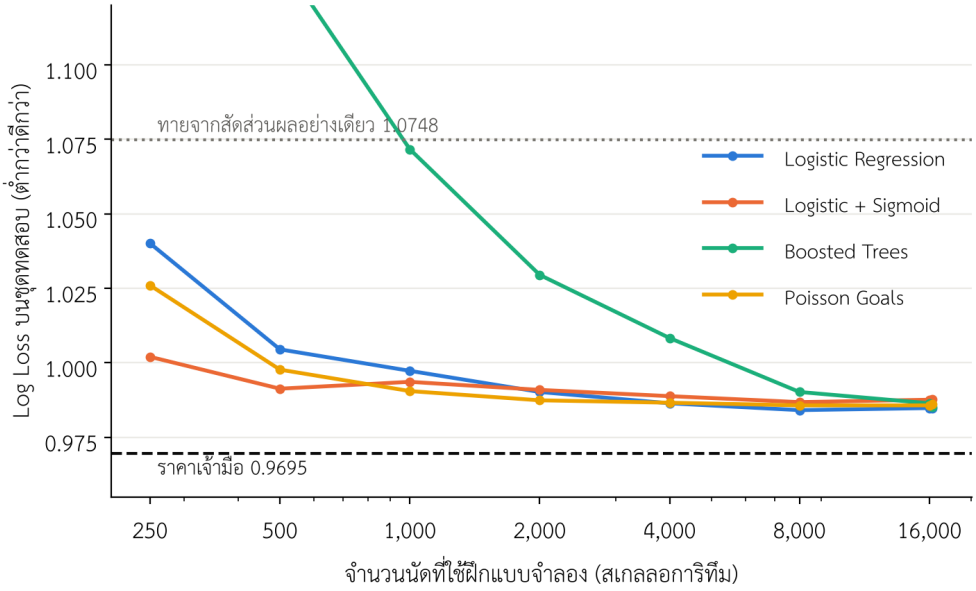
ชุดตัวแปร	Log Loss ↓
ทายจากสัดส่วนผลอย่างเดียว (Class Prior)	1.0745
คะแนน Elo อย่างเดียว	0.9876
ชุดตัวแปรที่คัดเลือก (4 กลุ่ม)	**0.9841**
ทุกกลุ่มตัวแปร (18 กลุ่ม)	0.9865

4.3 ผลการประเมินประสิทธิภาพของแบบจำลอง

แบบจำลองทั้ง 4 แบบใช้ชุดตัวแปรที่คัดเลือกชุดเดียวกัน ได้แก่ Logistic Regression แบบหลายกลุ่ม (Multinomial), Logistic Regression ที่ปรับเทียบความน่าจะเป็นด้วย Sigmoid, Gradient-boosted Trees และแบบจำลองจำนวนประตู Poisson (Poisson Regression หนึ่งตัวต่อหนึ่งฝั่ง แล้วรวมตารางสกอร์เป็นความน่าจะเป็น H/D/A) ทุกแบบจำลองฝึกด้วยข้อมูลก่อนฤดูกาล 2024 (16,258 นัด) และวัดผลบนชุดทดสอบ 3,749 นัดชุดเดียวกัน ซึ่งคือนัดทดสอบ 3,796 นัดของตารางสำหรับฝึกแบบจำลอง (20,054 นัด) หลังตัด 47 นัดที่ไม่มีราคาต่อรอง เพื่อให้วัดราคาเจ้ามือบนนัดชุดเดียวกันได้ ค่า Log Loss ของการทายจากสัดส่วนผลจึงต่างจากตารางที่ 6 เล็กน้อย (1.0748 เทียบกับ 1.0745)

4.3.1 เส้นโค้งการเรียนรู้ (Learning Curve)

ภาพที่ 7 แสดง Log Loss บนชุดทดสอบเมื่อฝึกด้วยนัดล่าสุดจำนวนต่าง ๆ ตั้งแต่ 250 นัดจนถึงทั้งหมด 16,258 นัด เส้นประด้านบนคือการทายจากสัดส่วนผลอย่างเดียว (1.0748) และเส้นประด้านล่างคือความน่าจะเป็นจากราคาเจ้ามือบนนัดชุดเดียวกัน (0.9695)



ภาพที่ 7 Log Loss บนชุดทดสอบเทียบกับจำนวนนัดที่ใช้ฝึกของแบบจำลองทั้ง 4 แบบ

ผลที่สำคัญมีดังนี้

1) Logistic Regression ให้ผลดีที่สุดที่ 0.9841 ($\pm$0.0078) เมื่อฝึกด้วย 8,000 นัด และ 0.9848 เมื่อฝึกด้วยทุกนัด เส้นแบนตั้งแต่ประมาณ 4,000 นัด การเพิ่มข้อมูลเท่าตัวในรอบสุดท้ายไม่ช่วยลด Log Loss เลย

2) เมื่อฝึกด้วยทุกนัด Log Loss บนชุดฝึก (0.9791) กับชุดทดสอบ (0.9848) ห่างกันเพียง 0.0058 แสดงว่าแบบจำลองไม่ได้จำข้อมูล (Overfitting) แต่เรียนรู้ได้เต็มที่เท่าที่ชุดตัวแปรนี้ให้ได้แล้ว

3) Gradient-boosted Trees ต้องการข้อมูลมากที่สุด ที่ 250 นัดได้ Log Loss 1.2606 ซึ่งแย่กว่าการทายจากสัดส่วนผล และไล่ตาม Logistic Regression ได้เมื่อใช้ข้อมูลทั้งหมดเท่านั้น

4) Logistic Regression ที่ฝึกด้วยทุกนัด (0.9848) ยังด้อยกว่าราคาเจ้ามือ (0.9695) อยู่ 0.0153 (และ 0.0146 แม้ที่จุดดีที่สุด 8,000 นัด) ซึ่งมากกว่าช่วงความคลาดเคลื่อนมาตรฐาน หมายความว่าข้อมูลสาธารณะชุดนี้ไม่พอให้ทำนายได้แม่นเท่าตลาด

4.3.2 เปรียบเทียบตัวชี้วัดหลายมิติ

ตารางที่ 7 สรุปผลเมื่อฝึกด้วยข้อมูลทั้งหมดก่อนฤดูกาล 2024 พร้อม RPS, Brier Score และ Accuracy จาก `notebooks/model_comparison.ipynb`

ความแตกต่างระหว่างแบบจำลองทั้ง 4 แบบน้อยกว่าช่วงความคลาดเคลื่อนมาตรฐาน ($\approx$ 0.008) แต่ Logistic Regression ดีที่สุดหรือใกล้เคียงที่สุดในทุกตัวชี้วัด และเรียบ

ตารางที่ 7 ประสิทธิภาพของแบบจำลองบนชุดทดสอบ (ฤดูกาล 2024 เป็นต้นไป)

แบบจำลอง	Log Loss[a] ↓	Log Loss[b] ↓	RPS[b] ↓	Brier[b] ↓	Accuracy[b] ↑
ทายจากสัดส่วนผล (Class Prior)	1.0748	1.0725	–	–	–
Logistic Regression	**0.9848**	**0.9855**	0.2005	**0.5875**	**52.41%**
Poisson Goals	0.9861	0.9865	**0.2004**	0.5880	52.18%
Gradient-boosted Trees	0.9851	0.9876	0.2010	0.5886	51.98%
Logistic + Sigmoid	0.9877	0.9877	0.2007	0.5888	52.41%
ราคาเจ้ามือ (อ้างอิง)	0.9695	–	–	–	–

[a] จาก `uv run learning_curve` (3,749 นัด) [b] จาก `model_comparison.ipynb` (รันก่อนหน้าบนข้อมูลชุดเดิม จึงต่างจาก [a] เล็กน้อย)

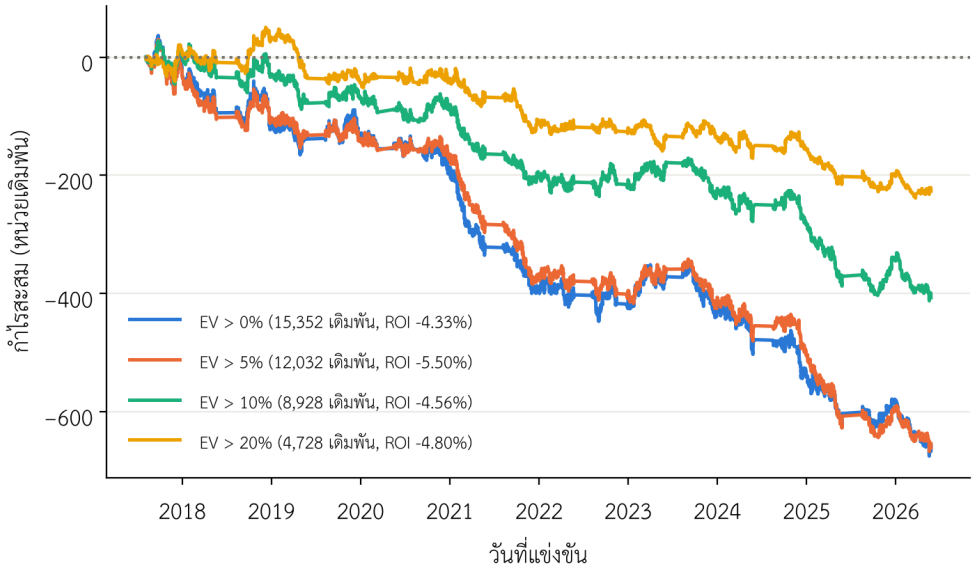
ง่ายที่สุด จึงถูกเลือกเป็นแบบจำลองหลักสำหรับการทดสอบย้อนหลังและการทำนายนัดที่กำลังจะมาถึง Gradient Boosting ซึ่งนำมาเพื่อตรวจหาความสัมพันธ์ไม่เชิงเส้น (บทที่ 3) ไม่ได้ให้ผลดีกว่า แสดงว่าสัญญาณของตัวแปรส่วนใหญ่เป็นเชิงเส้น และเมื่อข้อมูลฝึกมีน้อย Gradient Boosting จะเรียนรู้สัญญาณรบกวนจนแย่กว่าการทายจากสัดส่วนผล (ภาพที่ 7) นอกจากนี้ Accuracy ที่ 52.41% สูงกว่าช่วง 47.84–48.60% ของแบบจำลองที่ใช้เพียงผลสกอร์ย้อนหลังที่ Hubáček และคณะ [1] รายงานไว้ (คนละชุดข้อมูล จึงเทียบได้เพียงคร่าว ๆ) แต่ต่ำกว่าการทายทีมต่อตามราคาปิดของ Pinnacle ซึ่งถูก 54.1% ของนัดฤดูกาล 2024–2025 ในการทดสอบย้อนหลัง (3,503 นัด)

4.4 ผลการทดสอบย้อนหลังของแบบจำลอง (Model Backtest)

การทดสอบย้อนหลังทำนายแต่ละฤดูกาลตั้งแต่ 2017–2018 ถึง 2025–2026 ด้วย Logistic Regression ที่ฝึกจากฤดูกาลก่อนหน้าเท่านั้น (Walk-forward) รวม 16,110 นัด (ไม่รวมนัดของฤดูกาล 2026–2027 ที่เริ่มแข่งแล้ว) แต่ละนัดเลือกผลที่มีค่าคาดหมายสูงสุด $EV = p \times \text{Odds} - 1$ แล้ววางเดิมพัน 1 หน่วยที่ราคาปิดของ Pinnacle เมื่อ EV สูงกว่าเกณฑ์ ผลแสดงดังตารางที่ 8 และภาพที่ 8

ตารางที่ 8 ผลการวางเดิมพันตามแบบจำลองที่เกณฑ์ EV ต่าง ๆ (ฤดูกาล 2017–2025, เดิมพันละ 1 หน่วย)

เกณฑ์ EV	จำนวนเดิมพัน	อัตราชนะ	กำไรสุทธิ (หน่วย)	ROI
$> 0\%$	15,352	34.5%	-665.2	-4.33%
$> 2\%$	14,127	33.7%	-661.0	-4.68%
$> 5\%$	12,032	32.2%	-661.3	-5.50%
$> 10\%$	8,928	30.5%	-407.2	-4.56%
$> 20\%$	4,728	26.5%	-226.7	-4.80%



ภาพที่ 8 กำไรสะสมจากการวางเดิมพันตามแบบจำลองที่เกณฑ์ EV ต่าง ๆ

ทุกเกณฑ์ขาดทุนในอัตราใกล้เคียงกันประมาณ 4–5.5% การเพิ่มเกณฑ์ EV ไม่ได้ทำให้ผลดีขึ้น แสดงว่า EV ที่สูงตามแบบจำลองส่วนใหญ่มาจากความคลาดเคลื่อนของแบบจำลองเอง ไม่ใช่ความผิดพลาดของตลาด เมื่อแยกรายฤดูกาล มีเพียงฤดูกาล 2022 ที่ได้กำไร ($+30.7$ หน่วย, ROI $+1.74\%$) ส่วนอีก 8 ฤดูกาลขาดทุน และเมื่อแยกรายลีก มีเพียงบุนเดสลีกาที่ ROI เป็นบวกเล็กน้อย ($+0.49\%$ จาก 2,640 เดิมพัน) ซึ่งอยู่ในช่วงที่เกิดได้จากความบังเอิญ

4.5 ผลการเปรียบเทียบกับตลาดเดิมพัน

เนื่องจากแบบจำลองที่ใช้ข้อมูลทีมอย่างเดียวด้อยกว่าราคาตลาด การวิเคราะห์ส่วนนี้จึงตั้งคำถามที่เข้มงวดขึ้น คือ ถ้าเริ่มจากราคาตลาดแล้วเพิ่มข้อมูลทีมเข้าไป จะทำนายได้ดีกว่าตลาดหรือไม่ โดยใช้ข้อมูลจาก Football-Data.co.uk 20,712 นัดของ 5 ลีก ฤดูกาล 2014–2015 ถึง 2025–2026 และวัดผล 17,063 นัดตั้งแต่ฤดูกาล 2016–2017 ทุกฤดูกาลทำนายจากฤดูกาลก่อนหน้าเท่านั้น ผลแสดงดังตารางที่ 9 และ 10

ตารางที่ 9 คะแนนเฉลี่ยของผู้ทำนายแต่ละแบบบนนัดชุดเดียวกัน 17,063 นัด

ผู้ทำนาย (Forecaster)	**Log Loss ↓**	**RPS ↓**
ราคาปิดของ Pinnacle (Closing Price)	**0.9608**	**0.1932**
ราคาเปิดของ Pinnacle (Early Price)	0.9632	0.1938
ราคาเปิดที่ปรับเทียบใหม่ (Recalibrated)	0.9637	0.1940
ราคาเปิด + ฟอร์มทีม	0.9641	0.1940
ฟอร์มทีมอย่างเดียว	0.9805	0.1989

ผลสรุปได้ว่า

1) **ไม่มีแบบจำลองใดทำนายได้ดีกว่าตลาด:** การเพิ่มฟอร์มทีมเข้าไปในราคาเปิดทำให้ Log Loss เปลี่ยนไป $+0.0008$ และช่วงความเชื่อมั่นคร่อมศูนย์ ข้อมูลทีม

ตารางที่ 10 ผลต่าง Log Loss แบบจับคู่รายนัด (ค่าติดลบหมายถึงผู้ทำนายตัวแรกดีกว่า)

การเปรียบเทียบ	ผลต่าง	ช่วงความเชื่อมั่น 95%
ราคาปิด เทียบ ราคาเปิด	-0.0024	-0.0035 ถึง -0.0013
ราคาเปิดที่ปรับเทียบใหม่ เทียบ ราคาเปิด	$+0.0005$	$+0.0000$ ถึง $+0.0009$
ราคาเปิด + ฟอร์มทีม เทียบ ราคาเปิด	$+0.0008$	-0.0001 ถึง $+0.0017$
ราคาเปิด + ฟอร์มทีม เทียบ ราคาปิด	$+0.0032$	$+0.0018$ ถึง $+0.0046$
ฟอร์มทีมอย่างเดียว เทียบ ราคาปิด	$+0.0197$	$+0.0169$ ถึง $+0.0224$

ที่ใช้จึงไม่ได้เพิ่มสิ่งที่ตลาดยังไม่รู้ ผลนี้เหมือนกันในทั้ง 5 ลีก (ผลต่างอยู่ระหว่าง $+0.0001$ ถึง $+0.0019$)

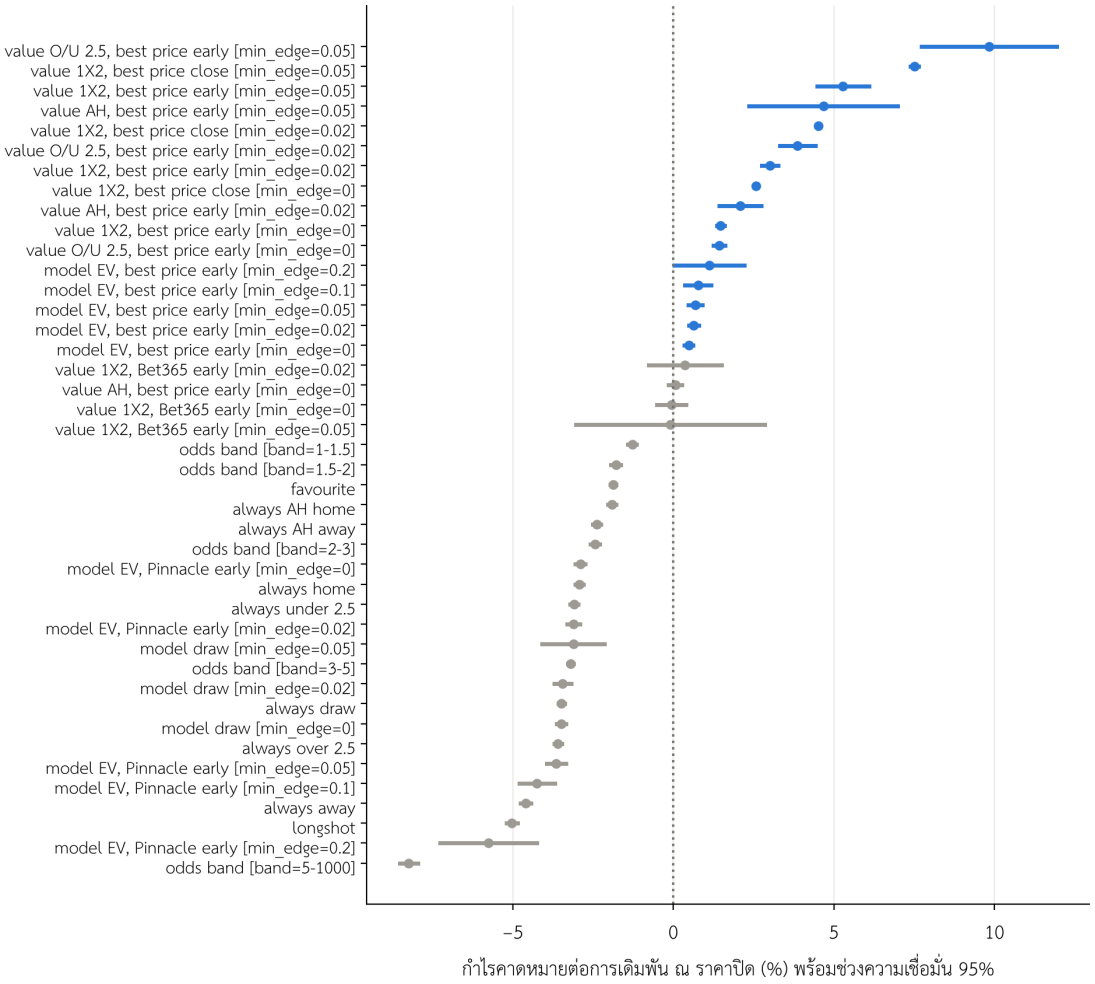
2) **ราคาตลาดแทบไม่มีความเอนเอียงที่ใช้ประโยชน์ได้:** การปรับเทียบราคาเปิดใหม่ด้วย Logistic Regression ทำให้แย่ลงเล็กน้อย

3) **ราคาปิดแม่นที่สุด:** ราคาปิดดีกว่าราคาเปิดอย่างมีนัยสำคัญ เนื่องจากรวมข้อมูลทุกอย่างที่ทราบจนถึงเวลาเริ่มแข่ง เช่น รายชื่อตัวจริงและข่าวบาดเจ็บ ราคาปิดจึงเป็นเกณฑ์ที่ใช้วัดว่าการเดิมพันมีความได้เปรียบจริงหรือไม่

4) **วิธีหักส่วนต่างของเจ้ามือแทบไม่มีผล:** วิธี Proportional, Power และ Shin ให้ Log Loss ต่างกันไม่เกิน 0.0003 โครงงานจึงใช้วิธี Power

4.6 ผลการทดสอบชุดกลยุทธ์การเดิมพัน

ชุด กลยุทธ์ 18 กลยุทธ์ (42 รูป แบบ เมื่อ นับ พารามิเตอร์) ถูก เขียน ลง ไฟล์ `strategies.toml` และ บันทึก เข้า Git ก่อน รัน กับ ข้อมูล จริง (คอม มิต **1521070**) เพื่อป้องกันการปรับกลยุทธ์หลังเห็นผล ทุกกลยุทธ์วางเดิมพันละ 1 หน่วยตั้งแต่ฤดูกาล 2016–2017 และวัดผล 2 แบบ คือ ROI ที่เกิดขึ้นจริง และกำไรคาดหมาย ณ ราคาปิด (Expected Profit at Close) ซึ่งคำนวณจากความน่าจะเป็นของราคาปิดคูณราคาที่วางเดิมพัน ค่าหลังมีความแปรปรวนต่ำกว่า ROI มาก เพราะไม่ต้องรอผลการแข่งขัน ผลการทดสอบทั้ง 252 ช่อง (กลยุทธ์ $\times$ ลีก) ถูกปรับแก้การทดสอบหลายครั้งด้วยวิธี Benjamini–Hochberg [13]



ภาพที่ 9 กำไรคาดหมายต่อการเดิมพัน ณ ราคาปิด พร้อมช่วงความเชื่อมั่น 95% ของทุกกลยุทธ์ (รวม 5 ลีก) สีน้ำเงินคือกลยุทธ์ที่ช่วงทั้งหมดอยู่เหนือศูนย์

ผลจากภาพที่ 9 และตารางที่ 11 สรุปได้ดังนี้

1) **ไม่มีกลยุทธ์ใดผ่านการปรับแก้การทดสอบหลายครั้ง:** จาก 252 ช่อง ไม่มีช่องใดมีค่า q-value ต่ำกว่า 0.05 (ทุกช่องมีค่า $q \approx 1.00$) ROI ที่เป็นบวกทุกค่าจึงอธิบายได้ด้วยความบังเอิญ

2) **กลยุทธ์ง่าย ๆ ขาดทุนตามส่วนต่างของเจ้ามือ:** ROI อยู่ระหว่าง -7.0% ถึง -1.1% โดยการแทงทีมรองขาดทุนมากที่สุด สอดคล้องกับปรากฏการณ์ Favourite–Longshot Bias

3) **แบบจำลองไม่มีความได้เปรียบที่ราคา Pinnacle:** เมื่อวางเดิมพันที่ราคาเดียวกับตลาดที่แบบจำลองใช้ กำไรคาดหมาย ณ ราคาปิดติดลบทุกเกณฑ์ (-2.9% ถึง -5.8%) ส่วนเวอร์ชันที่ราคาดีที่สุดมีกำไรคาดหมายบวกเล็กน้อย ($+0.5\%$ ถึง $+1.1\%$) ซึ่งมาจากการเลือกราคา ไม่ใช่จากแบบจำลอง

ตารางที่ 11 ผลของกลยุทธ์ที่สำคัญ (รวม 5 ลีก ฤดูกาล 2016–2025)

กลยุทธ์	เดิมพัน	ROI (ช่วง 95%)	กำไรคาดหมาย ณ ราคาปิด
กลยุทธ์พื้นฐาน (ราคาเปิดของ Pinnacle)			
แทงทีมต่อ (Favourite)	17,088	-1.1% (-2.5% ถึง $+0.4\%$)	-1.9%
แทงทีมรอง (Longshot)	17,125	-7.0% (-10.1% ถึง -3.8%)	-5.0%
แทงเจ้าบ้านทุกนัด	17,063	-4.2% (-6.3% ถึง -2.2%)	-2.9%
แทงเสมอทุกนัด	17,063	-2.4% (-5.0% ถึง $+0.3\%$)	-3.5%
แทงทีมเยือนทุกนัด	17,063	-5.8% (-8.5% ถึง -3.0%)	-4.6%
กลยุทธ์ตามแบบจำลอง (ราคาเปิด + ฟอร์มทีม)			
Model EV ที่ราคา Pinnacle ($EV > 2\%$)	7,793	-0.4% (-4.3% ถึง $+3.6\%$)	-3.1%
Model EV ที่ราคาดีที่สุด ($EV > 2\%$)	13,665	$+2.8\%$ (-0.2% ถึง $+5.8\%$)	$+0.6\%$
Model Draw (ขอบ > 0)	9,821	$+0.1\%$ (-3.4% ถึง $+3.7\%$)	-3.5%
Value Betting ที่ราคาดีที่สุดเทียบกับ Pinnacle (Line Shopping)			
1X2 ราคาเปิด (ขอบ $> 2\%$)	6,240	$+2.3\%$ (-2.2% ถึง $+6.8\%$)	$+3.0\%$
1X2 ราคาปิด (ขอบ $> 5\%$)	2,230	$+8.1\%$ (-1.0% ถึง $+17.3\%$)	$+7.5\%$
Over/Under 2.5 ราคาเปิด (ขอบ $> 2\%$)	668	$+5.5\%$ (-2.4% ถึง $+13.3\%$)	$+3.9\%$
Asian Handicap ราคาเปิด (ขอบ $> 2\%$)	644	$+5.9\%$ (-1.0% ถึง $+12.8\%$)	$+2.1\%$

4) **กลุ่มเดียวที่มีความได้เปรียบตามคาดหมายคือ Line Shopping:** การวางเดิมพันที่ราคาดีที่สุดในบรรดาเจ้ามือเมื่อราคานั้นสูงกว่าความน่าจะเป็นของ Pinnacle ตามแนวทางของ Kaunitz และคณะ [12] มีกำไรคาดหมาย ณ ราคาปิด $+1.4\%$ ถึง $+9.8\%$ ต่อการเดิมพัน และช่วงความเชื่อมั่นอยู่เหนือศูนย์ทั้งหมด (ยกเว้น Asian Handicap ที่ขอบ 0 ซึ่งได้ $+0.1\%$ และช่วงคร่อมศูนย์) แต่ ROI ที่เกิดขึ้นจริงยังมีช่วงความเชื่อมั่นคร่อมศูนย์

เมื่อเลือกพารามิเตอร์ของแต่ละฤดูกาลจากฤดูกาลก่อนหน้าเท่านั้น (Walk-forward) ผลยังเป็นทิศทางเดียวกัน กลยุทธ์ที่ดีที่สุดที่มีจำนวนเดิมพันมากพอ คือ Model EV ที่ราคาดีที่สุด ได้ ROI $+2.7\%$ (-0.5% ถึง $+5.9\%$ จาก 11,971 เดิมพัน) ซึ่งยังไม่มีนัยสำคัญ

4.7 ผลของกลยุทธ์การบริหารเงินทุน (Staking)

นำเดิมพันของกลยุทธ์ตัวแทนมาเล่นซ้ำตามลำดับวันที่ เริ่มจากเงินทุน 1 หน่วย ด้วยแผนการวางเงิน 5 แบบ ได้แก่ เงินคงที่ 1% ของทุนเริ่มต้น (Flat), Kelly เต็ม, Half Kelly, Quarter Kelly และ Martingale (เบิ้ลเงินเป็น 2 เท่าหลังแพ้) จากนั้นสุ่มเดิมพันแบบมีการแทนที่ (Bootstrap) สร้างประวัติจำลอง 1,000 ชุด ยาว 1, 3 และ 5 ฤดูกาล เพื่อวัดโอกาสที่เงินทุนจะลดลงครึ่งหนึ่ง (ตารางแสดงผลของประวัติ 3 ฤดูกาล) ผลแสดงดังตารางที่ 12

ผลที่สำคัญมีดังนี้

1) **Martingale พาหมดตัวทุกกรณี:** ไม่ว่าจะใช้กับกลยุทธ์ใด (รวมถึงกลยุทธ์ที่มีกำไรคาดหมายเป็นบวก) เงินทุนในประวัติจริงเหลือ $0.00\times$ และในประวัติจำลองเงินทุนลดลงครึ่งหนึ่งภายในฤดูกาลเดียวใน 88% ถึง 100% ของกรณี (96% ถึง 100% เมื่อจำลอง 3 ฤดูกาล) เพราะการเบิ้ลเงินไม่ได้เปลี่ยนค่าคาดหมายติดลบ แต่ทำให้ขนาดเดิมพันโตจนเกินทุนในช่วงแพ้ติดกัน

ตารางที่ 12 ผลของแผนการวางเงิน: เงินทุนสุดท้ายในประวัติจริง และโอกาสเสียเงินทุนครึ่งหนึ่งในประวัติจำลอง 3 ฤดูกาล

กลยุทธ์	แผนวางเงิน	ทุนสุดท้าย	Drawdown สูงสุด	โอกาสเสียครึ่ง	ค่ามัธยฐานทุนสุดท้าย
แทงทีมต่อ	Flat	$0.01\times$	100%	75%	$0.39\times$
แทงทีมต่อ	Martingale	$0.00\times$	100%	96%	$0.00\times$
Model EV ราคา Pinnacle	Flat	$0.71\times$	97%	59%	$0.84\times$
Model EV ราคา Pinnacle	Kelly	$0.01\times$	99%	95%	$0.05\times$
Model EV ราคา Pinnacle	Quarter Kelly	$0.53\times$	72%	37%	$0.79\times$
Model EV ราคาดีที่สุด	Flat	$4.80\times$	48%	35%	$2.03\times$
Model EV ราคาดีที่สุด	Kelly	$0.01\times$	100%	89%	$0.22\times$
Model EV ราคาดีที่สุด	Half Kelly	$25.84\times$	89%	56%	$2.47\times$
Model EV ราคาดีที่สุด	Quarter Kelly	$20.64\times$	61%	18%	$2.39\times$
Value 1X2 ราคาดีที่สุด	Flat	$2.43\times$	42%	31%	$1.47\times$
Value 1X2 ราคาดีที่สุด	Kelly	$53.06\times$	87%	34%	$3.34\times$
Value 1X2 ราคาดีที่สุด	Quarter Kelly	$4.87\times$	36%	0%	$1.61\times$
Value 1X2 ราคาดีที่สุด	Martingale	$0.00\times$	100%	99%	$0.00\times$

2) **Kelly เต็มอันตรายเมื่อความน่าจะเป็นไม่แม่น:** Kelly เหมาะสมที่สุดเฉพาะเมื่อความน่าจะเป็นถูกต้อง เมื่อใช้กับความน่าจะเป็นของแบบจำลองที่มั่นใจเกินจริง Kelly เต็มวางเงินมากเกินจนทุนเหลือ $0.01\times$ ทั้งในกลยุทธ์ราคา Pinnacle และราคาดีที่สุด

3) **Fractional Kelly ลดความเสี่ยงได้ชัดเจน:** สำหรับกลยุทธ์ Model EV ที่ราคาดีที่สุด Quarter Kelly ลดโอกาสเสียทุนครึ่งหนึ่งจาก 89% (Kelly เต็ม) เหลือ 18%

4) **ไม่มีแผนวางเงินใดเปลี่ยนค่าคาดหมายติดลบให้เป็นบวกได้:** กลยุทธ์ที่ไม่มีความได้เปรียบ (เช่น แทงทีมต่อ) ขาดทุนเมื่อวางเงินคงที่ ส่วน Kelly ไม่วางเงินเลย (ทุนคงที่ $1.00\times$) เพราะมองไม่เห็นความได้เปรียบที่ราคาของ Pinnacle เอง

4.8 ความเป็นไปได้ในการนำความได้เปรียบไปใช้จริง

แม้ Line Shopping จะมีกำไรคาดหมายเป็นบวก แต่การเก็บความได้เปรียบนี้ในทางปฏิบัติมีข้อจำกัด 3 ด้าน

1) ระยะเวลากว่าความได้เปรียบจะปรากฏเป็นกำไร

ผลการแข่งขันฟุตบอลมีความแปรปรวนสูง (ส่วนเบี่ยงเบนมาตรฐาน σ ประมาณ 1.8 หน่วยต่อการเดิมพัน 1 หน่วยในตลาด 1X2 และต่ำกว่านี้ในตลาด Over/Under และ Asian Handicap ที่ราคาใกล้ 2.0) ตารางที่ 13 แสดงจำนวนฤดูกาลที่ต้องเดิมพันทั้ง 5 ลีก กว่ากำไรตามขนาดความได้เปรียบที่คาดหมาย μ จะสูงกว่าศูนย์ 2 เท่าของความคลาดเคลื่อนมาตรฐาน คือต้องใช้ $n \geq (2\sigma/\mu)^2$ เดิมพัน โดย σ คำนวณแยกตามผลกำไรจริงของแต่ละกลยุทธ์

2) การปิดบัญชีของเจ้ามือ

ราคาดีที่สุดมักมาจากเจ้ามือทั่วไป (Soft Bookmakers) ซึ่งจำกัดหรือปิดบัญชีของผู้ที่ชนะ ตามที่ Kaunitz และคณะ [12] พบเมื่อทดลองด้วยเงินจริง การจำลองกระจายเดิมพันของกลยุทธ์ Value 1X2 ราคาเปิด ไปยังบัญชีหลายบัญชี โดยปิดบัญชีเมื่อกำไรถึงเกณฑ์ พบว่าถ้ามี

ตารางที่ 13 จำนวนฤดูกาลที่ต้องเดิมพันกว่าความได้เปรียบจะปรากฏเป็นกำไร (5 ลีก)

กลยุทธ์	เดิมพัน/ฤดูกาล	กำไรคาดหมาย ณ ราคาปิด	หน่วย/ฤดูกาล	ฤดูกาลที่ต้องใช้
Value 1X2 ราคาปิด (ขอบ $> 2\%$)	1,040	$+4.5\%$	47	6
Value 1X2 ราคาเปิด (ขอบ $> 2\%$)	624	$+3.0\%$	19	23
Value O/U 2.5 ราคาเปิด (ขอบ $> 2\%$)	95	$+3.9\%$	4	30
Value AH ราคาเปิด (ขอบ $> 2\%$)	92	$+2.1\%$	2	81
Model EV ราคาดีที่สุด ($EV > 2\%$)	1,366	$+0.6\%$	9	226

5 บัญชีและถูกปิดเมื่อกำไร 5 หน่วย จะวางเดิมพันได้เพียง 1,108 จาก 6,240 ครั้ง ได้กำไร $+32$ หน่วย และบัญชีสุดท้ายถูกปิดตั้งแต่เดือนกันยายน 2017 ส่วนกรณีที่ดีที่สุด (10 บัญชี ปิดเมื่อกำไร 20 หน่วย) ได้กำไร $+246$ หน่วยก่อนถูกปิดทั้งหมดในเดือนตุลาคม 2021

3) ตลาดแลกเปลี่ยน (Betting Exchange)

Betfair Exchange ไม่ปิดบัญชีผู้ชนะ แต่เก็บค่าคอมมิชชันจากกำไรสุทธิ เมื่อใช้กฎเดียวกันที่ราคา Exchange (ข้อมูลฤดูกาล 2024–2025) ได้ ROI -18.0% จาก 318 เดิมพันเมื่อค่าคอมมิชชัน 2% และ -25.9% จาก 110 เดิมพันเมื่อค่าคอมมิชชัน 5% โดยกำไรคาดหมาย ณ ราคาปิดเท่ากับ 0.0% และ -1.1% ตามลำดับ ความได้เปรียบจึงไม่มีอยู่ในตลาดที่ไม่ปิดบัญชีผู้ชนะ

4.9 สรุปผลการวิเคราะห์

1) ความได้เปรียบของเจ้าบ้าน ($+0.362$ ประตูต่อนัด) และความสัมพันธ์ระหว่าง Elo กับผลต่างประตู ($r = 0.441$) มีนัยสำคัญทางสถิติ

2) ตัวแปรที่ช่วยทำนายได้จริงคือ คะแนน Elo, ฟอร์มผู้เล่นตัวจริง, จำนวนนัดใน 14 วัน และนาทีลงเล่นก่อนหน้า ส่วนดัชนีความเหนื่อยล้าไม่ได้ช่วยเมื่อมี Elo อยู่แล้ว

3) Logistic Regression ดีที่สุดในบรรดาแบบจำลองที่ทดสอบ (Log Loss 0.9848, Accuracy 52.41%) แต่ยังด้อยกว่าราคาเจ้ามือ (0.9695)

4) การวางเดิมพันตามแบบจำลองที่ราคาตลาดขาดทุนประมาณ 4–5.5% ทุกเกณฑ์ EV และไม่มีกลยุทธ์ใดใน 252 ช่องที่มีนัยสำคัญหลังปรับแก้การทดสอบหลายครั้ง

5) ความได้เปรียบตามคาดหมายมีเฉพาะ Line Shopping แต่ต้องใช้เวลาหลายฤดูกาลกว่าจะเห็นเป็นกำไร เจ้ามือที่ให้ราคานั้นปิดบัญชีผู้ชนะ และหายไปในตลาดแลกเปลี่ยน

6) Martingale และ Kelly เต็มพาเงินทุนหมดได้ง่าย ส่วน Fractional Kelly ลดความเสี่ยงได้แต่ไม่สร้างความได้เปรียบ

บทที่ 5
สรุปผลการดำเนินงาน

5.1 สรุปผลการดำเนินโครงงาน

โครงงานนี้พัฒนาท่อส่งข้อมูลเชิงโมดูลาร์ตามกระบวนการวิทยาการข้อมูล ตั้งแต่การรวบรวมข้อมูล 5 ลีกใหญ่ของยุโรปจาก Understat, Transfermarkt และ Football-Data.co.uk การทำความสะอาดและตรวจสอบข้อมูล การสร้างตัวแปรก่อนแข่ง การพัฒนาแบบจำลองทำนายผล H/D/A ไปจนถึงการทดสอบย้อนหลังทางการเงิน โดยตั้งคำถามหลักว่า “ผู้เดิมพันที่ใช้ข้อมูลสาธารณะจะเอาชนะตลาดเดิมพันฟุตบอลได้หรือไม่” และออกแบบการทดสอบให้ตอบคำถามนี้อย่างตรงไปตรงมา ได้แก่ ทำนายทุกฤดูกาลจากฤดูกาลก่อนหน้าเท่านั้น ลงทะเบียนกลยุทธ์ไว้ล่วงหน้าก่อนเห็นผล และรายงานทุกผลลัพธ์พร้อมการปรับแก้การทดสอบหลายครั้ง ผลการดำเนินงานสรุปเทียบกับวัตถุประสงค์ได้ดังตารางที่ 14

โครงงานบรรลุวัตถุประสงค์ทั้ง 4 ข้อในแง่ของการพัฒนาระบบและการตอบคำถามวิจัย แต่คำตอบที่ได้เป็นเชิงลบ คือ **แบบจำลองที่สร้างจากข้อมูลสาธารณะไม่สามารถทำนายได้ดีกว่าตลาด และไม่มีกลยุทธ์ใดสร้างกำไรได้อย่างมีนัยสำคัญ** ซึ่งเป็นผลที่มีคุณค่าในตัวเอง เนื่องจากแสดงด้วยหลักฐานที่สร้างซ้ำได้ว่าตลาดเดิมพันของ 5 ลีกใหญ่มีประสิทธิภาพสูง และกำไรที่ปรากฏในการทดสอบย้อนหลังส่วนใหญ่อธิบายได้ด้วยความบังเอิญหรือการเลือกผลภายหลัง

5.1.1 บทเรียนที่ได้จากโครงงาน

1) **ตลาดเป็นเกณฑ์เปรียบเทียบที่ถูกต้อง:** การวัดแบบจำลองเทียบกับการทายจากสัดส่วนผล (Class Prior) ทำให้ดูเหมือนแบบจำลองดีมาก แต่เมื่อเทียบกับราคาเจ้ามือจะเห็นว่ายังห่างอยู่ 0.0153 Log Loss

2) **แบบจำลองที่ซับซ้อนกว่าไม่ได้ดีกว่าเสมอ:** Logistic Regression ดีกว่า Gradient Boosting บนข้อมูลชุดนี้ เพราะสัญญาณส่วนใหญ่เป็นเชิงเส้นและมีขนาดเล็กเมื่อเทียบกับความแปรปรวนของผลการแข่งขัน

3) **กำไรคาดหมาย ณ ราคาปิด น่าเชื่อถือกว่า ROI:** ROI ของฟุตบอลมีความแปรปรวนสูงจนต้องใช้เดิมพันหลายหมื่นครั้งจึงจะแยกความได้เปรียบเล็ก ๆ ออกจากโชคได้ ส่วนกำไรคาดหมาย ณ ราคาปิดให้ผลที่เสถียรกว่ามาก

4) **การนับจำนวนครั้งที่ลองมีความสำคัญ:** เมื่อทดสอบ 252 ช่อง ย่อมมีบางช่องที่ ROI เป็นบวกโดยบังเอิญ การลงทะเบียนกลยุทธ์ล่วงหน้าและการปรับแก้แบบ Benjamini–Hochberg ช่วยป้องกันการสรุปผิด

5) **การบริหารเงินทุนไม่สร้างความได้เปรียบ:** Martingale และ Kelly

ตารางที่ 14 สรุปผลเทียบกับวัตถุประสงค์ของโครงงาน

ข้อ	วัตถุประสงค์	ผลที่ได้	สถานะ
1	พัฒนากระบวนการวิทยาการข้อมูลแบบครบวงจรจากหลายแหล่งข้อมูล	ท่อส่งข้อมูลโมดูลาร์รวบรวมข้อมูล 5 ลีก ฤดูกาล 2014–2015 ถึง 2025–2026 (21,882 นัดในตารางตัวแปร และ 20,712 นัดพร้อมราคาต่อรอง) ตรวจสอบทุกขั้นด้วย Pandera และสร้างผลซ้ำได้จากรหัสคอมมิต	บรรลุ
2	สร้างและวิเคราะห์ตัวแปรก่อนแข่ง ได้แก่ Elo, ความเหนื่อยล้า, ตารางแข่ง และฟอร์มผู้เล่น 11 ตัวจริง	ยืนยันความได้เปรียบของเจ้าบ้านบนข้อมูลพรีเมียร์ลีก 2000–2024 ($+0.362$ ประตู) และความสัมพันธ์ของ Elo ($r = 0.441$) การคัดเลือกตัวแปรได้ Elo, ฟอร์มผู้เล่นตัวจริง, จำนวนนัดใน 14 วัน และนาทีลงเล่นก่อนหน้า ส่วนดัชนีความเหนื่อยล้าไม่ช่วยเมื่อมี Elo อยู่แล้ว	บรรลุ
3	เปรียบเทียบความน่าจะเป็นของแบบจำลองกับราคาตลาดเพื่อค้นหา Value Bet	Logistic Regression ดีที่สุด (Log Loss 0.9848, Accuracy 52.41%) แต่ด้อยกว่าราคาเจ้ามือ (0.9695) และการเพิ่มฟอร์มทีมเข้าไปในราคาตลาดไม่ทำให้ดีขึ้น ($+0.0008$)	บรรลุ
4	ประเมินผลกำไรผ่านการทดสอบย้อนหลังด้วยกลยุทธ์การบริหารเงินทุนหลายรูปแบบ	ทดสอบ 18 กลยุทธ์ 42 รูปแบบใน 5 ลีก และแผนวางเงิน 5 แบบ การเดิมพันตามแบบจำลองขาดทุน 4–5.5% ไม่มีกลยุทธ์ใดมีนัยสำคัญหลังปรับแก้ มีเพียง Line Shopping ที่มีกำไรคาดหมายเป็นบวก แต่เก็บได้ยากในทางปฏิบัติ	บรรลุ

เต็มพาเงินทุนหมดได้ง่าย ส่วน Fractional Kelly ลดความเสี่ยงได้ แต่ไม่มีแผนใดเปลี่ยนค่าคาดหมายติดลบให้เป็นบวกได้

5.2 ข้อจำกัดของระบบ

5.2.1 ข้อจำกัดด้านการทำงาน

- **ความพร้อมของข้อมูลไลน์อัป (Lineup Availability):** รายชื่อผู้เล่น 11 ตัวจริงต้องรอการประกาศอย่างเป็นทางการล่วงหน้าก่อนแข่งประมาณ 60 นาที ทำให้แบบจำลองไม่สามารถประเมินผลในระยะยาวล่วงหน้าหลายวันได้
- **ความผันผวนของราคาอัตราต่อรอง (Odds Movement):** ระบบยังไม่ได้บันทึกความเคลื่อนไหวของราคาต่อรองแบบเรียลไทม์ (Live Odds) แต่ใช้อัตราต่อรองย้อนหลังคงที่จาก Football-Data.co.uk ซึ่งมีเพียงราคาเปิดและราคาปิด
- **ขอบเขตของตลาด:** ทดสอบเฉพาะ 5 ลีกใหญ่ และตลาด 1X2, Asian Handicap และ Over/Under 2.5 ลีกที่เล็กกว่าหรือตลาดอื่นอาจตั้งราคาได้แม่นน้อยกว่า แต่ก็เป็นตลาดที่เจ้ามือจำกัดบัญชีเร็วที่สุดเช่นกัน
- **ข้อมูลของแบบจำลองที่เทียบกับตลาด:** แบบจำลอง “ราคาเปิด + ฟอร์มทีม” ใช้ประตูและการยิงเข้ากรอบจาก Football-Data.co.uk ยังไม่ได้รวมฟอร์มผู้เล่นตัวจริงจาก Understat เข้าไป
- **สมมติฐานของการจำลอง:** การทดสอบที่ราคาดีที่สุดสมมติว่ามีบัญชีกับเจ้ามือทุกรายที่ Football-Data.co.uk บันทึกไว้ และราคาปิดเป็นกรณีที่ดีที่สุดของจังหวะเวลา ส่วนการจำลองโอกาสหมดตัวสุ่มเดิมพันทีละครั้ง จึงไม่รวมช่วงแพ้ติดกันภายในฤดูกาลและประเมินความเสี่ยงต่ำกว่าความจริง

5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และซอฟต์แวร์

- **หน่วยความจำและการประมวลผล:** การคำนวณตัวแปรระดับผู้เล่น (Player-level features) ย้อนหลัง 12 ฤดูกาลครอบคลุม 5 ลีกยุโรป ต้องใช้หน่วยความจำ RAM ขั้นต่ำ 8 GB และระบบประมวลผลแบบ Multi-core เพื่อให้รัน Data Pipeline ได้มีประสิทธิภาพ
- **ข้อจำกัดการเข้าถึง API แหล่งข้อมูล:** การดึงข้อมูลสถิติจากเว็บไซต์ภายนอกขึ้นอยู่กับโครงสร้าง HTML และขีดจำกัดการรับส่งข้อมูล (Rate Limit) ของเว็บไซต์ต้นทาง

5.3 ปัญหาอุปสรรค และแนวทางแก้ไข

ปัญหาที่พบระหว่างดำเนินงานและแนวทางแก้ไขแสดงดังตารางที่ 15

ตารางที่ 15 ปัญหาอุปสรรคและแนวทางแก้ไขในการดำเนินโครงงาน

ลำดับ	ปัญหาที่พบ	แนวทางแก้ไข
1	ชื่อ สโมสร และ นัก เตะ ใน Understat, Transfermarkt และ Football-Data ไม่ตรงกัน	จัด ทำ ระบบ Alias Table เพื่อ ทำ Entity Resolution แปลงชื่อให้เป็นมาตรฐานเดียวกันก่อนเชื่อมโยงข้อมูล
2	รูป แบบ และ ชนิด ข้อมูล เกิด ความคลาด เคลื่อน ระหว่าง ขั้น ตอนใน Pipeline	กำหนด สเปก ข้อมูล ด้วย Pandera Schema Validation ตรวจสอบโครงสร้างข้อมูลทุกสเตปก่อนส่งต่อไปฝึกโมเดล
3	ปัญหา ข้อมูล อนาคต รั่ว ไหล (Data Leakage) หาก ใช้ สถิติ หลังจบการแข่งขัน	ออกแบบระบบให้รองรับเฉพาะข้อมูลก่อน เริ่ม แข่ง (Pre-match Data) และ ใช้ วิธี Temporal Split ใน การ แบ่ง ชุด ข้อมูล ทดสอบ

5.4 ข้อเสนอแนะในการพัฒนาต่อไป

5.4.1 การปรับปรุงฟังก์ชันการทำงาน

- **การเชื่อมต่อราคาเรียลไทม์ (Live Odds Integration):** พัฒนาระบบเชื่อมต่อ API กับเจ้ามือรับพนันเพื่อดึงราคาต่อรองล่าสุดก่อนเตะแบบอัตโนมัติ ทำให้คำนวณค่า $+EV$ ได้แม่นยำยิ่งขึ้น
- **การ ประมวล ผล ข่าวสาร และ ความ เคลื่อนไหว (Sentiment Analysis):** เพิ่ม มอ ดู ล วิเคราะห์ ข่าวสาร การ บาด เจ็บ สภาพ อากาศ หรือ สัมภาษณ์ ผู้ จัดการ ทีม ด้วย เทคนิค Natural Language Processing (NLP) เพื่อเสริมมิติการทำนาย

5.4.2 แนวทางการวิจัยต่อยอด

- **การใช้ Deep Learning และ Graph Neural Networks (GNN):** ประยุกต์ใช้แบบจำลองโครงข่ายประสาทเทียมเพื่อเรียนรู้ความสัมพันธ์ระหว่างผู้เล่นในทีมแบบเชิงพื้นที่และปฏิสัมพันธ์บนสนาม
- **การ ขยาย แบบ จำลอง สู่ ตลาด การ เดิม พัน อื่น ๆ:** โครงงานนี้ทดสอบตลาด จำนวน ประตู รวม (Over/Under 2.5) และ เอ เชีย น แฮนดิ แคป (Asian Handicap) เฉพาะ กลยุทธ์ Line Shopping ที่ อิง ราคา ของ Pinnacle ขั้นต่อไปคือใช้แบบจำลองจำนวนประตู Poisson ทำนายความน่าจะเป็นของตลาดเหล่านี้โดยตรง และทดสอบกับลีกรองที่ราคาอาจแม่นน้อยกว่า

เอกสารอ้างอิง

[1] O. Hubáček, G. Šír, and F. Železný, "Forty years of score-based soccer match outcome prediction: an experimental review," *IMA Journal of Management Mathematics*, vol. 33, no. 1, pp. 1–18, 2022.

[2] Understat Team, "Understat: Expected goals (xg) statistics." https://understat.com, 2026. Accessed: 2026-10-12.

[3] Transfermarkt GmbH & Co. KG, "Transfermarkt: Football transfers, rumours and market values." https://www.transfermarkt.com, 2026. Accessed: 2026-10-12.

[4] "Football-Data.co.uk: Historical football results and betting odds data." https://www.football-data.co.uk/data.php, 2026. Accessed: 2026-10-12.

[5] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[6] L. M. Hvattum and H. Arntzen, "Using elo ratings for match result prediction in association football," *International Journal of Forecasting*, vol. 26, no. 3, pp. 460–470, 2010.

[7] The Analyst (Opta), "What is expected goals (xg)?." https://theanalyst.com/articles/what-is-expected-goals-xg, 2026. Accessed: 2026-10-12.

[8] M. J. Dixon and S. G. Coles, "Modelling association football scores and inefficiencies in the football betting market," *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997.

[9] A. C. Constantinou and N. E. Fenton, "Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries," *Journal of Quantitative Analysis in Sports*, vol. 9, no. 1, pp. 37–50, 2013.

[10] W. Dubitzky, P. Lopes, J. Davis, and D. Berrar, "The open international soccer database for machine learning," *Machine Learning*, vol. 108, no. 1, pp. 9–28, 2019.

[11] D. Berrar, P. Lopes, and W. Dubitzky, "Incorporating domain knowledge in machine learning for soccer outcome prediction," *Machine Learning*, vol. 108, no. 1, pp. 97–126, 2019.

[12] L. Kaunitz, S. Zhong, and J. Kreiner, “Beating the bookies with their own numbers – and how the online sports betting market is rigged.” arXiv preprint arXiv:1710.02824, 2017.

[13] Y. Benjamini and Y. Hochberg, “Controlling the false discovery rate: a practical and powerful approach to multiple testing,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995.