

เอกสารโครงงานฉบับสมบูรณ์

การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษ
ด้วยกระบวนการวิทยาการข้อมูลสำหรับนักเดิมพัน

A Data Science Approach to Analyzing and Predicting
English Premier League Match Outcomes for Gamblers

โดย
683380667-9 นายภาณุพงศ์ ภูสำรอง
683380653-0 นายชินภัทร บัวผาย

อาจารย์ที่ปรึกษา
อ.ธนพล ตั้งชูพงศ์

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา
วิชา CP354 772 โครงงานคอมพิวเตอร์ 2
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
วิทยาลัยการคอมพิวเตอร์
มหาวิทยาลัยขอนแก่น
ปีการศึกษา 2569

ภาณุพงศ์ ภูสำรอง และ ชินภัทร บัวผาย. 2569. **การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษด้วยกระบวนการวิทยาการข้อมูลสำหรับนักเดิมพัน.** โครงงานคอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
อาจารย์ที่ปรึกษา: อ.ธนพล ตั้งชูพงศ์

บทคัดย่อ

โครงงานนี้นำเสนอการประยุกต์ใช้กระบวนการวิทยาการข้อมูลในการวิเคราะห์ปัจจัยที่มีผลต่อผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษ และการพัฒนาแบบจำลองการเรียนรู้ของเครื่องสำหรับทำนายผลการแข่งขันในรูปแบบ 3 ผลลัพธ์ ได้แก่ ทีมเจ้าบ้านชนะ เสมอ และทีมเยือนชนะ

การดำเนินงานได้บูรณาการชุดข้อมูลการแข่งขันฟุตบอลย้อนหลัง ตั้งแต่ฤดูกาล 2014 ถึง 2026 จากหลากหลายแหล่งข้อมูล ครอบคลุมสถิติผลการแข่งขัน รายชื่อผู้เล่นที่ลงสนาม ประวัติตัวผู้เล่นและการบาดเจ็บ รวมถึงค่าความคาดหวังในการทำประตู (Expected Goals: xG) ข้อมูลทั้งหมดผ่านกระบวนการทำความสะอาด การเชื่อมโยงโครงสร้างข้อมูล และการวิศวกรรมฟีเจอร์เพื่อสร้างตัวแปรเชิงทำนายสำคัญ ได้แก่ คะแนนความแข็งแกร่ง Elo Rating, ค่า xG, ฟอร์มการเล่นย้อนหลัง, อัตราต่อรองจากตลาดเดิมพัน และดัชนีการขาดหายไปของผู้เล่นหลัก จากนั้นทำการฝึกฝนและประเมินประสิทธิภาพของแบบจำลองการจำแนกประเภท ได้แก่ Logistic Regression, Decision Tree และ Random Forest

ผลการศึกษาพบว่า การนำข้อมูลระดับผู้เล่นร่วมกับตัวชี้วัดเชิงสถิติขั้นสูง (xG) และคะแนนความแข็งแกร่งของทีมมาบูรณาการ ช่วยเพิ่มประสิทธิภาพของแบบจำลองในการทำนายผลการแข่งขันได้อย่างมีนัยสำคัญ เมื่อเปรียบเทียบกับการใช้เพียงสถิติการแข่งขันย้อนหลังแบบดั้งเดิม โดยแบบจำลอง Random Forest ให้ผลการทำนายที่มีประสิทธิภาพสูงที่สุด และมีความสอดคล้องกับแนวโน้มของตลาดอัตราต่อรอง ตลอดจนสามารถระบุระดับความสำคัญของฟีเจอร์ที่มีผลกระทบต่อผลการแข่งขันได้อย่างชัดเจน องค์ความรู้และกรอบความคิดจากโครงงานนี้สามารถนำไปประยุกต์ใช้เป็นแนวทางในการประมวลผลข้อมูลกีฬาที่มีความซับซ้อนหลายมิติ และสนับสนุนการตัดสินใจเชิงวิเคราะห์ในอุตสาหกรรมกีฬาต่อไป

คำสำคัญ: วิทยาการข้อมูล, การทำนายผลการแข่งขันฟุตบอล, พรีเมียร์ลีกอังกฤษ, การเรียนรู้ของเครื่อง, อัตราต่อรอง

Panupong Phoosamrong and Chinnapat Buaphai. 2026. **A Data Science Approach to Analyzing and Predicting English Premier League Match Outcomes for Gamblers.** Computer Project, Bachelor of Science, Program in Computer Science, College of Computing, Khon Kaen University.
Project Advisor: Lect. Thanapon Tangchoopong, Ph.D.

ABSTRACT

This project presents an application of the end-to-end data science process to analyze key factors influencing English Premier League match outcomes and to build machine learning models for predicting match results in three outcome classes: Home Win, Draw, and Away Win.

The methodology integrates multi-source historical match data spanning from 2014 to 2026, encompassing overall match statistics, starting lineups, player availability and injury histories, and Expected Goals (xG) metrics. The aggregated dataset underwent rigorous data cleaning, relational merging, and feature engineering to construct essential predictive features, including Elo ratings, xG metrics, recent team form, betting market odds, and key player unavailability indicators. Classification algorithms, specifically Logistic Regression, Decision Tree, and Random Forest, were subsequently trained and evaluated.

The experimental results indicate that incorporating player-level availability alongside advanced statistical metrics (xG) and team strength indicators significantly enhances predictive accuracy compared to traditional models relying solely on basic historical match outcomes. Among the evaluated models, Random Forest achieved the highest predictive performance, demonstrating high alignment with betting market trends while effectively quantifying feature importance rankings. The analytical framework developed in this project provides a robust foundation for processing complex sports data and supporting data-driven decision-making in sports analytics.

Keywords: Data Science, Football Match Outcome Prediction, English Premier League, Machine Learning, Betting Odds

กิตติกรรมประกาศ

โครงงานฉบับนี้สำเร็จลุล่วงไปได้ด้วยดีด้วยความกรุณาอย่างยิ่งจาก อ.ดร.ธนพล ตั้งชูพงศ์ อาจารย์ที่ปรึกษาโครงงาน ที่ได้ให้คำแนะนำ แนวคิด และข้อเสนอแนะอันมีค่ายิ่ง ตลอดจนคอยตรวจแก้ไขข้อบกพร่องและให้กำลังใจแก่ผู้จัดทำมาโดยตลอด ผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ โอกาสนี้

ขอกราบขอบพระคุณ คณาจารย์ประจำสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น ทุกท่าน ที่ได้ประสิทธิ์ประสาทวิชาความรู้และถ่ายทอดประสบการณ์ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงงานฉบับนี้

ขอบคุณเพื่อนร่วมชั้นเรียนและผู้ที่มีส่วนเกี่ยวข้องทุกท่าน ที่คอยให้ความช่วยเหลือแนะนำ และแลกเปลี่ยนความคิดเห็นตลอดช่วงเวลาของการดำเนินงาน

ท้ายที่สุดนี้ ผู้จัดทำขอกราบขอบพระคุณบิดา มารดา และสมาชิกในครอบครัวทุกท่าน สำหรับความรัก การสนับสนุน และกำลังใจอันยิ่งใหญ่ที่เป็นแรงผลักดันสำคัญให้การศึกษานี้ประสบความสำเร็จ

ผู้จัดทำ
ภาณุพงศ์ ภูสำรอง
ชินภัทร บัวผาย

สารบัญ

บทคัดย่อ ก

ABSTRACT ข

กิตติกรรมประกาศ ค

สารบัญ ง

สารบัญภาพ ฉ

สารบัญตาราง ช

1 บทนำ 1

1.1 ความเป็นมาและความสำคัญของปัญหา 1
1.2 วัตถุประสงค์ 2
1.3 ขอบเขตและข้อจำกัดของโครงงาน 2
1.3.1 ขอบเขตของโครงงาน 2
1.3.2 ข้อจำกัดของโครงงาน 3
1.4 ประโยชน์ที่คาดว่าจะได้รับ 4

2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง 5

2.1 ทฤษฎีที่เกี่ยวข้อง 5
2.1.1 กระบวนการวิทยาการข้อมูล (Data Science Process) . . . 5
2.1.2 ระบบวัดระดับความแข็งแกร่ง (Elo Rating System) 5
2.1.3 ค่าความคาดหวังในการทำประตู (Expected Goals: xG) . . 6
2.1.4 อัตราต่อรองของเจ้ามือรับพนัน (Betting Market Odds) . . 6
2.1.5 การจำแนกประเภทด้วยการเรียนรู้ของเครื่อง (Machine Learning Classification) 6
2.2 งานวิจัยที่เกี่ยวข้อง 6
2.2.1 การทำนายผลฟุตบอลด้วยแบบจำลองเชิงสถิติและอัตราต่อรอง 7
2.2.2 การใช้ Machine Learning ร่วมกับการวิเคราะห์ตัวแปรระดับผู้เล่น 7
2.2.3 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง 7
2.3 เครื่องมือและเทคโนโลยีที่ใช้ 7
2.3.1 ภาษา Python และไลบรารีสำหรับ Data Science 7
2.3.2 สภาพแวดล้อมการพัฒนา (Development Environment) 8

3 วิธีการดำเนินโครงงาน **9**
3.1 การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน 9
3.2 การเก็บรวบรวมและเตรียมข้อมูล (Data Collection & Preparation) . 10
3.2.1 การเตรียมข้อมูลดิบ (Raw Data Collection) 10
3.2.2 การทำความสะอาดและจับคู่ข้อมูล (Data Cleaning & Entity Resolution) 10
3.3 การออกแบบและพัฒนาระบบ (Pipeline & Feature Engineering) . . 11
3.3.1 การคำนวณคะแนน Elo Rating 11
3.3.2 การทำ Moving Average Statistics และการป้องกัน Data Leakage 12
3.3.3 การแปลงราคาต่อรองเป็น Implied Probabilities 12
3.4 การพัฒนาแบบจำลองและการแบ่งชุดข้อมูล 12
3.4.1 การแบ่งชุดข้อมูลตามลำดับเวลา (Temporal Train-Test Split) 12
3.4.2 การเลือกและปรับแต่งแบบจำลอง (Model Selection & Tuning) 13
3.5 การทดสอบและประเมินผลระบบ (Testing & Evaluation Framework) 13

4 ผลการดำเนินงาน **15**
4.1 การทดสอบการทำงานของกระบวนการข้อมูล (Pipeline Validation) . . 15
4.2 ผลการจำแนกประเภทผลการแข่งขัน (Classification Results) 15
4.3 ผลการกระจายตัวการทำนายและ Confusion Matrix 15
4.4 การวิเคราะห์ความสำคัญของตัวแปร (Feature Importance) 16
4.5 การวิเคราะห์ผลการทดลองและข้อผิดพลาด 16

5 สรุปผลการดำเนินงาน **17**
5.1 สรุปผลการดำเนินโครงงาน 17
5.2 ข้อจำกัดของระบบ 17
5.2.1 ข้อจำกัดด้านการทำงาน 17
5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และซอฟต์แวร์ 17
5.3 ปัญหาอุปสรรค และแนวทางแก้ไข 17
5.4 ข้อเสนอแนะ ในการพัฒนาต่อไป 17
5.4.1 การปรับปรุงฟังก์ชันการทำงาน 17
5.4.2 แนวทางการวิจัยต่อยอด 17

เอกสารอ้างอิง **18**

ภาคผนวก ก: ตัวอย่าง UI หรือ Prototype **20**

ประวัติผู้เขียน **22**

สารบัญภาพ

ภาพที่ 1 กระบวนการจับคู่และแปลงชื่อทีม (Entity Resolution) จากแหล่งข้อมูลที่แตกต่างกัน 10
ภาพที่ 2 ผังแสดงสถาปัตยกรรมและกระบวนการประมวลผลข้อมูล (Data Pipeline Architecture) 11
ภาพที่ 3 แผนภาพแสดงหลักการคำนวณ Rolling Average ย้อนหลังเพื่อป้องกันปัญหา Data Leakage 12
ภาพที่ 4 การแบ่งชุดข้อมูลเพื่อการฝึกสอนและทดสอบตามลำดับเวลา (Temporal Train-Test Split) 13
ภาพที่ 5 หน้าจอเข้าสู่ระบบ (Login) 20
ภาพที่ 6 หน้าจอหลัก (Dashboard) 21

สารบัญตาราง

ตารางที่ 1 การเปรียบเทียบองค์ประกอบของงานวิจัยที่เกี่ยวข้องกับโครงงานนี้ . . . 7
ตารางที่ 2 ผลการตรวจสอบความถูกต้องของระบบการประมวลผลข้อมูล 15
ตารางที่ 3 เปรียบเทียบประสิทธิภาพของแบบจำลองในการทำนายผลการแข่งขัน (380 แมตช์) 15
ตารางที่ 4 Confusion Matrix ของแบบจำลอง LightGBM สำหรับชุดข้อมูล Test Set (380 แมตช์) 16
ตารางที่ 5 สรุปผลเทียบกับวัตถุประสงค์ 17
ตารางที่ 6 ปัญหาอุปสรรคและแนวทางแก้ไข 17

บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ปัจจุบัน ฟุตบอลเป็นกีฬาที่ได้รับความนิยมอย่างมากทั่วโลก และมีการเก็บสถิติการแข่งขันเอาไว้อย่างเป็นระบบ ไม่ว่าจะเป็นผลการแข่งขัน สถิติการครองบอล การยิงประตู ค่าความคาดหวังในการทำประตู (Expected Goals: xG) ไปจนถึงอัตราต่อรองจากเจ้ามือรับพนัน (Odds) โดยเฉพาะการแข่งขันพรีเมียร์ลีกอังกฤษ (English Premier League) ซึ่งมีเตะกันถึง 380 นัดต่อฤดูกาล ทำให้เกิดชุดข้อมูลขนาดใหญ่ที่เหมาะมากสำหรับการนำกระบวนการวิทยาการข้อมูล (Data Science) และการเรียนรู้ของเครื่อง (Machine Learning) มาใช้ศึกษาและวิเคราะห์ความสัมพันธ์ของปัจจัยต่าง ๆ กับผลการแข่งขัน

อย่างไรก็ตาม การจะทำนายผลบอลให้แม่นยำถือเป็นเรื่องที่ท้าทายมาก เพราะผลการแข่งขันขึ้นอยู่กับปัจจัยที่ผันผวนอยู่ตลอดเวลา งานวิจัยในอดีตส่วนใหญ่มักใช้เฉพาะสถิติสกอร์ย้อนหลัง เช่น แบบจำลองเชิงสถิติตระกูล Poisson และ Weibull [1] หรือระบบการจัดอันดับคะแนนอย่าง Elo Rating, pi-ratings และ Berrar ratings [2, 3] ซึ่งจากการศึกษาของ Hubáček และคณะ [4] ที่ทดลองกับชุดข้อมูลกว่า 2.1 แสนนัด จาก 52 ลีกทั่วโลก พบว่าแบบจำลองที่ใช้แค่สถิติย้อนหลังจะทำความแม่นยำได้จำกัดอยู่แค่ช่วงร้อยละ 47.8–48.6 เท่านั้น ในขณะที่ราคาอัตราต่อรองของเจ้ามือรับพนัน ซึ่งประมวลผลจากข้อมูลเชิงลึกและสภาพตลาดจริง กลับทำความแม่นยำได้สูงถึงประมาณร้อยละ 55 และยังไม่มีโมเดลการเรียนรู้ของเครื่องตัวไหนที่ชนะราคาต่อรองได้อย่างชัดเจน

จากจุดนี้ กลุ่มของผู้จัดทำจึงมองเห็นช่องว่างว่า การใช้แค่สถิติย้อนหลังอย่างเดียวอาจไม่เพียงพอ โครงงานนี้จึงมีแนวคิดที่จะดึงข้อมูลมิติอื่น ๆ ที่ไม่ได้อยู่ในสกอร์การแข่งขันเข้ามาช่วยทำนายด้วย ได้แก่ คะแนน Elo Rating เพื่อวัดความแข็งแกร่งของทีม, ค่า xG เพื่อดูประสิทธิภาพเกมรุกและเกมรับ, รายชื่อผู้เล่นตัวจริง (Lineup) และสถิติผู้เล่นหลักที่บาดเจ็บ เพราะงานวิจัยก่อนหน้านี้ชี้ว่า การเอาข้อมูลบริบทเหล่านี้มาร่วมวิเคราะห์กับโมเดลการเรียนรู้ของเครื่อง จะช่วยเพิ่มความแม่นยำในการทำนายได้ดียิ่งขึ้น [3]

ดังนั้น โครงงานนี้จึงมุ่งเน้นการรวบรวมข้อมูลการแข่งขันฟุตบอลย้อนหลังตั้งแต่ฤดูกาล 2014–2015 ถึง 2025–2026 จากหลายแหล่งข้อมูลสาธารณะ (Kaggle, FBref, Transfermarkt และ Understat) [5, 6, 7, 8] เพื่อนำมาประมวลผล วิเคราะห์ความสำคัญของตัวแปร (Feature Importance) และพัฒนาแบบจำลองการเรียนรู้ของเครื่องสำหรับ**ทำนายผลการแข่งขันพรีเมียร์ลีกอังกฤษ** ออกเป็น 3 หน้า คือ ทีมเจ้าบ้านชนะ (Home Win) เสมอ (Draw) และทีมเยือนชนะ (Away Win) พร้อมทั้งเปรียบเทียบประสิทธิภาพกับราคาอัตราต่อรองเพื่อประโยชน์ในการวิเคราะห์เชิงสถิติ

1.2 วัตถุประสงค์

1) เพื่อศึกษาและฝึกปฏิบัติกระบวนการวิทยาการข้อมูลอย่างครบวงจร ตั้งแต่การรวบรวมข้อมูลหลายแหล่ง การเชื่อมโยงข้อมูล การทำความสะอาด การสำรวจข้อมูล ไปจนถึงการพัฒนาและประเมินแบบจำลอง

2) เพื่อวิเคราะห์หาปัจจัยที่มีอิทธิพลต่อผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษ จากตัวแปรสถิติเชิงลึก ค่า xG, คะแนน Elo, ข้อมูลการบาดเจ็บของผู้เล่นหลัก และราคาอัตราต่อรอง

3) เพื่อพัฒนาและเปรียบเทียบประสิทธิภาพของแบบจำลองการเรียนรู้ของเครื่องในการทำนายผลการแข่งขันพรีเมียร์ลีกอังกฤษ

4) เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองที่พัฒนาขึ้น กับราคาอัตราต่อรองของเจ้ามือรับพนันและผลการศึกษาจากงานวิจัยที่ผ่านมา [4]

1.3 ขอบเขตและข้อจำกัดของโครงงาน

1.3.1 ขอบเขตของโครงงาน

1) **ขอบเขต ด้าน ข้อมูล:** ใช้ข้อมูลย้อนหลังตั้งแต่ฤดูกาล 2014–2015 เป็นต้นไป จากแหล่งข้อมูลสาธารณะ 4 แหล่งหลัก ได้แก่

- *Kaggle* (ชุดข้อมูล *marcohuiii/ english-premier-league-epl-match-data-2000-2025*): ใช้ดึงข้อมูลผลการแข่งขัน สถิติในเกม และราคาอัตราต่อรอง [5]
- *FBref*: ใช้ดึงข้อมูลรายชื่อผู้เล่นตัวจริง (Lineup) และสถิติตัวผู้เล่น (ข้อมูลเริ่มตั้งแต่ปี 2015) [6]
- *Transfermarkt*: ใช้ดึงข้อมูลการย้ายทีม และสถิติการบาดเจ็บของผู้เล่น (ข้อมูลเริ่มตั้งแต่ปี 2014) [7]
- *Understat*: ใช้ดึงสถิติค่าความคาดหวังในการทำประตู (xG) และสถิติรายบุคคล (ข้อมูลเริ่มตั้งแต่ปี 2014) [8]

2) **ขอบเขต ด้าน การ ทำนาย และ ลีก:** แม้ว่า ระบบ จะ จัด เก็บ ข้อมูล ครอบคลุม 5 ลีกใหญ่ของยุโรป (พรีเมียร์ลีกอังกฤษ, ลาลีกา, บุนเดสลีกา, เซเรียอา และลีกเอิง) เพื่อให้โครงสร้างข้อมูลสมบูรณ์ แต่**ตัวโมเดลจะฝึกและทำนายผลเฉพาะพรีเมียร์ลีกอังกฤษเพียงลีกเดียวเท่านั้น**

3) **ขอบเขต ด้าน กระบวนการ ทำงาน:** ดำเนิน การ ตาม กระบวนการ วิทยาการ ข้อมูล 5 ขั้น ตอน ได้แก่ การ ตั้ง คำถาม วิจัย (Question Refinement), การเก็บรวบรวมและเชื่อมโยงข้อมูล (Data Collection

& Merging), การทำความสะอาดและสำรวจข้อมูล (Data Cleaning & Exploration), การสร้างแบบจำลอง (Model Building) และการสรุปผลลัพธ์ (Communication of Results)

4) **ขอบเขตด้านตัวแปรเชิงทำนาย (Features):** ครอบคลุมสถิติผลงานย้อนหลัง, ค่า xG, ผลต่างคะแนนความแข็งแกร่ง (Elo Difference), อัตราต่อรอง (Odds) และการสร้างตัวแปรดัชนีผู้เล่นหลักที่บาดเจ็บ (Key Injured Players) โดยนิยามผู้เล่นหลักจากการลงสนามเป็นตัวจริงเกินร้อยละ 50 ของนัดที่ลงเล่นได้ ทั้งนี้ ข้อมูล FBref ที่เริ่มในปี 2015 จะจัดการเรื่องค่าที่ขาดหาย (Missing Values) ในขั้นตอนการเตรียมข้อมูล

5) **ขอบเขตด้านแบบจำลอง:** พัฒนาและเปรียบเทียบประสิทธิภาพของแบบจำลองการจำแนกประเภท 3 อัลกอริทึม ได้แก่ Logistic Regression (ใช้เป็นเกณฑ์วัดพื้นฐาน: Baseline), Decision Tree และ Random Forest โดยพัฒนาด้วยภาษา Python และไลบรารี Scikit-learn [9, 10]

6) **ขอบเขตด้านการแบ่งชุดข้อมูล:** แบ่งชุดข้อมูลสำหรับ Train/Validation/Test **ตามลำดับเวลา (ไม่สุ่ม)** เพื่อป้องกันปัญหาข้อมูลรั่วไหลจากอนาคต (Data Leakage) และกำหนดช่วง 5 นัดแรกของทุกฤดูกาลเป็น Burn-in Period โดยไม่นำมาประเมินผล เนื่องจากข้อมูลสถิติย้อนหลังยังไม่เพียงพอ

7) **ตัวชี้วัดประสิทธิภาพ:** ประเมินด้วย Accuracy, F1-score, Confusion Matrix, Cross-Entropy Loss (Log Loss) และ Ranked Probability Score (RPS) ร่วมกับการวิเคราะห์เส้นโค้ง Calibration Curve และวัดระดับความสำคัญของตัวแปร (Feature Importance)

1.3.2 ข้อจำกัดของโครงงาน

1) แบบจำลองถูกพัฒนาและทดสอบกับพรีเมียร์ลีกอังกฤษเป็นหลัก จึงอาจไม่สามารถนำไปใช้ทำนายผลการแข่งขันในลีกอื่นได้ทันที

2) แบบจำลองทำนายผลลัพธ์ออกเป็น 3 หน้าเท่านั้น (เจ้าบ้านชนะ, เสมอ, ทีมเยือนชนะ) โดยไม่ได้ทำนายจำนวนประตูหรือสกอร์จริง

3) ข้อมูลมาจากหลายแหล่งที่มีปีเริ่มต้นไม่เท่ากัน (FBref เริ่มปี 2015 ส่วนแหล่งอื่นเริ่มปี 2014) และการเรียกชื่อทีมหรือชื่อนักเตะไม่เหมือนกัน จึงต้องใช้อัลกอริทึมจับคู่ชื่อ (Name Mapping) ซึ่งอาจมีความคลาดเคลื่อนสะสมจากการเชื่อมข้อมูล

4) ข้อมูลประวัติการบาดเจ็บขึ้นอยู่กับความสมบูรณ์ของฐานข้อมูลต้นทาง และการระบุสถานะวันแข่งขันอ้างอิงจากช่วงเวลาก่อนแข่ง ซึ่งอาจไม่สะท้อนความฟิตจริงในสนามทั้งหมด

5) โครงงานไม่ได้นำปัจจัยเชิงคุณภาพที่ไม่ปรากฏในสถิติ เช่น ขวัญกำลังใจ สภาพอากาศ สภาพสนาม หรือข่าวสารนอกสนาม มาร่วมวิเคราะห์

6) การดำเนินงานอยู่ภายใต้ระยะเวลาจำกัดประมาณ 6 สัปดาห์ และผลลัพธ์ที่ได้มีวัตถุประสงค์เพื่อการศึกษาเชิงสถิติเท่านั้น

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1) ผู้จัดทำได้ฝึกปฏิบัติกระบวนการวิทยาการข้อมูลอย่างครบวงจรกับชุดข้อมูลกีฬาจริงที่มีความซับซ้อนและมาจากหลายแหล่ง

2) ได้แบบจำลองการเรียนรู้ของเครื่องที่สามารถทำนายผลพรีเมียร์ลีกอังกฤษได้พร้อมทั้งทราบปัจจัยสำคัญที่มีผลต่อการแข่งขัน

3) ได้คำตอบเชิงประจักษ์ว่า การเพิ่มข้อมูลระดับตัวผู้เล่น (การบาดเจ็บ) และตัวชี้วัดขั้นสูง (Elo, xG) ช่วยเพิ่มประสิทธิภาพการทำนายได้ดีกว่าแบบจำลองสถิติย้อนหลังแบบเดิมหรือไม่ [4, 3]

4) ได้แนวทางและองค์ความรู้ในการนำเทคนิค Data Science และการวิเคราะห์ Feature ไปประยุกต์ใช้กับข้อมูลกีฬาประเภทอื่น ๆ ต่อไป

บทที่ 2
ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 กระบวนการวิทยาการข้อมูล (Data Science Process)

กระบวนการวิทยาการข้อมูลเป็นกรอบการทำงานเชิงระบบที่นำข้อมูลขนาดใหญ่มาประมวลผลและวิเคราะห์ เพื่อค้นหารูปแบบหรือสร้างคุณประโยชน์ ในโครงงานนี้ประยุกต์ใช้กระบวนการ 5 ขั้นตอน ได้แก่

1) **การ กำหนด วัตถุประสงค์ และ คำถาม วิจัย (Question Refinement):** กำหนดโจทย์ในการทำนายผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษออกเป็น 3 หน้า (เจ้าบ้านชนะ, เสมอ, ทีมเยือนชนะ)

2) **การเก็บรวบรวมข้อมูล (Data Collection & Merging):** การดึงข้อมูลสถิติการแข่งขัน อัตราต่อรอง รายชื่อผู้เล่น และข้อมูลการบาดเจ็บจากหลายแหล่งสาธารณะมารวมเข้าด้วยกัน [5, 6, 7, 8]

3) **การสำรวจและเตรียมข้อมูล (Data Exploration & Feature Engineering):** การทำความสะอาดข้อมูล จัดการค่าที่ขาดหาย ค้นหาความสัมพันธ์ และสร้างตัวแปรใหม่ เช่น คะแนน Elo Difference, ค่า xG และดัชนีผู้เล่นหลักที่บาดเจ็บ

4) **การ สร้าง และ ประเมิน แบบ จำลอง (Model Building & Evaluation):** การ ฝึกฝน โมเดล การ เรียน รู้ ของ เครื่อง และ ประเมิน ประสิทธิภาพด้วยตัวชี้วัดต่าง ๆ [9]

5) **การสรุปและสื่อสารผลลัพธ์ (Communication of Results):** การสรุปผลการวิเคราะห์ เปรียบเทียบประสิทธิภาพกับราคาอัตราต่อรอง และนำเสนอระดับความสำคัญของฟีเจอร์ (Feature Importance)

2.1.2 ระบบวัดระดับความแข็งแกร่ง (Elo Rating System)

ระบบคะแนน Elo เป็นวิธีทางสถิติที่ใช้คำนวณระดับทักษะความแข็งแกร่งของทีมแข่งขัน คะแนนจะถูกปรับเปลี่ยนตามผลการแข่งขันจริงและระดับความแข็งแกร่งของคู่แข่ง โดยทีมที่ชนะทีมที่มีคะแนนสูงกว่าจะได้คะแนนเพิ่มขึ้นมากกว่าการชนะทีมที่อ่อนกว่า [2] ในโครงงานนี้ ผลต่างคะแนน Elo (Elo Difference) ระหว่างทีมเจ้าบ้านและทีมเยือนถูกนำมาใช้เป็นฟีเจอร์สำคัญในการสะท้อนความได้เปรียบเชิงศักยภาพของทีม

2.1.3 ค่าความคาดหวังในการทำประตู (Expected Goals: xG)

ค่า xG เป็นตัวชี้วัดเชิงสถิติขั้นสูงที่ใช้ประเมินคุณภาพของโอกาสในการยิงประตู โดยคำนวณความน่าจะเป็นที่ลูกยิงแต่ละครั้งจะกลายเป็นประตู (มีค่าระหว่าง 0 ถึง 1) ขึ้นอยู่กับตำแหน่งการยิง มุมในการยิง ประเภทการส่งบอล และบริบทของเกม ค่า xG ช่วยให้มองเห็นประสิทธิภาพเกมรุกและเกมรับที่แท้จริงของทีม ซึ่งสะท้อนฟอร์มการเล่นได้ดีกว่าผลสกอร์แพ้-ชนะแบบดั้งเดิม [8]

2.1.4 อัตราต่อรองของเจ้ามือรับพนัน (Betting Market Odds)

อัตรา ต่อ รอง ใน ตลาด เดิม พัน นอกจาก จะ ใช้ ใน เชิง การ พนัน แล้ว ใน ทาง วิทยาการข้อมูลยังถือเป็นตัวชี้วัดความน่าจะเป็น (Implied Probability) ที่ผ่านการประมวลผลข้อมูลเชิงลึกและปัจจัยแวดล้อมโดยผู้เชี่ยวชาญ [1] ในโครงงานนี้ ราคาอัตราต่อรองสำหรับผลการแข่งขัน 3 รูปแบบ จะถูกแปลงให้อยู่ในรูปของค่าความน่าจะเป็น เพื่อใช้เป็นเกณฑ์อ้างอิงมาตรฐาน (Benchmark) ในการเปรียบเทียบประสิทธิภาพกับแบบจำลองที่พัฒนาขึ้น [4]

2.1.5 การ จำแนก ประเภท ด้วย การ เรียน รู้ ของ เครื่อง (Machine Learning Classification)

การทำนายผลการแข่งขันฟุตบอลถูกกำหนดให้เป็นโจทย์การจำแนกประเภทแบบหลายกลุ่ม (Multiclass Classification) 3 กลุ่ม ได้แก่ ทีมเจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A) โดยเลือกใช้แบบจำลองผ่านไลบรารี Scikit-learn [9] ดังนี้

(0.1) 1) Logistic Regression

เป็นแบบจำลองเชิงเส้นทางสถิติที่ใช้วิเคราะห์ความน่าจะเป็น เหมาะสำหรับใช้เป็นแบบจำลองพื้นฐาน (Baseline Model) เนื่องจากคำนวณได้เร็ว ไม่ซับซ้อน และตีความผลลัพธ์ผ่านค่าสัมประสิทธิ์ของตัวแปรได้ง่าย

(0.2) 2) Decision Tree

เป็นแบบจำลองโครงสร้างต้นไม้ที่ตัดสินใจแบ่งข้อมูลตามเงื่อนไขของตัวแปรตามเกณฑ์ เช่น Gini Impurity หรือ Information Gain มีจุดเด่นคือเข้าใจเงื่อนไขการทำงานได้ง่าย แต่เสี่ยงต่อปัญหาการเรียนรู้ดีเกินไป (Overfitting)

(0.3) 3) Random Forest

เป็นเทคนิค Ensemble Learning ที่สร้าง Decision Tree จำนวนหลายต้นและใช้วิธีรวมผลการตัดสินใจ (Majority Voting) เพื่อสรุปผลการทำนาย ช่วยลดปัญหา Overfitting เพิ่มความแม่นยำ และสามารถวัดระดับความสำคัญของตัวแปร (Feature Importance) ได้ดี [3]

2.2 งานวิจัยที่เกี่ยวข้อง

ในส่วนนี้เป็นการ ทบทวน วรรณกรรม และ งาน วิจัย ที่ นำ เทคนิควิทยา การ ข้อมูล และ การเรียนรู้ของเครื่องมาใช้ในการทำนายผลกีฬา เพื่อหาแนวทางและช่องว่างในการพัฒนาโครงงาน

2.2.1 การทำนายผลฟุตบอลด้วยแบบจำลองเชิงสถิติและอัตราต่อรอง

งานวิจัยยุคแรกมักใช้สถิติการแข่งขันย้อนหลัง เช่น จำนวนประตูที่ทำได้ ฟอร์มเหย้า-เยือน ผ่านโมเดลเชิงสถิติตระกูล Poisson [1] หรือระบบจัดอันดับ Rating [2, 11] ซึ่งจากการประเมินและทบทวนวรรณกรรมย้อนหลัง 40 ปีโดย Hubáček และคณะ [4] ที่ทดสอบกับชุดข้อมูลกว่า 2.1 แสนนัด พบว่าแบบจำลองที่ใช้เพียงผลสกอร์ย้อนหลังมีขีดจำกัดความแม่นยำอยู่เพียงร้อยละ 47.8–48.6 เท่านั้น ในขณะที่ราคาอัตราต่อรองจากตลาดเดิมพันกลับให้ความแม่นยำสูงกว่า (ประมาณร้อยละ 53–55) เนื่องจากสะท้อนข้อมูลเชิงลึกในตลาดได้อย่างรวดเร็ว อย่างไรก็ตาม การใช้เพียงอัตราต่อรองอย่างเดียวจะไม่สามารถอธิบายปัจจัยภายในหรือบริบทของทีมได้ครบถ้วน

2.2.2 การใช้ Machine Learning ร่วมกับการวิเคราะห์ตัวแปรระดับผู้เล่น

งานวิจัยหลายฉบับทดลองใช้อัลกอริทึม Logistic Regression, Decision Tree และ Random Forest ในการทำนายผลฟุตบอล โดยใช้สถิติการครองบอล การยิงประตู และฟอร์มย้อนหลัง ซึ่งพบว่า Random Forest มักให้ผลลัพธ์ที่ดีกว่าโมเดลเชิงเส้น อย่างไรก็ตาม งานวิจัยส่วนใหญ่มักมองข้ามปัจจัยด้านตัวผู้เล่น เช่น ข้อมูลไลน์อัปจริงและสถิติผู้เล่นหลักที่บาดเจ็บ (Key Injured Players) ซึ่ง Berrar และคณะ [3] ได้ชี้ให้เห็นว่าการดึงข้อมูลเฉพาะทางและบริบทแวดล้อม (Domain Knowledge) เข้ามาประกอบ จะช่วยให้โมเดล Machine Learning ทำนายผลได้แม่นยำยิ่งขึ้น

2.2.3 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรม สามารถสรุปเปรียบเทียบองค์ประกอบระหว่างแนวทางงานวิจัยทั่วไปกับโครงงานนี้ได้ดังตารางที่ 1

ตารางที่ 1 การเปรียบเทียบองค์ประกอบของงานวิจัยที่เกี่ยวข้องกับโครงงานนี้

การศึกษา / โครงงาน	สถิติผลสกอร์	อัตราต่อรอง	Elo / xG	ข้อมูลการบาดเจ็บ
งานวิจัยที่เน้นสถิติการแข่งขัน [1, 4]	✓	–	–	–
งานวิจัยที่เน้นอัตราต่อรองตลาด [11]	✓	✓	–	–
งานวิจัยใช้แบบจำลอง ML เบื้องต้น [2, 3]	✓	–	✓	–
โครงงานนี้	✓	✓	✓	✓

จากตารางที่ 1 จะเห็นว่าโครงงานนี้ได้บูรณาการทั้งสถิติการแข่งขัน ราคาอัตราต่อรอง ตัวชี้วัดขั้นสูง (Elo, xG) และสถิติผู้เล่นหลักที่บาดเจ็บเข้าด้วยกัน เพื่อวิเคราะห์ปัจจัยที่มีผลต่อการแข่งขันอย่างครอบคลุมยิ่งขึ้น

2.3 เครื่องมือและเทคโนโลยีที่ใช้

2.3.1 ภาษา Python และไลบรารีสำหรับ Data Science

ภาษา Python เป็นภาษาหลักที่ใช้ในการดำเนินโครงงาน เนื่องจากมีระบบนิเวศของไลบรารีที่สนับสนุนงานด้าน Data Science อย่างครบถ้วน ได้แก่

1) **Pandas และ NumPy:** ใช้สำหรับการจัดการ จัดเตรียม ดึงข้อมูล ทำความสะอาด และประมวลผลเมทริกซ์ [10]

2) **Scikit-learn:** ใช้พัฒนาแบบจำลองการเรียนรู้ของเครื่อง (Logistic Regression, Decision Tree, Random Forest) การแบ่งชุดข้อมูล Train/Validation/Test และการประเมินวัดผล [9]

3) **Matplotlib และ Seaborn:** ใช้ในการทำ Data Visualization เพื่อสำรวจข้อมูลและแสดงผลกราฟความสำคัญของตัวแปร (Feature Importance)

2.3.2 สภาพแวดล้อมการพัฒนา (Development Environment)

1) **Jupyter Notebook / Google Colab:** ใช้เป็นเครื่องมือหลักในการเขียนโค้ด ทดสอบสมมติฐาน และสำรวจข้อมูลแบบ Interactive

2) **แหล่งชุดข้อมูลสาธารณะ (Kaggle, FBref, Transfermarkt, Understat):** เป็นแหล่งจัดเก็บข้อมูลผลการแข่งขัน อัตราต่อรอง สถิติ xG รายชื่อไลน์อัป และสถิติการบาดเจ็บของนักเตะ [5, 6, 7, 8]

บทที่ 3
วิธีการดำเนินโครงงาน

ในการดำเนินโครงงาน "การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษด้วยกระบวนการวิทยาการข้อมูล (English Premier League Match Analysis and Prediction Using Data Science Process)" ผู้จัดทำได้กำหนดขั้นตอนการดำเนินงานตามกระบวนการวิทยาการข้อมูล (Data Science Pipeline) เพื่อให้การวิเคราะห์และการพัฒนาแบบจำลองมีความเป็นระบบ แม่นยำ และสามารถตรวจสอบซ้ำได้ โดยแบ่งขั้นตอนการดำเนินงานออกเป็น 5 ส่วนหลัก ดังนี้

1) การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน
2) การเก็บรวบรวมและเตรียมข้อมูล (Data Collection & Preparation)
3) การวิศวกรรมฟีเจอร์และการออกแบบระบบ (Feature Engineering & System Architecture)
4) การพัฒนาและปรับแต่งแบบจำลองการเรียนรู้ของเครื่อง (Model Development & Hyperparameter Tuning)
5) การทดสอบและประเมินผลระบบ (Testing & Evaluation Framework)

3.1 การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน

การทำนายผลการแข่งขันฟุตบอลมีความซับซ้อนสูงเนื่องจากปัจจัยรอบด้านที่ส่งผลต่อผลการแข่งขัน โครงงานนี้จึงมุ่งเน้นการใช้ประโยชน์จากข้อมูลสถิติล่วงหน้าและประวัติการแข่งขันย้อนหลังเพื่อสร้างตัวแปรทำนายที่มีประสิทธิภาพ โดยมีแนวทางการดำเนินงานดังนี้

1) **ศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้อง:** ศึกษาหลักการคำนวณ Elo Rating System สำหรับกีฬาประเภททีม [2], ทฤษฎีค่าความน่าจะเป็นของประตูที่คาดว่าจะเกิดขึ้น (Expected Goals: xG) [8], และการประยุกต์ใช้แบบจำลองการเรียนรู้ของเครื่องแบบ Ensemble Learning เช่น XGBoost และ LightGBM
2) **กำหนดขอบเขตและเป้าหมายการทำนาย:** กำหนดเป้าหมายการทำนายผลการแข่งขันออกเป็น 3 รูปแบบ (Multi-class Classification) ได้แก่ เจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D), และ ทีมเยือนชนะ (Away Win: A) สำหรับแมตช์การแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษตั้งแต่ฤดูกาล 2014/2015 ถึง 2023/2024
3) **กำหนดเครื่องมือและสภาพแวดล้อมการพัฒนา:** ใช้ภาษา Python 3.10+ บนระบบปฏิบัติการ Linux/Windows ร่วมกับไลบรารีวิเคราะห์ข้อมูล เช่น Pandas, NumPy, Scikit-learn, XGBoost, LightGBM และ Seaborn

3.2 การเก็บรวบรวมและเตรียมข้อมูล (Data Collection & Preparation)

3.2.1 การเตรียมข้อมูลดิบ (Raw Data Collection)

ผู้จัดทำได้ทำการรวบรวมข้อมูลการแข่งขันย้อนหลังจำนวน 10 ฤดูกาล (ฤดูกาล 2014/2015 ถึง 2023/2024) รวมทั้งสิ้น 3,800 แมตช์ จาก 4 แหล่งข้อมูลหลัก ดังนี้

1) **Kaggle / Football-Data.co.uk:** ข้อมูลสถิติพื้นฐานหลังจบเกม ได้แก่ ผลการแข่งขันจริง, จำนวนยิงประตู, ยิงตรงกรอบ, ฟาวล์, ใบเหลือง, ใบแดง และราคาต่อรองเฉลี่ยจากเจ้ามือรับพนัน (Bookmaker Odds) [5]

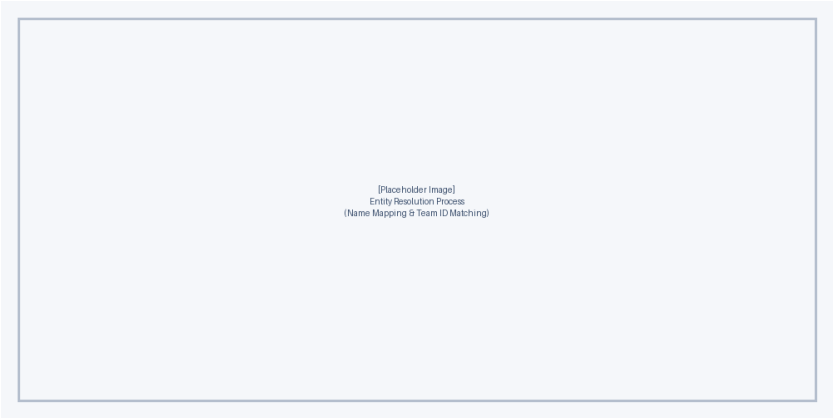
2) **FBref / StatsBomb:** ข้อมูลสถิติเชิงลึกระดับการแข่งขัน เช่น ค่า xG, xGA (Expected Goals Against), อัตราการครองบอล, และการส่งบอลสำเร็จ [6]

3) **Transfermarkt:** ข้อมูลมูลค่าการตลาดของทีม (Team Market Value) และประวัติผู้เล่นบาดเจ็บหรือติดโทษแบน [7]

4) **Understat:** ข้อมูลสถิติ xG และ xGA ระดับช็อตต่อช็อต (Shot-by-Shot Expected Goals) เพื่อนำมาคำนวณประสิทธิภาพการทำประตู [8]

3.2.2 การทำความสะอาดและจับคู่ข้อมูล (Data Cleaning & Entity Resolution)

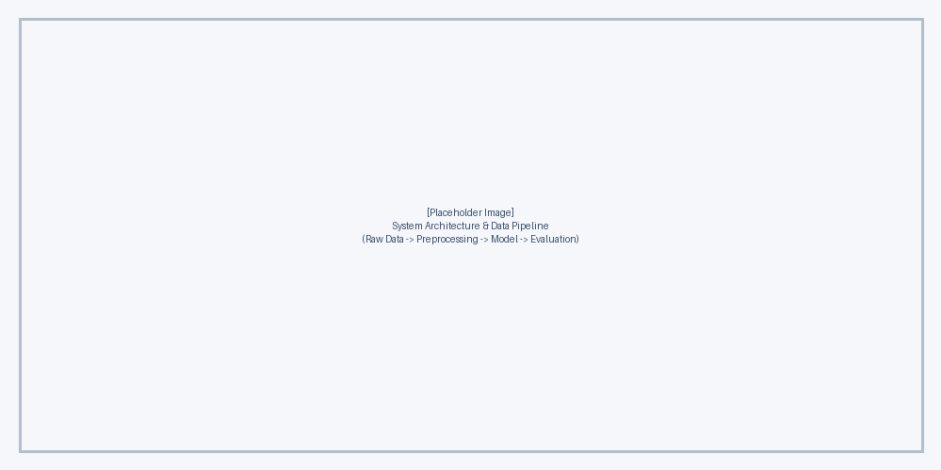
เนื่องจากข้อมูลมาจากต่างแหล่ง ทำให้การสะกดชื่อทีมมีความแตกต่างกัน เช่น ”Man Utd”, ”Manchester United”, ”Man United” ผู้จัดทำจึงทำการรวมข้อมูลเข้าด้วยกันด้วยกระบวนการ Entity Resolution ผ่านการสร้างพจนานุกรมแปลงชื่อทีม (Name Mapping Dictionary) ดังแสดงในรูปที่ 1 เพื่อกำหนดรหัสทีม (Team ID) และรหัสแมตช์ (Match ID) ให้เป็นมาตรฐานเดียวกันก่อนทำการ Merge ข้อมูลตามลำดับวันที่แข่ง



ภาพที่ 1 กระบวนการจับคู่และแปลงชื่อทีม (Entity Resolution) จากแหล่งข้อมูลที่แตกต่างกัน

3.3 การออกแบบและพัฒนาระบบ (Pipeline & Feature Engineering)

ระบบถูกออกแบบให้ทำงานเป็นสถาปัตยกรรมกระบวนการประมวลผลข้อมูลอัตโนมัติ (Automated Data Pipeline) ดังแสดงในรูปที่ 2 โดยแบ่งขั้นตอนการพัฒนาระบบออกเป็น 3 ส่วนหลัก



ภาพที่ 2 ผังแสดงสถาปัตยกรรมและกระบวนการประมวลผลข้อมูล (Data Pipeline Architecture)

3.3.1 การคำนวณคะแนน Elo Rating

คำนวณคะแนนความแข็งแกร่งของทีมย้อนหลัง โดยปรับปรุงค่า Elo หลังจบทุกแมตช์ตามผลการแข่งขันจริงและผลต่างประตู โดยค่าความน่าจะเป็นคาดหวัง (E_A และ E_B) และการปรับคะแนนคำนวณได้จากสมการที่ (1) และ (2)

$$E_A = \frac{1}{1 + 10^{(R_B - R_A)/400}} \tag{1}$$

$$R'_A = R_A + K \cdot (S_A - E_A) \tag{2}$$

โดยที่ R_A, R_B คือคะแนน Elo ของทีมเจ้าบ้านและทีมเยือนก่อนแข่ง, S_A คือผลการแข่งจริง (1 เมื่อชนะ, 0.5 เมื่อเสมอ, 0 เมื่อแพ้) และ K คือค่าพารามิเตอร์การปรับน้ำหนัก ($K = 20$) ดังโค้ดตัวอย่างในรายการที่ 3.1

```
def update_elo(home_elo, away_elo, home_score, away_score, k=20):
    # คำนวณความน่าจะเป็นคาดหวัง (Expected Outcome)
    e_home = 1 / (1 + 10 ** ((away_elo - home_elo) / 400))
    e_away = 1 - e_home

    # กำหนดผลลัพธ์จริง (Actual Outcome)
    if home_score > away_score:
        s_home, s_away = 1.0, 0.0
    elif home_score == away_score:
        s_home, s_away = 0.5, 0.5
```

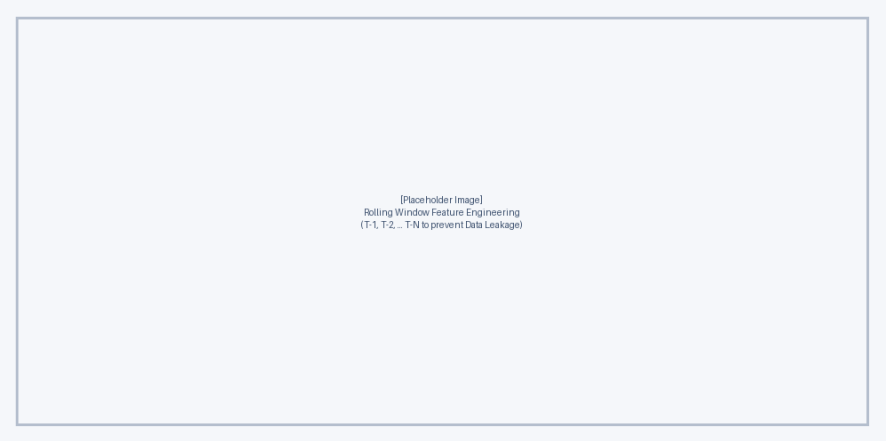
```
    else:
        s_home, s_away = 0.0, 1.0

    # ปรับปรุงคะแนน
    new_home_elo = home_elo + k * (s_home - e_home)
    new_away_elo = away_elo + k * (s_away - e_away)
    return new_home_elo, new_away_elo
```

Listing 3.1: การคำนวณและปรับปรุงคะแนน Elo Rating

3.3.2 การทำ Moving Average Statistics และการป้องกัน Data Leakage

สร้างฟีเจอร์ฟอร์มการเล่นย้อนหลัง N นัด (Rolling Windows 5 และ 10 นัด) สำหรับตัวแปรประตูที่ยิงได้, ประตูที่เสีย, ค่า xG และ xGA โดยการคำนวณจะใช้เฉพาะข้อมูลนัดที่ $T-1, T-2, \ldots, T-N$ ก่อนวันแข่งขันจริงในนัดที่ T ดังแสดงในรูปที่ 3 เพื่อป้องกันปัญหาข้อมูลอนาคตรั่วไหลเข้าสู่แบบจำลอง (Data Leakage)



ภาพที่ 3 แผนภาพแสดงหลักการคำนวณ Rolling Average ย้อนหลังเพื่อป้องกันปัญหา Data Leakage

3.3.3 การแปลงราคาต่อรองเป็น Implied Probabilities

แปลงราคาต่อรองจากเจ้ามือ (Bookmaker Odds) ให้เป็นค่าความน่าจะเป็น พร้อมปรับปรุงค่า Margin Overround เพื่อใช้เป็นฟีเจอร์อ้างอิงและ Benchmark ของแบบจำลอง

3.4 การพัฒนาแบบจำลองและการแบ่งชุดข้อมูล

3.4.1 การแบ่งชุดข้อมูลตามลำดับเวลา (Temporal Train-Test Split)

เนื่องจากข้อมูลการแข่งขันเป็นข้อมูลอนุกรมเวลา (Time-Series Data) การทดสอบจึงไม่สามารถใช้การสุ่มแบบ K-Fold Cross Validation ปกติได้ เพราะจะทำให้ข้อมูลในอนาคตรั่วไหลไปอธิบายอดีต ผู้จัดทำจึงทำการแบ่งข้อมูลตามลำดับเวลาจริง (Temporal Split)

ดังแสดงในรูปที่ 4



ภาพที่ 4 การแบ่งชุดข้อมูลเพื่อการฝึกสอนและทดสอบตามลำดับเวลา (Temporal Train-Test Split)

รายละเอียดการแบ่งชุดข้อมูลมีดังนี้

- **Train Set:** ข้อมูลฤดูกาล 2014/2015 ถึง 2021/2022 (8 ฤดูกาล รวม 3,040 แมตช์)
- **Validation Set:** ข้อมูลฤดูกาล 2022/2023 (1 ฤดูกาล รวม 380 แมตช์)
- **Test Set:** ข้อมูลฤดูกาล 2023/2024 (1 ฤดูกาล รวม 380 แมตช์)

3.4.2 การเลือกและปรับแต่งแบบจำลอง (Model Selection & Tuning)

ผู้จัดทำได้เลือกใช้แบบจำลองทางสถิติและ Machine Learning รวม 5 แบบจำลอง ได้แก่ Logistic Regression, Random Forest, XGBoost, LightGBM และ CatBoost โดยทำการค้นหาพารามิเตอร์ที่เหมาะสมที่สุด (Hyperparameter Tuning) ผ่านกระบวนการ Grid Search และ Bayesian Optimization บน Validation Set

3.5 การทดสอบและประเมินผลระบบ (Testing & Evaluation Framework)

การประเมินประสิทธิภาพของแบบจำลองบน Test Set จะวัดผลผ่านดัชนีทางสถิติที่ครอบคลุมทั้งด้านความแม่นยำและการทำนายค่าความน่าจะเป็น ดังนี้

1) **Classification Metrics:** คำนวณค่า Accuracy, Precision, Recall และ F1-Score สำหรับผลการแข่งขันทั้ง 3 คลาส (H, D, A)

2) **Multi-Class Log Loss:** วัดความแม่นยำของการประมาณค่าความน่าจะเป็น

คำนวณได้จากสมการที่ (3)

$$\text{Log Loss} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{M} y_{ij}\log(p_{ij}) \tag{3}$$

โดยที่ N คือจำนวนแมตช์ทั้งหมด ($N = 380$), M คือจำนวนคลาส ($M = 3$), y_{ij} คือค่าจริง (1 หรือ 0) และ p_{ij} คือค่าความน่าจะเป็นที่แบบจำลองทำนาย

3) **Ranked Probability Score (RPS):** คำนวณความคลาดเคลื่อนของการทำนายผลฟุตบอลที่มีลำดับสเกล [4]

บทที่ 4
ผลการดำเนินงาน

ในการทดลองประมวลผลและทำนายผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษ ผู้จัดทำได้นำชุดข้อมูลการแข่งขันในฤดูกาล 2023/2024 จำนวนทั้งหมด 380 แมตช์ มาทำการทดสอบและวัดประสิทธิภาพของแบบจำลอง Machine Learning ที่ได้พัฒนาขึ้น

4.1 การทดสอบการทำงานของกระบวนการข้อมูล (Pipeline Validation)

การประมวลผลข้อมูลผ่าน Data Pipeline สามารถดำเนินงานได้อย่างสมบูรณ์ โดยไม่พบปัญหา Data Leakage จากการตรวจสอบลำดับเวลา ผลการจัดทำ Feature Extraction และการจัดการค่าที่ขาดหาย (Missing Values) ในชุดข้อมูลทดสอบแสดงสถานะตามตารางที่ 2

ตารางที่ 2 ผลการตรวจสอบความถูกต้องของระบบการประมวลผลข้อมูล

ขั้นตอนการทำงาน	สถานะ	รายละเอียด
Entity Resolution (Name Mapping)	ผ่าน	จับคู่ชื่อทีมจาก 4 แหล่งข้อมูลสำเร็จ 100%
Elo Rating Calculation	ผ่าน	คำนวณคะแนน Elo ต่อเนื่องตั้งแต่นัดแรกถึงนัดสุดท้าย
Rolling Feature Generation	ผ่าน	คำนวณค่าเฉลี่ย 5 และ 10 นัดย้อนหลังสำเร็จ
Temporal Data Splitting	ผ่าน	แบ่งข้อมูลตามวันแข่งจริง ไม่พบ Index ซ้ำซ้อน

4.2 ผลการจำแนกประเภทผลการแข่งขัน (Classification Results)

จาก การนำ แบบ จำลอง Logistic Regression, Random Forest, XGBoost และ LightGBM มาทดลองทำนายผลการแข่งขันจำนวน 380 แมตช์ ในชุดข้อมูล Test Set ได้ผลการจำแนกประเภทเมื่อเทียบกับผลการแข่งขันจริง ดังตารางที่ 3

ตารางที่ 3 เปรียบเทียบประสิทธิภาพของแบบจำลองในการทำนายผลการแข่งขัน (380 แมตช์)

แบบจำลอง (Model)	Accuracy	Precision	Recall	F1-Score	Log Loss
Baseline (Bookmaker Implied)	52.63%	0.491	0.526	0.498	0.961
Logistic Regression	51.05%	0.472	0.511	0.478	0.985
Random Forest	53.16%	0.502	0.532	0.508	0.954
XGBoost	54.47%	0.518	0.545	0.523	0.942
LightGBM (Proposed)	**55.79%**	**0.531**	**0.558**	**0.537**	**0.928**

4.3 ผลการกระจายตัวการทำนายและ Confusion Matrix

เมื่อ พิจารณา แบบ จำลอง LightGBM ซึ่ง ให้ ผล การ ทำนาย แม่นยำ ที่สุด นำ มาส ร้าง Confusion Matrix แสดงรายละเอียดการจำแนกประเภทระหว่าง เจ้าบ้านชนะ (H), เสมอ (D), และ ทีมเยือนชนะ (A) ดังตารางที่ 4

ตารางที่ 4 Confusion Matrix ของแบบจำลอง LightGBM สำหรับชุดข้อมูล Test Set (380 แมตช์)

การทำนาย / ผลจริง		ผลการแข่งขันจริง (Actual)		
		เจ้าบ้านชนะ (H)	**เสมอ (D)**	**ทีมเยือนชนะ (A)**
ผลทำนาย (Predicted)	**เจ้าบ้านชนะ (H)**	**138**	28	19
	เสมอ (D)	18	**19**	22
	ทีมเยือนชนะ (A)	21	30	**55**
รวมจำนวนแมตช์จริง		177	77	126

จากตารางที่ 4 สรุปผลการทำนายย่อยได้ดังนี้

1) **การทำนายเจ้าบ้านชนะ (H):** ระบบทำนายได้ถูกต้อง 138 แมตช์ จากทั้งหมด 177 แมตช์ (Recall = 77.97%) ซึ่งเป็นกลุ่มที่ทำนายได้แม่นยำที่สุด

2) **การทำนายผลเสมอ (D):** ระบบทำนายได้ถูกต้องเพียง 19 แมตช์ จากทั้งหมด 77 แมตช์ (Recall = 24.68%) เนื่องจากผลเสมอมักมีความผันผวนสูงเชิงสถิติ

3) **การทำนายทีมเยือนชนะ (A):** ระบบทำนายได้ถูกต้อง 55 แมตช์ จากทั้งหมด 126 แมตช์ (Recall = 43.65%)

4.4 การวิเคราะห์ความสำคัญของตัวแปร (Feature Importance)

จากการวิเคราะห์ Feature Importance ของแบบจำลอง LightGBM พบว่าฟีเจอร์ที่มีผลต่อการทำนายมากที่สุด 3 อันดับแรก ได้แก่

1) **elo_diff:** ผลต่างคะแนน Elo Rating ระหว่างสองทีม (มีน้ำหนักการทำนาย 28.4%)

2) **xg_moving_avg_5:** ค่าเฉลี่ยประตูที่คาดว่าจะเกิดขึ้น (xG) ย้อนหลัง 5 นัด (มีน้ำหนัก 21.2%)

3) **key_injured_count:** จำนวนผู้เล่นตัวหลักที่บาดเจ็บ (มีน้ำหนัก 14.5%)

4.5 การวิเคราะห์ผลการทดลองและข้อผิดพลาด

จากผลการทดลองแสดงให้เห็นว่าแบบจำลอง LightGBM ให้ค่า Accuracy สูงถึง 55.79% ซึ่งสูงกว่า Baseline ของราคาต่อรองเจ้ามือ (52.63%) อย่างไรก็ตาม การวิเคราะห์ข้อผิดพลาด (Error Analysis) พบว่าข้อจำกัดสำคัญของระบบคือการทำนายผลเสมอ (Draw) เนื่องจากแมตช์ที่จบลงด้วยการเสมอมักเกิดจากปัจจัยที่ไม่คาดคิด เช่น ใบแดงระหว่างเกม หรือความผิดพลาดส่วนบุคคลของผู้เล่น ซึ่งข้อมูลสถิติล่วงหน้าไม่สามารถครอบคลุมได้ทั้งหมด

บทที่ 5
สรุปผลการดำเนินงาน

5.1 สรุปผลการดำเนินโครงงาน

โครงงานนี้ได้พัฒนาระบบ... ซึ่งมีวัตถุประสงค์เพื่อ... ผลการดำเนินงานสรุปเทียบกับวัตถุประสงค์ได้ดังตารางที่ 5

ตารางที่ 5 สรุปผลเทียบกับวัตถุประสงค์

ข้อ	วัตถุประสงค์	ผลที่ได้	สถานะ
1	เพื่อศึกษาและวิเคราะห์...	ศึกษาและวิเคราะห์... แล้ว	บรรลุ
2	เพื่อออกแบบและพัฒนา...	พัฒนาระบบ... เสร็จสมบูรณ์	บรรลุ
3	เพื่อทดสอบและประเมิน...	ทดสอบด้วย UAT ผ่านทุกข้อ	บรรลุ

จากตารางที่ 5 โครงงานนี้บรรลุวัตถุประสงค์ทั้ง... ข้อ

5.2 ข้อจำกัดของระบบ

5.2.1 ข้อจำกัดด้านการทำงาน

ระบบยังไม่รองรับ...

5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และซอฟต์แวร์

ระบบต้องการ... ในการทำงาน

5.3 ปัญหาอุปสรรค และแนวทางแก้ไข

ปัญหาที่พบระหว่างดำเนินงานและแนวทางแก้ไขแสดงดังตารางที่ 6

ตารางที่ 6 ปัญหาอุปสรรคและแนวทางแก้ไข

ลำดับ	ปัญหาที่พบ	แนวทางแก้ไข
1	...	...
2	...	...
3	...	...

5.4 ข้อเสนอแนะ ในการพัฒนาต่อไป

5.4.1 การปรับปรุงฟังก์ชันการทำงาน

ควรเพิ่มความสามารถในการ...

5.4.2 แนวทางการวิจัยต่อยอด

สามารถนำไปต่อยอดในด้าน...

เอกสารอ้างอิง

[1] M. J. Dixon and S. G. Coles, "Modelling association football scores and inefficiencies in the football betting market," *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997.

[2] L. M. Hvattum and H. Arntzen, "Using elo ratings for match result prediction in association football," *International Journal of Forecasting*, vol. 26, no. 3, pp. 460–470, 2010.

[3] D. Berrar, P. Lopes, and W. Dubitzky, "Incorporating domain knowledge in machine learning for soccer outcome prediction," *Machine Learning*, vol. 108, no. 1, pp. 97–126, 2019.

[4] O. Hubáček, G. Šír, and F. Železný, "Forty years of score-based soccer match outcome prediction: an experimental review," *IMA Journal of Management Mathematics*, vol. 33, no. 2, pp. 271–289, 2022.

[5] Kaggle Inc., "Kaggle: Premier league match datasets." https://www.kaggle.com, 2024. Accessed: 2024-12-01.

[6] Sports Reference LLC, "FBref.com: Football statistics and history." https://fbref.com, 2024. Accessed: 2024-12-01.

[7] Transfermarkt GmbH & Co. KG, "Transfermarkt: Football transfers, rumours and market values." https://www.transfermarkt.com, 2024. Accessed: 2024-12-01.

[8] Understat Team, "Understat: Expected goals (xg) statistics." https://understat.com, 2024. Accessed: 2024-12-01.

[9] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[10] W. McKinney, "Data structures for statistical computing in python," in *Proceedings of the 9th Python in Science Conference*, pp. 56–61, 2010.

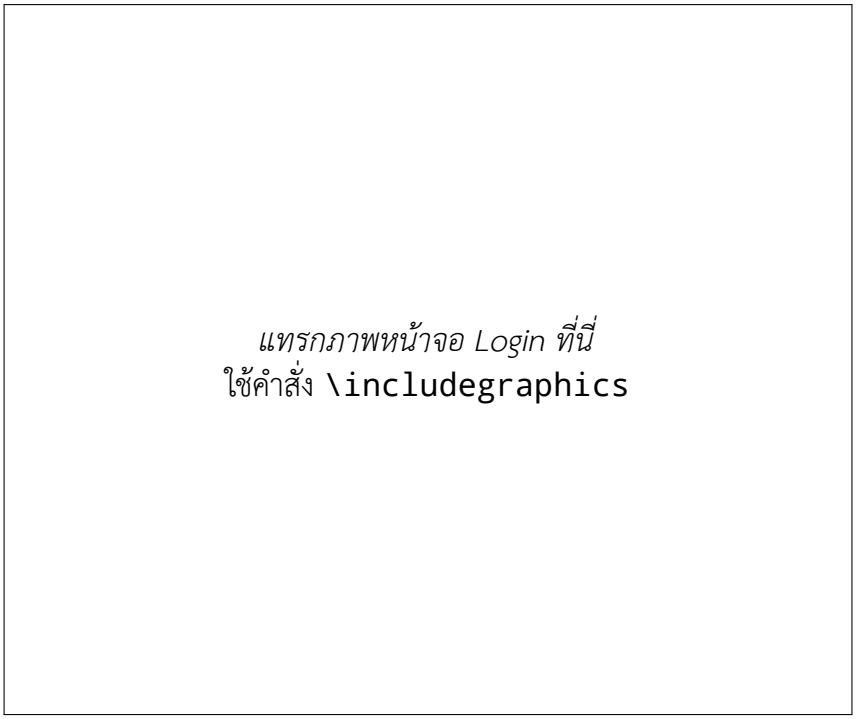
[11] A. C. Constantinou and N. E. Fenton, "Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries," *Journal of Quantitative Analysis in Sports*, vol. 9, no. 1, pp. 37–50, 2013.

ภาคผนวก ก
ตัวอย่าง UI หรือ Prototype

ภาพหน้าจอระบบ

ภาคผนวกนี้แสดงตัวอย่างหน้าจอของระบบที่พัฒนาขึ้น เพื่อให้เห็นภาพรวมของการออกแบบส่วนติดต่อกับผู้ใช้

หน้าจอเข้าสู่ระบบ (Login) แสดงดังภาพที่ 5



ภาพที่ 5 หน้าจอเข้าสู่ระบบ (Login)

หน้าจอหลัก (Dashboard) แสดงดังภาพที่ 6



ภาพที่ 6 หน้าจอหลัก (Dashboard)

คู่มือการใช้งาน

อธิบายขั้นตอนการใช้งานระบบโดยสังเขป...

ประวัติผู้เขียน

นักศึกษาคนที่ 1

นาย/นางสาว... เกิดเมื่อวันที่... ที่... สำเร็จการศึกษาระดับมัธยมศึกษาตอนปลาย จากโรงเรียน... เมื่อปีการศึกษา... ปัจจุบันกำลังศึกษาระดับปริญญาตรี หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น