


# เอกสารโครงงานฉบับสมบูรณ์

การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษ
ด้วยกระบวนการวิทยาการข้อมูลสำหรับนักเดิมพัน

A Data Science Approach to Analyzing and Predicting
English Premier League Match Outcomes for Gamblers

โดย
683380667-9 นายภาณุพงศ์ ภูสำรอง
683380653-0 นายชินภัทร บัวผาย

อาจารย์ที่ปรึกษา
อ.ธนพล ตั้งชูพงศ์

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา
วิชา CP354 772 โครงงานคอมพิวเตอร์ 2
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
วิทยาลัยการคอมพิวเตอร์
มหาวิทยาลัยขอนแก่น
ปีการศึกษา 2569

ภาณุพงศ์ ภูสำรอง และ ชินภัทร บัวผาย. 2569. **การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษด้วยกระบวนการวิทยาการข้อมูลสำหรับนักเดิมพัน.** โครงงานคอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
**อาจารย์ที่ปรึกษา:** อ.ธนพล ตั้งชูพงศ์

## บทคัดย่อ

โครงงานนี้นำเสนอการประยุกต์ใช้กระบวนการวิทยาการข้อมูลในการวิเคราะห์ปัจจัยที่มีผลต่อผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษ และการพัฒนาแบบจำลองการเรียนรู้ของเครื่องสำหรับทำนายผลการแข่งขันในรูปแบบ 3 ผลลัพธ์ ได้แก่ ทีมเจ้าบ้านชนะ เสมอ และทีมเยือนชนะ

การดำเนินงานได้บูรณาการชุดข้อมูลการแข่งขันฟุตบอลย้อนหลัง ตั้งแต่ฤดูกาล 2014 ถึง 2026 จากหลากหลายแหล่งข้อมูล ครอบคลุมสถิติผลการแข่งขัน รายชื่อผู้เล่นที่ลงสนาม ประวัติตัวผู้เล่นและการบาดเจ็บ รวมถึงค่าความคาดหวังในการทำประตู (Expected Goals: xG) ข้อมูลทั้งหมดผ่านกระบวนการทำความสะอาด การเชื่อมโยงโครงสร้างข้อมูล และการวิศวกรรมฟีเจอร์เพื่อสร้างตัวแปรเชิงทำนายสำคัญ ได้แก่ คะแนนความแข็งแกร่ง Elo Rating, ค่า xG, ฟอร์มการเล่นย้อนหลัง, อัตราต่อรองจากตลาดเดิมพัน และดัชนีการขาดหายไปของผู้เล่นหลัก จากนั้นทำการฝึกฝนและประเมินประสิทธิภาพของแบบจำลองการจำแนกประเภท ได้แก่ Logistic Regression, Decision Tree และ Random Forest

ผลการศึกษาพบว่า การนำข้อมูลระดับผู้เล่นร่วมกับตัวชี้วัดเชิงสถิติขั้นสูง (xG) และคะแนนความแข็งแกร่งของทีมมาบูรณาการ ช่วยเพิ่มประสิทธิภาพของแบบจำลองในการทำนายผลการแข่งขันได้อย่างมีนัยสำคัญ เมื่อเปรียบเทียบกับการใช้เพียงสถิติการแข่งขันย้อนหลังแบบดั้งเดิม โดยแบบจำลอง Random Forest ให้ผลการทำนายที่มีประสิทธิภาพสูงที่สุด และมีความสอดคล้องกับแนวโน้มของตลาดอัตราต่อรอง ตลอดจนสามารถระบุระดับความสำคัญของฟีเจอร์ที่มีผลกระทบต่อผลการแข่งขันได้อย่างชัดเจน องค์ความรู้และกรอบความคิดจากโครงงานนี้สามารถนำไปประยุกต์ใช้เป็นแนวทางในการประมวลผลข้อมูลกีฬาที่มีความซับซ้อนหลายมิติ และสนับสนุนการตัดสินใจเชิงวิเคราะห์ในอุตสาหกรรมกีฬาต่อไป

**คำสำคัญ:** วิทยาการข้อมูล, การทำนายผลการแข่งขันฟุตบอล, พรีเมียร์ลีกอังกฤษ, การเรียนรู้ของเครื่อง, อัตราต่อรอง

Panupong Phoosamrong and Chinnapat Buaphai. 2026. **A Data Science Approach to Analyzing and Predicting English Premier League Match Outcomes for Gamblers.** Computer Project, Bachelor of Science, Program in Computer Science, College of Computing, Khon Kaen University.
**Project Advisor:** Lect. Thanapon Tangchoopong, Ph.D.

# ABSTRACT

This project presents an application of the end-to-end data science process to analyze key factors influencing English Premier League match outcomes and to build machine learning models for predicting match results in three outcome classes: Home Win, Draw, and Away Win.

The methodology integrates multi-source historical match data spanning from 2014 to 2026, encompassing overall match statistics, starting lineups, player availability and injury histories, and Expected Goals (xG) metrics. The aggregated dataset underwent rigorous data cleaning, relational merging, and feature engineering to construct essential predictive features, including Elo ratings, xG metrics, recent team form, betting market odds, and key player unavailability indicators. Classification algorithms, specifically Logistic Regression, Decision Tree, and Random Forest, were subsequently trained and evaluated.

The experimental results indicate that incorporating player-level availability alongside advanced statistical metrics (xG) and team strength indicators significantly enhances predictive accuracy compared to traditional models relying solely on basic historical match outcomes. Among the evaluated models, Random Forest achieved the highest predictive performance, demonstrating high alignment with betting market trends while effectively quantifying feature importance rankings. The analytical framework developed in this project provides a robust foundation for processing complex sports data and supporting data-driven decision-making in sports analytics.

**Keywords:** Data Science, Football Match Outcome Prediction, English Premier League, Machine Learning, Betting Odds

# กิตติกรรมประกาศ

โครงงานฉบับนี้สำเร็จลุล่วงไปได้ด้วยดีด้วยความกรุณาอย่างยิ่งจาก อ.ดร.ธนพล ตั้งชูพงศ์ อาจารย์ที่ปรึกษาโครงงาน ที่ได้ให้คำแนะนำ แนวคิด และข้อเสนอแนะอันมีค่ายิ่ง ตลอดจนคอยตรวจแก้ไขข้อบกพร่องและให้กำลังใจแก่ผู้จัดทำมาโดยตลอด ผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ โอกาสนี้

ขอกราบขอบพระคุณ คณาจารย์ประจำสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น ทุกท่าน ที่ได้ประสิทธิ์ประสาทวิชาความรู้และถ่ายทอดประสบการณ์ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงงานฉบับนี้

ขอบคุณเพื่อนร่วมชั้นเรียนและผู้ที่มีส่วนเกี่ยวข้องทุกท่าน ที่คอยให้ความช่วยเหลือแนะนำ และแลกเปลี่ยนความคิดเห็นตลอดช่วงเวลาของการดำเนินงาน

ท้ายที่สุดนี้ ผู้จัดทำขอกราบขอบพระคุณบิดา มารดา และสมาชิกในครอบครัวทุกท่าน สำหรับความรัก การสนับสนุน และกำลังใจอันยิ่งใหญ่ที่เป็นแรงผลักดันสำคัญให้การศึกษานี้ประสบความสำเร็จ

ผู้จัดทำ
ภาณุพงศ์ ภูสำรอง
ชินภัทร บัวผาย

# สารบัญ


**บทคัดย่อ** ก

**ABSTRACT** ข

**กิตติกรรมประกาศ** ค

**สารบัญ** ง

**สารบัญภาพ** ช

**สารบัญตาราง** ซ

**1 บทนำ** 1

1.1 ความเป็นมาและความสำคัญของปัญหา . . . . . 1
1.2 วัตถุประสงค์ . . . . . 2
1.3 ขอบเขตและข้อจำกัดของโครงงาน . . . . . 2
1.3.1 ขอบเขตของโครงงาน . . . . . 2
1.3.2 ข้อจำกัดของโครงงาน . . . . . 3
1.4 ประโยชน์ที่คาดว่าจะได้รับ . . . . . 4

**2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง** 5

2.1 ทฤษฎีที่เกี่ยวข้อง . . . . . 5
2.1.1 กระบวนการ วิทยาการ ข้อมูล และ การ จัด ทำ ท่อ ส่ง ข้อมูล (Data Science & Pipeline Process) . . . . . 5
2.1.2 ระบบวัดระดับความแข็งแกร่ง (Elo Rating System) . . . . 6
2.1.3 ค่าความคาดหวังในการทำประตู (Expected Goals: xG) . . 6
2.1.4 ดัชนีความเหนื่อยล้าและความหนาแน่นของตารางแข่ง (Fatigue Metric & Schedule Congestion) . . . . . 7
2.1.5 อัตราต่อรองของเจ้ามือรับพนัน (Betting Market Odds) ในฐานะเกณฑ์อ้างอิงของงานวิจัย . . . . . 8
2.1.6 การ จับ คู่ และ แปลง ชื่อ เอ นทิ ตี ให้ เป็น มาตรฐาน (Entity Resolution) . . . . . 8
2.1.7 แบบจำลองทำนายผลการแข่งขัน . . . . . 8
2.1.8 การทดสอบสมมติฐานทางสถิติ . . . . . 9
2.2 งานวิจัยที่เกี่ยวข้อง . . . . . 9
2.2.1 การทำนายผลฟุตบอลด้วยแบบจำลองเชิงสถิติและอัตราต่อรอง 10
2.2.2 การใช้ Machine Learning ร่วมกับตัวแปรสถิติเชิงลึกและข้อมูลบริบท . . . . . 10

2.2.3 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง . . . . . 10
2.3 เครื่องมือและเทคโนโลยีที่ใช้ . . . . . 10
2.3.1 ภาษา Python และไลบรารีสำหรับการประมวลผลข้อมูล . . 10
2.3.2 สภาพแวดล้อมและการประกันคุณภาพซอฟต์แวร์ (Development Environment & Quality Control) . . . . . 11

**3 วิธีการดำเนินโครงงาน 12**
3.1 การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน . . . . . 12
3.2 การเก็บรวบรวมข้อมูล (Data Collection) . . . . . 13
3.3 การทำความสะอาดข้อมูลและการตรวจสอบความถูกต้อง . . . . . 13
3.3.1 ขั้นตอนการทำความสะอาด (Data Cleaning) . . . . . 13
3.3.2 การ จับ คู่ และ แปลง ชื่อ เอ นทิ ตี ให้ เป็น มาตรฐาน (Entity Resolution) . . . . . 14
3.3.3 การ ตรวจ สอบ ความ ถูก ต้อง ของ ข้อ ตกลง ข้อมูล (Data Schema Validation) . . . . . 14
3.4 การวิศวกรรมฟีเจอร์ (Feature Engineering) . . . . . 14
3.4.1 การคำนวณคะแนนความแข็งแกร่งเชิงสัมพัทธ์ (Elo Rating Calculation) . . . . . 15
3.4.2 การ คำนวณ ดัชนี ความ เหนื่อย ล้า สะสม (Fatigue Index Calculation) . . . . . 16
3.4.3 ตัวแปรความหนาแน่นของตารางแข่งขัน (Schedule Congestion) . . . . . 17
3.4.4 ฟอร์มรายบุคคลของผู้เล่นตัวจริง (Starter Form Features) 17
3.5 การพัฒนาแบบจำลองและการแบ่งชุดข้อมูล . . . . . 17
3.5.1 แบบจำลอง Double Poisson ที่ขับเคลื่อนด้วย Elo . . . . 17
3.5.2 แบบจำลอง Gradient Boosting และการวัดความสำคัญของตัวแปร . . . . . 18
3.5.3 การแบ่งชุดข้อมูลตามลำดับเวลา (Temporal Split) . . . . 18
3.5.4 ตัวชี้วัดประสิทธิภาพ (Evaluation Metrics) . . . . . 18
3.5.5 การทดสอบสมมติฐานทางสถิติ . . . . . 19
3.6 การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance Framework) . . . . . 19
3.6.1 การทดสอบซอฟต์แวร์อัตโนมัติ (Automated Testing) . . . 19
3.6.2 การตรวจสอบคุณภาพโค้ดและการเผยแพร่ . . . . . 19

**4 ผลการดำเนินงาน 20**
4.1 การทดสอบการทำงานของกระบวนการข้อมูล (Pipeline Validation) . . 20
4.2 ผลการจำแนกประเภทผลการแข่งขัน (Classification Results) . . . . . 20
4.3 ผลการกระจายตัวการทำนายและ Confusion Matrix . . . . . 20
4.4 การวิเคราะห์ความสำคัญของตัวแปร (Feature Importance) . . . . . 21
4.5 การวิเคราะห์ผลการทดลองและข้อผิดพลาด . . . . . 21

**5 สรุปผลการดำเนินงาน 22**

5.1 สรุปผลการดำเนินโครงงาน . . . . . 22
5.2 ข้อจำกัดของระบบ . . . . . 22
5.2.1 ข้อจำกัดด้านการทำงาน . . . . . 22
5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และซอฟต์แวร์ . . . . . 22
5.3 ปัญหาอุปสรรค และแนวทางแก้ไข . . . . . 22
5.4 ข้อเสนอแนะ ในการพัฒนาต่อไป . . . . . 22
5.4.1 การปรับปรุงฟังก์ชันการทำงาน . . . . . 22
5.4.2 แนวทางการวิจัยต่อยอด . . . . . 22

**เอกสารอ้างอิง** **23**

# สารบัญภาพ

ภาพ ที่ 1 ตัวอย่าง แผนภาพ แสดง การ ปรับปรุง คะแนน Elo Rating ของ สโมสร ฟุตบอลตามผลการแข่งขันย้อนหลัง (ที่มา: ClubElo) . . . . . 6
ภาพที่ 2 ตัวอย่างการประเมินค่าความคาดหวังในการทำประตู (Expected Goals: xG) จากตำแหน่งการยิง (ที่มา: Opta Analyst) . . . . . 7
ภาพที่ 3 ตัวอย่างการวิเคราะห์ความตึงเครียดของโปรแกรมแข่งขัน . . . . . 8

# สารบัญตาราง

ตารางที่ 1 การเปรียบเทียบองค์ประกอบของงานวิจัยที่เกี่ยวข้องกับโครงงานนี้ . . . 10
ตารางที่ 2 สถาปัตยกรรมโมดูลการประมวลผลข้อมูลในระบบ (Data Pipeline Modules) . . . 15
ตารางที่ 3 องค์ประกอบของคะแนนความเหนื่อยล้ารายผู้เล่น . . . 16
ตารางที่ 4 ผลการตรวจสอบความถูกต้องของระบบการประมวลผลข้อมูล . . . 20
ตารางที่ 5 เปรียบเทียบประสิทธิภาพของแบบจำลองในการทำนายผลการแข่งขัน (380 แมตช์) . . . 20
ตารางที่ 6 Confusion Matrix ของแบบจำลอง LightGBM สำหรับชุดข้อมูล Test Set (380 แมตช์) . . . 21
ตารางที่ 7 สรุปผลเทียบกับวัตถุประสงค์ . . . 22
ตารางที่ 8 ปัญหาอุปสรรคและแนวทางแก้ไข . . . 22

# บทที่ 1
# บทนำ

## 1.1 ความเป็นมาและความสำคัญของปัญหา

ปัจจุบัน ฟุตบอลเป็นกีฬาที่ได้รับความนิยมอย่างมากทั่วโลก และมีการเก็บสถิติการแข่งขันเอาไว้อย่างเป็นระบบ ไม่ว่าจะเป็นผลการแข่งขัน สถิติการครองบอล การยิงประตู ค่าความคาดหวังในการทำประตู (Expected Goals: xG) ไปจนถึงอัตราต่อรองจากเจ้ามือรับพนัน (Odds) โดยเฉพาะการแข่งขันพรีเมียร์ลีกอังกฤษ (English Premier League) ซึ่งมีเตะกันถึง 380 นัดต่อฤดูกาล ทำให้เกิดชุดข้อมูลขนาดใหญ่ที่เหมาะมากสำหรับการนำกระบวนการวิทยาการข้อมูล (Data Science) และการเรียนรู้ของเครื่อง (Machine Learning) มาใช้ศึกษาและวิเคราะห์ความสัมพันธ์ของปัจจัยต่าง ๆ กับผลการแข่งขัน

อย่างไรก็ตาม การจะทำนายผลบอลให้แม่นยำถือเป็นเรื่องที่ท้าทายมาก เพราะผลการแข่งขันขึ้นอยู่กับปัจจัยที่ผันผวนอยู่ตลอดเวลา งานวิจัยในอดีตส่วนใหญ่มักใช้เฉพาะสถิติสกอร์ย้อนหลัง เช่น แบบจำลองเชิงสถิติตระกูล Poisson และ Weibull [1] หรือระบบการจัดอันดับคะแนนอย่าง Elo Rating, pi-ratings และ Berrar ratings [2, 3] ซึ่งจากการศึกษาของ Hubáček และคณะ [4] ที่ทดลองกับชุดข้อมูลกว่า 2.1 แสนนัด จาก 52 ลีกทั่วโลก พบว่าแบบจำลองที่ใช้แค่สถิติย้อนหลังจะทำความแม่นยำได้จำกัดอยู่แค่ช่วงร้อยละ 47.8–48.6 เท่านั้น ในขณะที่ราคาอัตราต่อรองของเจ้ามือรับพนัน ซึ่งประมวลผลจากข้อมูลเชิงลึกและสภาพตลาดจริง กลับทำความแม่นยำได้สูงถึงประมาณร้อยละ 55 และยังไม่มีโมเดลการเรียนรู้ของเครื่องตัวไหนที่ชนะราคาต่อรองได้อย่างชัดเจน

จากจุดนี้ กลุ่มของผู้จัดทำจึงมองเห็นช่องว่างว่า การใช้แค่สถิติย้อนหลังอย่างเดียวอาจไม่เพียงพอ โครงงานนี้จึงมีแนวคิดที่จะดึงข้อมูลมิติอื่น ๆ ที่ไม่ได้อยู่ในสกอร์การแข่งขันเข้ามาช่วยทำนายด้วย ได้แก่ คะแนน Elo Rating เพื่อวัดความแข็งแกร่งของทีม, ดัชนีความเหนื่อยล้าของผู้เล่นตัวจริง, ความหนาแน่นของตารางการแข่งขัน (รวมถึงการแข่งขันถ้วยและรายการยุโรป) และฟอร์มรายบุคคลของผู้เล่นตัวจริงทั้ง 11 คน เช่น ค่า xG ต่อ 90 นาที เพราะงานวิจัยก่อนหน้านี้ชี้ว่า การเอาข้อมูลบริบทเหล่านี้มาร่วมวิเคราะห์กับโมเดลการเรียนรู้ของเครื่อง จะช่วยเพิ่มความแม่นยำในการทำนายได้ดียิ่งขึ้น [3]

ดังนั้น โครงงานนี้จึงมุ่งเน้นการรวบรวมข้อมูลการแข่งขันฟุตบอลย้อนหลังตั้งแต่ฤดูกาล 2014–2015 ถึง 2025–2026 จากแหล่งข้อมูลสาธารณะ (Understat และ Transfermarkt) [5, 6] รวมถึงชุดข้อมูลผลการแข่งขันพรีเมียร์ลีกจาก Kaggle [7] เพื่อนำมาประมวลผลผ่านท่อส่งข้อมูลที่มีการตรวจสอบโครงสร้างข้อมูล (Schema Validation) สร้างตัวแปรก่อนการแข่งขัน วิเคราะห์ความสำคัญของตัวแปร (Feature Importance) และพัฒนาแบบจำลองสำหรับ**ทำนายผลการแข่งขัน**ออกเป็น 3 ผลลัพธ์ คือ ทีมเจ้าบ้านชนะ (Home Win) เสมอ (Draw) และทีมเยือนชนะ (Away Win) พร้อมทั้งทดสอบสมมติฐานทางสถิติเกี่ยวกับความได้เปรียบของทีมเจ้าบ้านและความสัมพันธ์ระหว่างคะแนน Elo กับผลต่างประตู เพื่อประโยชน์ในการวิเคราะห์เชิงสถิติ

## 1.2 วัตถุประสงค์

1) เพื่อศึกษาและฝึกปฏิบัติกระบวนการวิทยาการข้อมูลอย่างครบวงจร ตั้งแต่การรวบรวมข้อมูลหลายแหล่ง การเชื่อมโยงข้อมูล การทำความสะอาด การสำรวจข้อมูล ไปจนถึงการพัฒนาและประเมินแบบจำลอง

2) เพื่อวิเคราะห์หาปัจจัยที่มีอิทธิพลต่อผลการแข่งขันฟุตบอล จากตัวแปรก่อนการแข่งขัน ได้แก่ คะแนน Elo, ดัชนีความเหนื่อยล้า, ความหนาแน่นของตารางแข่งขัน และฟอร์มของผู้เล่นตัวจริง

3) เพื่อทดสอบสมมติฐานทางสถิติว่า (1) ทีมเจ้าบ้านทำประตูได้มากกว่าทีมเยือน และ (2) ผลต่างคะแนน Elo มีความสัมพันธ์กับผลต่างประตู

4) เพื่อพัฒนาและประเมินประสิทธิภาพของแบบจำลองในการทำนายผลการแข่งขัน โดยเปรียบเทียบกับค่าพื้นฐาน (Baseline) และผลการศึกษาจากงานวิจัยที่ผ่านมา [4]

## 1.3 ขอบเขตและข้อจำกัดของโครงงาน

### 1.3.1 ขอบเขตของโครงงาน

1) **ขอบเขตด้านข้อมูล:** ใช้ข้อมูลย้อนหลังตั้งแต่ฤดูกาล 2014–2015 ถึง 2025–2026 จากแหล่งข้อมูลสาธารณะดังนี้

- *Understat*: ใช้ดึงตารางการแข่งขันพร้อมจำนวนประตูและค่า xG และสถิติรายบุคคลของผู้เล่นในแต่ละนัด [5]
- *Transfermarkt*: ใช้ดึงปฏิทินการแข่งขันเต็มของแต่ละสโมสรทุกรายการ (รวมถึงถ้วยและรายการยุโรป) และแผนการเล่น (Formation) ที่ทีมใช้ [6]
- *Kaggle* (ชุดข้อมูล *marcohuiii/ english-premier-league-epl-match-data-2000-2025*): ใช้สำหรับการสำรวจข้อมูลและการทดสอบสมมติฐานเชิงสถิติ กับผลการแข่งขันพรีเมียร์ลีก อังกฤษ ฤดูกาล 2000–2001 ถึง 2024–2025 [7]

2) **ขอบเขตด้านลีก:** ระบบเก็บรวบรวมข้อมูลและสร้างตัวแปรครอบคลุม 5 ลีกใหญ่ของยุโรป (พรีเมียร์ลีกอังกฤษ, ลาลีกา, บุนเดสลีกา, เซเรียอา และลีกเอิง) ส่วนการทดสอบสมมติฐานเชิงสถิติและแบบจำลอง Elo ใช้ข้อมูลพรีเมียร์ลีกอังกฤษ

3) **ขอบเขต ด้าน ระบบ:** พัฒนาท่อส่งข้อมูลแบบโมดูลาร์ด้วยภาษา Python ประกอบด้วยการเก็บข้อมูล (`collect_data`) การ

ทำความสะอาดและสร้างตัวแปร (`clean_data`) การตรวจสอบโครงสร้างข้อมูลด้วย Pandera (`check_clean`) การวิเคราะห์ความสำคัญของตัวแปร (`feature_importance`) พร้อมชุดทดสอบอัตโนมัติและ API สำหรับเรียกดูผลการทำนาย

4) **ขอบเขตด้านตัวแปรเชิงทำนาย (Features):** ใช้เฉพาะข้อมูลที่ทราบก่อนเริ่มการแข่งขัน ได้แก่ คะแนน Elo และผลต่างคะแนน Elo (Elo Difference), ดัชนีความเหนื่อยล้าของผู้เล่นตัวจริง, ความหนาแน่นของตารางแข่งขัน (วันพัก จำนวนนัดใน 7 และ 14 วัน เกมถ้วยหรือเกมยุโรป) และฟอร์มรายบุคคลของผู้เล่นตัวจริง 11 คน

5) **ขอบเขตด้านแบบจำลอง:** (1) แบบจำลอง Double Poisson ที่ขับเคลื่อนด้วยผลต่างคะแนน Elo ร่วมกับการแก้ไขแบบ Dixon-Coles [1] เพื่อคำนวณความน่าจะเป็นของผลการแข่งขัน H/D/A และ (2) แบบจำลอง Gradient Boosting (`HistGradientBoostingClassifier` จากไลบรารี Scikit-learn [8]) เพื่อวิเคราะห์ความสำคัญของตัวแปรด้วยวิธี Permutation Importance โดยใช้ค่าความน่าจะเป็นตามสัดส่วนผลการแข่งขันในอดีต (Class Prior) เป็นเกณฑ์เปรียบเทียบพื้นฐาน

6) **ขอบเขตด้านการแบ่งชุดข้อมูล:** แบ่งข้อมูล**ตามลำดับเวลา (ไม่สุ่ม)** เพื่อป้องกันปัญหาข้อมูลรั่วไหลจากอนาคต (Data Leakage) โดยการวิเคราะห์ความสำคัญของตัวแปรใช้ฤดูกาลก่อนปี 2024 เป็นชุดฝึก และตั้งแต่ปี 2024 เป็นต้นไปเป็นชุดทดสอบ ส่วนแบบจำลอง Elo ใช้การทำนายแบบ Walk-forward คือทำนายแต่ละฤดูกาลด้วยแบบจำลองที่ฝึกจากฤดูกาลก่อนหน้าเท่านั้น และถือว่าฤดูกาล 2014–2015 เป็นช่วงเริ่มต้น (Warm-up) ของคะแนน Elo

7) **ตัวชี้วัดประสิทธิภาพ:** ประเมินด้วย Cross-Entropy Loss (Log Loss), Ranked Probability Score (RPS) และ Accuracy พร้อมวัดระดับความสำคัญของตัวแปรด้วย Permutation Importance ส่วนการทดสอบสมมติฐานใช้ Paired t-test, Wilcoxon Signed-rank Test, สัมประสิทธิ์สหสัมพันธ์ของ Pearson และ Spearman

### 1.3.2 ข้อจำกัดของโครงงาน

1) ผลการทดสอบสมมติฐานและแบบจำลอง Elo อ้างอิงข้อมูลพรีเมียร์ลีกอังกฤษเป็นหลัก จึงอาจไม่สามารถนำไปใช้ทำนายผลการแข่งขันในลีกอื่นได้ทันที

2) แบบจำลองทำนายผลลัพธ์ออกเป็น 3 ผลลัพธ์เท่านั้น (เจ้าบ้านชนะ, เสมอ, ทีมเยือนชนะ) และไม่ได้ใช้ราคาอัตราต่อรองของเจ้ามือเป็นตัวแปรหรือเป็นเกณฑ์เปรียบเทียบ จึงไม่สามารถสรุปได้ว่าแบบจำลองเหนือกว่าตลาดการพนัน

3) ข้อมูลมาจากหลายแหล่งที่เรียกชื่อทีมและชื่อนักเตะไม่เหมือนกัน จึงต้องใช้พจนานุกรมจับคู่ชื่อ (Name Mapping) ซึ่งอาจมีความคลาดเคลื่อนจากการเชื่อมข้อมูล และสโมสรที่จับคู่กับ Transfermarkt ไม่ได้จะมีค่าตัวแปรตารางแข่งขันเป็นค่าว่าง

4) ข้อมูลของ Understat ครอบคลุมเฉพาะนัดในลีก ดัชนีความเหนื่อยล้ารายผู้เล่นจึงอาจสูงเกินจริงสำหรับสโมสรที่ลงแข่งถ้วยหรือรายการยุโรปด้วย (ชดเชยบางส่วนด้วยตัวแปรตารางแข่งขันระดับทีมจาก Transfermarkt) และตัวแปรบางตัวที่มองไปข้างหน้า เช่น จำนวนวันถึงนัดถัดไป ใช้วันที่แข่งจริง ซึ่งอาจต่างจากที่ทราบก่อนเริ่มนัดในกรณีเลื่อนการแข่งขัน

5) โครงงานไม่ได้นำข้อมูลการบาดเจ็บหรือปัจจัยเชิงคุณภาพที่ไม่ปรากฏในสถิติ เช่น ขวัญกำลังใจ สภาพอากาศ สภาพสนาม หรือข่าวสารนอกสนาม มาร่วมวิเคราะห์

6) คะแนน Elo ของฤดูกาล 2014–2015 เริ่มจากค่าเท่ากันทุกทีม จึงมีความน่าเชื่อถือต่ำกว่าฤดูกาลหลัง ๆ

7) การดำเนินงานอยู่ภายใต้ระยะเวลาจำกัดประมาณ 6 สัปดาห์ และผลลัพธ์ที่ได้มีวัตถุประสงค์เพื่อการศึกษาเชิงสถิติเท่านั้น

## 1.4 ประโยชน์ที่คาดว่าจะได้รับ

1) ผู้จัดทำได้ฝึกปฏิบัติกระบวนการวิทยาการข้อมูลอย่างครบวงจรกับชุดข้อมูลกีฬาจริงที่มีความซับซ้อนและมาจากหลายแหล่ง

2) ได้ท่อส่งข้อมูลที่ตรวจสอบได้และทำซ้ำได้ (Reproducible) พร้อมแบบจำลองที่ทำนายความน่าจะเป็นของผลการแข่งขันได้ และทราบปัจจัยสำคัญที่มีผลต่อการแข่งขัน

3) ได้คำตอบเชิงประจักษ์ว่า ตัวแปรกลุ่มใด (Elo, ความเหนื่อยล้า, ตารางแข่งขัน, ฟอร์มผู้เล่น) ให้สัญญาณต่อการทำนายผลการแข่งขันมากที่สุด และแบบจำลองให้ผลดีกว่าค่าพื้นฐานมากน้อยเพียงใด [4, 3]

4) ได้แนวทางและองค์ความรู้ในการนำเทคนิค Data Science และการวิเคราะห์ Feature ไปประยุกต์ใช้กับข้อมูลกีฬาประเภทอื่น ๆ ต่อไป

# บทที่ 2
# ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

## 2.1 ทฤษฎีที่เกี่ยวข้อง

### 2.1.1 กระบวนการวิทยาการข้อมูลและการจัดทำท่อส่งข้อมูล (Data Science & Pipeline Process)

กระบวนการวิทยาการข้อมูลเป็นกรอบการทำงานเชิงระบบที่นำข้อมูลขนาดใหญ่มาประมวลผลและวิเคราะห์ เพื่อค้นหารูปแบบหรือสร้างคุณประโยชน์ ในโครงงานนี้ได้ประยุกต์ใช้กระบวนการ 5 ขั้นตอน ร่วมกับการออกแบบท่อส่งข้อมูลแบบโมดูลาร์ (Modular Data Pipeline) ได้แก่

1) **การ กำหนด วัตถุประสงค์ และ คำถาม วิจัย (Question Refinement):** กำหนดโจทย์ในการทำนายผลการแข่งขันฟุตบอลออกเป็น 3 รูปแบบ ได้แก่ ทีมเจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A)

2) **การเก็บรวบรวมข้อมูล (Data Collection):** การสร้างระบบดึงข้อมูลอัตโนมัติ เพื่อรวบรวมตารางการแข่งขัน ผลประตู ค่า xG และสถิติรายบุคคลของผู้เล่นจาก Understat และปฏิทินการแข่งขันทุกรายการของสโมสรจาก Transfermarkt รวมถึงชุดข้อมูลผลการแข่งขันพรีเมียร์ลีกจาก Kaggle [7, 6, 5]

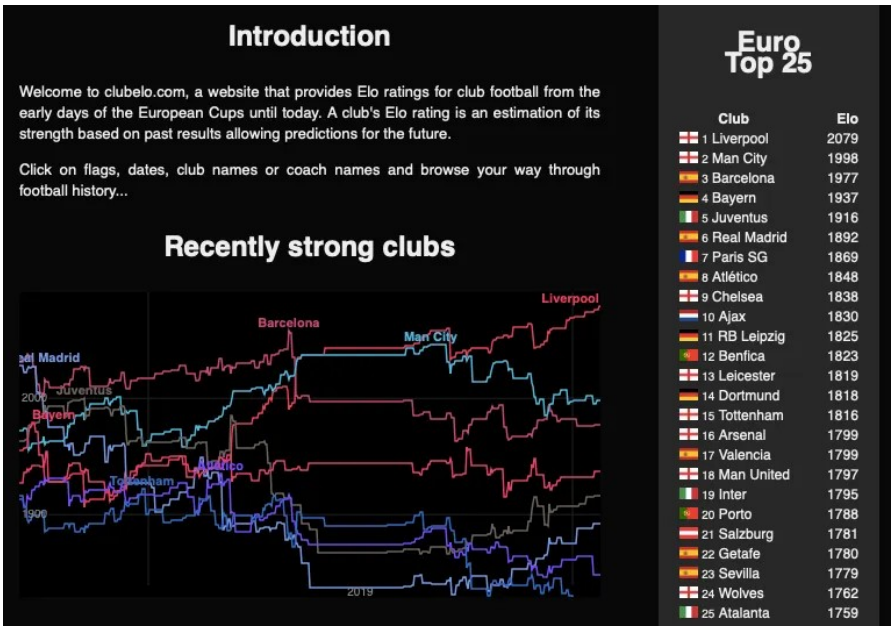
3) **การตรวจสอบ ทำความสะอาด และสร้างตัวแปร (Data Validation & Feature Engineering):** การตรวจสอบคุณภาพข้อมูลผ่านสัญญาข้อมูล (Data Contracts) การจัดการค่าที่ขาดหาย การจับคู่ชื่อสโมสร (Entity Resolution) และการสร้างตัวแปรก่อนการแข่งขัน เช่น คะแนน Elo, ดัชนีความเหนื่อยล้า, ความหนาแน่นของตารางแข่งขัน และฟอร์มของผู้เล่นตัวจริง

4) **การสร้างและประเมินแบบจำลอง (Model Building & Evaluation):** การพัฒนาแบบจำลองเพื่อทำนายความน่าจะเป็นของผลการแข่งขัน และประเมินประสิทธิภาพด้วยตัวชี้วัด Log Loss, Ranked Probability Score (RPS) และ Accuracy [8]

5) **การ สรุป และ วิเคราะห์ ผลลัพธ์ (Communication & Feature Analysis):** การสรุปผลการวิเคราะห์ เปรียบเทียบกับค่าพื้นฐานและงานวิจัยที่ผ่านมา และนำเสนอระดับความสำคัญของตัวแปรทำนาย (Feature Importance)

### 2.1.2 ระบบวัดระดับความแข็งแกร่ง (Elo Rating System)

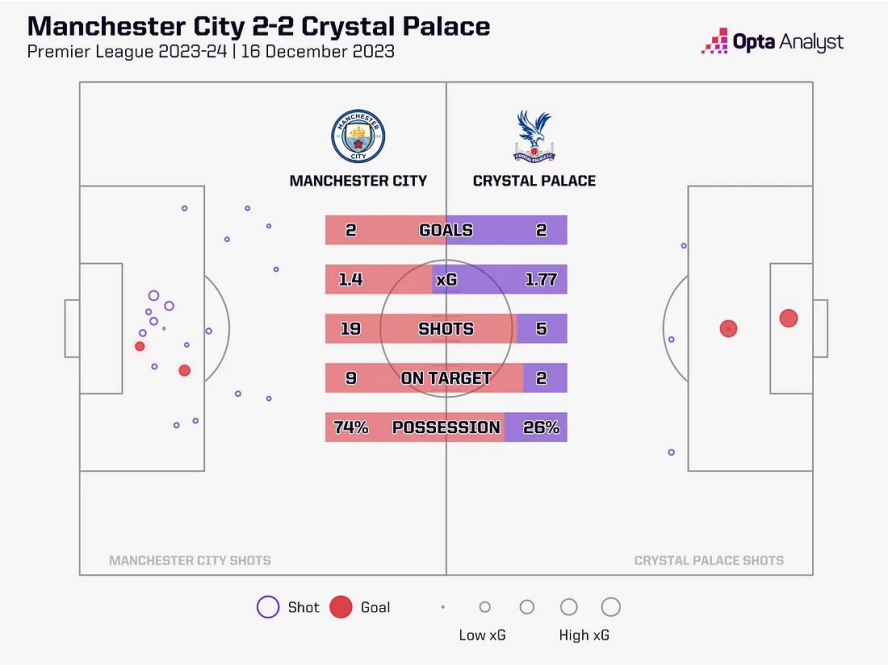
ระบบคะแนน Elo เป็นวิธีทางสถิติที่ใช้คำนวณระดับทักษะความแข็งแกร่งของทีมแข่งขัน คะแนนจะถูกปรับเปลี่ยนตามผลการแข่งขันจริงและระดับความแข็งแกร่งของคู่แข่ง โดยทีมที่ชนะทีมที่มีคะแนนสูงกว่าจะได้คะแนนเพิ่มขึ้นมากกว่าการชนะทีมที่อ่อนกว่า [2] สำหรับฟุตบอล การปรับคะแนนสามารถถ่วงน้ำหนักตามผลต่างประตูของการแข่งขันได้ เพื่อให้ชัยชนะที่ขาดลอยส่งผลต่อคะแนนมากกว่าชัยชนะเฉียดฉิว ในโครงงานนี้ได้มีการคำนวณค่า Elo Rating ของแต่ละสโมสรอย่างต่อเนื่องตามลำดับเวลา (Time-series) ดังแสดงในรูปที่ 1 และนำผลต่างคะแนน Elo (Elo Difference) ระหว่างทีมเจ้าบ้านและทีมเยือน ซึ่งใช้ค่าก่อนเริ่มการแข่งขันเท่านั้น มาใช้เป็นตัวแปรสำคัญในการสะท้อนความได้เปรียบเชิงศักยภาพของทีม




**ภาพที่ 1** ตัวอย่างแผนภาพแสดงการปรับปรุงคะแนน Elo Rating ของสโมสรฟุตบอลตามผลการแข่งขันย้อนหลัง (ที่มา: ClubElo)

### 2.1.3 ค่าความคาดหวังในการทำประตู (Expected Goals: xG)

ค่า xG เป็นตัวชี้วัดเชิงสถิติขั้นสูงที่ใช้ประเมินคุณภาพของโอกาสในการยิงประตู โดยคำนวณความน่าจะเป็นที่ลูกยิงแต่ละครั้งจะกลายเป็นประตู (มีค่าระหว่าง 0 ถึง 1) ขึ้นอยู่กับตำแหน่งการยิง มุมในการยิง ประเภทการส่งบอล และบริบทของเกม ดังแสดงตัวอย่างในรูปที่ 2 ค่า xG ช่วยให้มองเห็นประสิทธิภาพเกมรุกที่แท้จริง ซึ่งสะท้อนฟอร์มการเล่นได้ดีกว่าผลสกอร์แพ้-ชนะแบบดั้งเดิม [5] ในโครงงานนี้ ค่า xG และค่า xA (Expected Assists) รายบุคคลถูกนำมาสรุปเป็นฟอร์มของผู้เล่นตัวจริงแต่ละคน ในรูปอัตราต่อ 90 นาที โดยใช้เฉพาะการแข่งขันก่อนนัดปัจจุบัน



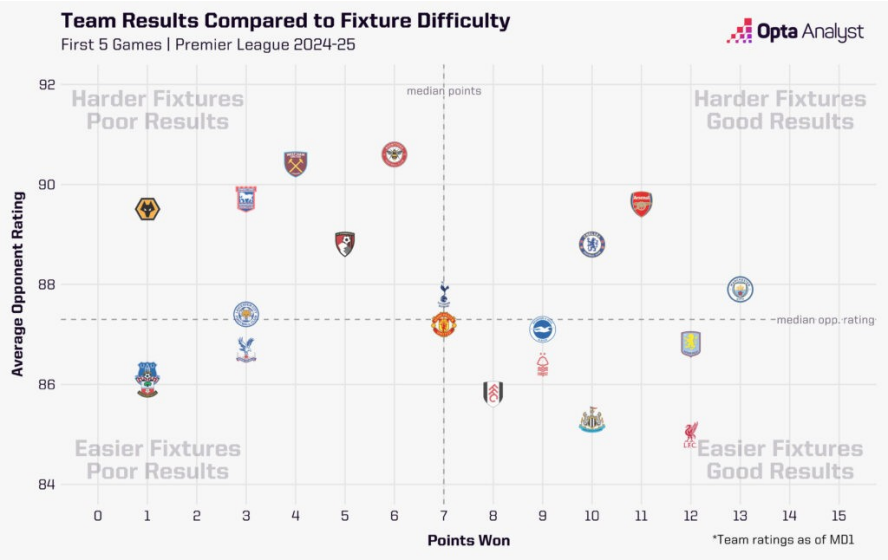

**ภาพที่ 2** ตัวอย่างการประเมินค่าความคาดหวังในการทำประตู (Expected Goals: xG) จากตำแหน่งการยิง (ที่มา: Opta Analyst)

### 2.1.4 ดัชนีความเหนื่อยล้าและความหนาแน่นของตารางแข่ง (Fatigue Metric & Schedule Congestion)

ระยะ เวลา พัก ผ่อน ระ หว่าง แมตช์ การ แข่งขัน ส่ง ผล ต่อ สภาพ ร่างกาย และประสิทธิภาพการเล่นของนักเตะ ในโครงงานนี้จึงสร้างตัวแปรที่เกี่ยวข้องกับภาระการเล่นเป็น 2 ระดับ ดังแสดงตัวอย่างแนวคิดในรูปที่ 3

1) **ระดับผู้เล่น:** คำนวณคะแนนความเหนื่อยล้า (Fatigue Score) ช่วง 0–100 จากนาทีที่ลงเล่นใน 7 วันก่อนหน้า ความสั้นของระยะพัก จำนวนนัดที่ลงเล่นติดต่อกัน และอัตราส่วนภาระงานระยะสั้นต่อระยะยาว (Acute-to-Chronic Workload Ratio) แล้วสรุปเป็นค่าเฉลี่ยของผู้เล่นตัวจริงแต่ละฝั่ง

2) **ระดับทีม:** คำนวณจากปฏิทินการแข่งขันทุกรายการ ได้แก่ จำนวนวันพักนับจากนัดก่อนหน้า จำนวนนัดใน 7 และ 14 วันที่ผ่านมา จำนวนนัดที่ไม่ใช่ลีกใน 14 วัน และการเดินทางไปเยือนในศึกยุโรปในนัดก่อนหน้า




**ภาพที่ 3** ตัวอย่างการวิเคราะห์ความตึงเครียดของโปรแกรมแข่งขัน

### 2.1.5 อัตราต่อรองของเจ้ามือรับพนัน (Betting Market Odds) ในฐานะเกณฑ์อ้างอิงของงานวิจัย

อัตราต่อรองในตลาดเดิมพันสามารถแปลงเป็นค่าความน่าจะเป็นโดยนัย (Implied Probability) ซึ่งงานวิจัยหลายฉบับใช้เป็นเกณฑ์อ้างอิงมาตรฐาน (Benchmark) ในการวัดประสิทธิภาพของแบบจำลองทำนายผลฟุตบอล เนื่องจากสะท้อนข้อมูลและสภาพตลาดจริง [4] อย่างไรก็ตาม โครงงานนี้**ไม่ได้ใช้อัตราต่อรองเป็นตัวแปรนำเข้าหรือเป็นเกณฑ์เปรียบเทียบ** แต่นำมากล่าวถึงเพื่อเป็นบริบทในการอ่านผลการศึกษาของงานวิจัยที่ผ่านมา

### 2.1.6 การจับคู่และแปลงชื่อเอนทิตีให้เป็นมาตรฐาน (Entity Resolution)

เนื่องจากข้อมูลถูกรวบรวมมาจากหลายแหล่งข้อมูลภายนอก ทำให้ชื่อสโมสรฟุตบอลเดียวกันอาจถูกบันทึกด้วยข้อความที่แตกต่างกัน (เช่น `"Man Utd"`, `"Manchester Utd"` และ `"Manchester United"`) กระบวนการ Entity Resolution จึงถูกนำมาใช้เพื่อปรับแปลงชื่อทีมจากทุกแหล่งข้อมูลให้อยู่ในรูปแบบมาตรฐาน (Canonical Team Names) ผ่านพจนานุกรมเทียบเคียงชื่อ (Alias Mapping) เพื่อให้สามารถเชื่อมโยงข้อมูล (Data Joining) จากต่างแหล่งได้ ทั้งนี้ สโมสรที่ไม่สามารถจับคู่ได้จะมีตัวแปรที่ต้องอาศัยแหล่งนั้นเป็นค่าว่าง

### 2.1.7 แบบจำลองทำนายผลการแข่งขัน

การทำนายผลการแข่งขันฟุตบอลถูกกำหนดให้เป็นโจทย์ที่ให้ผลลัพธ์เป็นความน่าจะเป็นของ 3 กลุ่ม ได้แก่ ทีมเจ้าบ้านชนะ (H), เสมอ (D) และทีมเยือนชนะ (A) โครงงานนี้ใช้แบบจำลอง 2 แนวทางที่มีบทบาทต่างกัน ดังนี้

(0.1) 1) แบบจำลอง Double Poisson และการแก้ไขแบบ Dixon-Coles

จำนวนประตูของทีมเจ้าบ้านและทีมเยือนถูกจำลองเป็นตัวแปรสุ่มแบบปัวซง (Poisson) สองตัว โดยให้ค่าลอการิทึมของอัตราการทำประตูเป็นฟังก์ชันเชิงเส้นของผลต่างคะแนน Elo ก่อนการแข่งขัน (หารด้วย 400) ซึ่งประมาณค่าด้วย Poisson Regression จากนั้นนำความน่าจะเป็นของสกอร์ทุกค่ามาสร้างตารางร่วม (Score Grid) แล้วรวมเป็นความน่าจะเป็นของ H, D และ A การแก้ไขแบบ Dixon-Coles [1] ปรับความน่าจะเป็นของสกอร์ต่ำ (0–0, 1–0, 0–1 และ 1–1) ด้วยพารามิเตอร์ $\rho$ เพื่อแก้ปัญหาที่การแจกแจงปัวซงอิสระประเมินความน่าจะเป็นของสกอร์เหล่านี้คลาดเคลื่อน โดยในโครงงานนี้เลือกค่า $\rho$ จากช่วงที่กำหนดด้วยค่าความควรจะเป็นสูงสุด การทำนายใช้วิธี Walk-forward คือทำนายแต่ละฤดูกาลด้วยแบบจำลองที่ฝึกจากฤดูกาลก่อนหน้าเท่านั้น

(0.2) 2) Gradient Boosting

เป็นเทคนิค Ensemble Learning ที่สร้างต้นไม้ตัดสินใจขนาดเล็กหลายต้นต่อเนื่องกัน โดยแต่ละต้นเรียนรู้แก้ไขความคลาดเคลื่อนของต้นก่อนหน้า ในโครงงานนี้ใช้ `HistGradientBoostingClassifier` ของ Scikit-learn [8] เป็นแบบจำลองสำหรับวัดว่าตัวแปรกลุ่มใดให้สัญญาณต่อการทำนายผล โดยใช้วิธี Permutation Importance

(0.3) 3) Permutation Importance

วัดความสำคัญของตัวแปรจากระดับที่ค่า Log Loss บนชุดทดสอบเพิ่มขึ้นเมื่อสลับค่าของตัวแปรนั้นแบบสุ่มโดยไม่เปลี่ยนค่าอื่น ตัวแปรที่เมื่อถูกสลับแล้วทำให้ Log Loss เพิ่มมากแสดงว่าให้ข้อมูลสำคัญต่อแบบจำลอง เนื่องจากตัวแปรผู้เล่นตัวจริง 22 ตำแหน่งมีความสัมพันธ์กันสูง จึงสลับค่าเป็นกลุ่มพร้อมกัน แทนการสลับทีละคอลัมน์

(0.4) 4) ตัวชี้วัดประสิทธิภาพ

**Log Loss** วัดคุณภาพของความน่าจะเป็นที่ทำนาย (ยิ่งต่ำยิ่งดี) **Ranked Probability Score (RPS)** วัดความคลาดเคลื่อนของการแจกแจงสะสมของผลลัพธ์ที่เรียงลำดับ (ชนะ-เสมอ-แพ้) และ **Accuracy** วัดสัดส่วนที่ทำนายผลที่มีความน่าจะเป็นสูงสุดถูกต้อง โดยใช้ความน่าจะเป็นตามสัดส่วนผลการแข่งขันในอดีต (Class Prior) เป็นเกณฑ์เปรียบเทียบพื้นฐาน

### 2.1.8 การทดสอบสมมติฐานทางสถิติ

โครงงานนี้ใช้การทดสอบสมมติฐานเพื่อตรวจสอบข้อสังเกตเชิงปริมาณก่อนสร้างแบบจำลอง ได้แก่ การทดสอบ Paired t-test และ Wilcoxon Signed-rank Test (ทางเลือกที่ไม่ต้องสมมติว่าข้อมูลแจกแจงปกติ) เพื่อเปรียบเทียบจำนวนประตูของทีมเจ้าบ้านกับทีมเยือน และสัมประสิทธิ์สหสัมพันธ์ของ Pearson และ Spearman เพื่อวัดความสัมพันธ์ระหว่างผลต่างคะแนน Elo กับผลต่างประตู โดยกำหนดระดับนัยสำคัญที่ 0.05

## 2.2 งานวิจัยที่เกี่ยวข้อง

ในส่วนนี้เป็นการทบทวนวรรณกรรมและงานวิจัยที่นำเทคนิควิทยาการข้อมูลและการเรียนรู้ของเครื่องมาใช้ในการทำนายผลกีฬา เพื่อหาแนวทางและช่องว่างในการพัฒนาโครงงาน

### 2.2.1 การทำนายผลฟุตบอลด้วยแบบจำลองเชิงสถิติและอัตราต่อรอง

งานวิจัยยุคแรกมักใช้สถิติการแข่งขันย้อนหลัง เช่น จำนวนประตูที่ทำได้ ฟอร์มเหย้า-เยือน ผ่านโมเดลเชิงสถิติตระกูล Poisson [1] หรือระบบจัดอันดับ Rating [2, 9] ซึ่งจากการประเมินและทบทวนวรรณกรรมย้อนหลัง 40 ปีโดย Hubáček และคณะ [4] ที่ทดสอบกับชุดข้อมูลกว่า 2.1 แสนนัด พบว่าแบบจำลองที่ใช้เพียงผลสกอร์ย้อนหลังมีขีดจำกัดความแม่นยำอยู่เพียงร้อยละ 47.8–48.6 เท่านั้น ในขณะที่ราคาอัตราต่อรองจากตลาดเดิมพันกลับให้ความแม่นยำสูงกว่า (ประมาณร้อยละ 53–55) เนื่องจากสะท้อนข้อมูลเชิงลึกในตลาดได้อย่างรวดเร็ว อย่างไรก็ตาม การใช้เพียงอัตราต่อรองอย่างเดียวจะไม่สามารถอธิบายปัจจัยภายในหรือบริบทการเล่นของทีมได้ครบถ้วน

### 2.2.2 การใช้ Machine Learning ร่วมกับตัวแปรสถิติเชิงลึกและข้อมูลบริบท

งานวิจัยจำนวนมากใช้สถิติการครองบอล การยิงประตู และฟอร์มย้อนหลังเป็นตัวแปรสำหรับแบบจำลองการเรียนรู้ของเครื่อง อย่างไรก็ตาม งานวิจัยส่วนใหญ่มักมองข้ามข้อมูลระดับผู้เล่นและบริบทของตารางแข่งขัน เช่น ไลน์อัปตัวจริง ภาระการเล่นสะสมของนักเตะ และการแข่งขันรายการอื่นที่ทีมต้องลงเล่น ซึ่ง Berrar และคณะ [3] ได้ชี้ให้เห็นว่าการดึงความรู้เฉพาะทางและบริบทแวดล้อม (Domain Knowledge) เช่น สถิติ xG และไลน์อัปตัวจริง เข้ามาประกอบ จะช่วยให้แบบจำลองทำนายผลได้แม่นยำยิ่งขึ้น

### 2.2.3 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรม สามารถสรุปเปรียบเทียบองค์ประกอบระหว่างแนวทางงานวิจัยทั่วไปกับโครงงานนี้ได้ดังตารางที่ 1

**ตารางที่ 1** การเปรียบเทียบองค์ประกอบของงานวิจัยที่เกี่ยวข้องกับโครงงานนี้

| การศึกษา / โครงงาน | สถิติผลสกอร์ | อัตราต่อรอง | Elo / xG | ไลน์อัป / ฟอร์มผู้เล่น | ความเหนื่อยล้า / ตารางแข่ง |
|---|---|---|---|---|---|
| งานวิจัยที่เน้นสถิติการแข่งขัน [1, 4] | ✓ | – | – | – | – |
| งานวิจัยที่เน้นอัตราต่อรองตลาด [9] | ✓ | ✓ | – | – | – |
| งานวิจัยใช้แบบจำลอง ML เบื้องต้น [2, 3] | ✓ | – | ✓ | – | – |
| **โครงงานนี้** | ✓ | – | ✓ | ✓ | ✓ |

จากตารางที่ 1 จะเห็นว่าโครงงานนี้บูรณาการสถิติการแข่งขัน ตัวชี้วัดขั้นสูง (Elo, xG) ฟอร์มรายบุคคลของผู้เล่นตัวจริง ดัชนีความเหนื่อยล้า และความหนาแน่นของตารางแข่งขันที่รวมการแข่งขันทุกรายการ เข้าด้วยกัน เพื่อวิเคราะห์ปัจจัยที่มีผลต่อการแข่งขัน โดยไม่ได้ใช้อัตราต่อรองเป็นตัวแปร

## 2.3 เครื่องมือและเทคโนโลยีที่ใช้

### 2.3.1 ภาษา Python และไลบรารีสำหรับการประมวลผลข้อมูล

ภาษา Python เป็นภาษาหลักที่ใช้ในการดำเนินโครงงาน เนื่องจากมีระบบนิเวศของไลบรารีที่สนับสนุนงานด้าน Data Science และ Data Engineering อย่างครบถ้วน ได้แก่

1) **Polars, DuckDB และ PyArrow:** ใช้สำหรับการจัดการ ทำความสะอาด และ ประมวล ผล ตาราง ข้อมูล ประสิทธิภาพ สูง (High-performance DataFrames)

2) **Pandera และ Pydantic:** ใช้สำหรับการตรวจสอบความถูกต้องของโครงสร้างข้อมูล (Data Schema Validation & Data Contracts) และการตรวจสอบไฟล์ตั้งค่าของระบบ

3) **Soccerdata:** ใช้ ดึง ข้อมูล จาก แหล่ง ข้อมูล ฟุตบอล สาธารณะ เช่น Understat

4) **Scikit-learn และ SciPy:** ใช้พัฒนาแบบจำลอง (Poisson Regression, Gradient Boosting) การ คำนวณ ตัว ชี้ วัด และ การ ทดสอบ สมมติฐานทางสถิติ [8]

5) **Matplotlib:** ใช้ทำ Data Visualization เพื่อสำรวจข้อมูลและแสดงผลการวิเคราะห์

6) **FastAPI และ Uvicorn:** ใช้พัฒนา API สำหรับเรียกดูตารางข้อมูลที่ผ่านการทำความสะอาดและผลการทำนายของแบบจำลอง

### 2.3.2 สภาพแวดล้อมและการประกันคุณภาพซอฟต์แวร์ (Development Environment & Quality Control)

1) **ระบบบริหารจัดการสภาพแวดล้อมเสมือน (uv) และ Docker: uv** บริหารจัดการ Virtual Environment และไลบรารีความเร็วสูง พร้อมไฟล์ล็อกรุ่นของไลบรารี ส่วน Docker ช่วยให้รันท่อส่งข้อมูลและ API ได้ในสภาพแวดล้อมเดียวกัน

2) **ระบบ ทดสอบ ซอฟต์แวร์ และ ตรวจ สอบ โค้ด อัตโนมัติ:** ใช้ Pytest (พร้อม รายงาน ความ ครอบคลุม ของ การ ทดสอบ) และ Hypothesis สำหรับชุดทดสอบอัตโนมัติ ใช้ Ruff และ Pyright สำหรับตรวจรูปแบบและชนิดข้อมูลของโค้ด ใช้ pre-commit และ GitHub Actions ตรวจสอบก่อนบันทึกและทุกครั้งที่ส่งโค้ดขึ้นระบบ

3) **เอกสารประกอบ:** ใช้ MkDocs จัดทำเอกสารอธิบายขั้นตอนของท่อส่งข้อมูล โครงสร้างตาราง (Schema) และคำสั่งที่ใช้งาน

4) **แหล่งชุดข้อมูลสาธารณะ (Understat, Transfermarkt, Kaggle):** เป็นแหล่งข้อมูลผลการแข่งขัน ค่า xG สถิติรายบุคคลของผู้เล่น ปฏิทินการแข่งขันของสโมสร และผลการแข่งขันพรีเมียร์ลีกย้อนหลัง [7, 6, 5]

# บทที่ 3
# วิธีการดำเนินโครงงาน

ในการดำเนินโครงงาน "การวิเคราะห์และทำนายผลการแข่งขันฟุตบอลพรีเมียร์ลีกอังกฤษด้วยกระบวนการวิทยาการข้อมูล (English Premier League Match Analysis and Prediction Using Data Science Process)" ผู้จัดทำได้ออกแบบและพัฒนาท่อส่งข้อมูลเชิงโมดูลาร์ (Modular Data Pipeline) ตามกระบวนการวิทยาการข้อมูล เพื่อให้ระบบสามารถประมวลผลข้อมูลที่มีความซับซ้อน ป้องกันปัญหาข้อมูลอนาคตรั่วไหล (Data Leakage) และรองรับการทดสอบคุณภาพระบบอย่างเป็นระบบ โดยแบ่งขั้นตอนการดำเนินงานออกเป็น 6 ส่วนหลัก ดังนี้

1) การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน
2) การเก็บรวบรวมข้อมูล (Data Collection)
3) การทำความสะอาดข้อมูล และการตรวจสอบความถูกต้อง (Data Cleaning, Schema Validation & Entity Resolution)
4) การวิศวกรรมฟีเจอร์ (Feature Engineering)
5) การพัฒนาแบบจำลอง การแบ่งชุดข้อมูล และกรอบการประเมินผล (Model Development & Evaluation Framework)
6) การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance)

## 3.1 การวิเคราะห์และกำหนดแนวทางการพัฒนาโครงงาน

การทำนายผลการแข่งขันฟุตบอลมีความซับซ้อนสูงเนื่องจากปัจจัยรอบด้านที่ส่งผลต่อผลการแข่งขัน โครงงานนี้จึงมุ่งเน้นการใช้ประโยชน์จากข้อมูลที่ทราบก่อนเริ่มการแข่งขันเท่านั้น โดยมีแนวทางการดำเนินงานดังนี้

1) **ศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้อง:** ศึกษาหลักการคำนวณระบบประเมินศักยภาพเชิงสัมพัทธ์ (Elo Rating System) [2], ค่าความคาดหวังในการทำประตู (Expected Goals: xG) [5], แบบจำลองปัวซงสำหรับจำนวนประตู [1], การคำนวณดัชนีความเหนื่อยล้าสะสม (Fatigue Index) และการทำวิศวกรรมฟีเจอร์แบบอนุกรมเวลา (Time-Series Feature Engineering)

2) **กำหนดขอบเขตและเป้าหมายการทำนาย:** กำหนดเป้าหมายการทำนายผลการแข่งขันออกเป็น 3 ผลลัพธ์ ได้แก่ เจ้าบ้านชนะ (Home Win: H), เสมอ (Draw: D) และทีมเยือนชนะ (Away Win: A) โดยทำนายเป็นความน่าจะเป็นของแต่ละผลลัพธ์

3) **กำหนดเครื่องมือและสภาพแวดล้อมการพัฒนา:** พัฒนาระบบด้วยภาษา Python 3.14 ขึ้นไป ร่วมกับเครื่องมือบริหารจัดการสภาพแวดล้อมเสมือน (**uv**), ไลบรารีวิเคราะห์ข้อมูลตาราง (Polars), เครื่องมือตรวจสอบสัญญาข้อมูล (Pandera และ Pydantic), ไลบรารีเรียนรู้ของเครื่อง (Scikit-learn), ระบบทดสอบซอฟต์แวร์อัตโนมัติ (Pytest) และระบบตรวจทานคุณภาพโค้ด (Ruff และ Pyright)

## 3.2 การเก็บรวบรวมข้อมูล (Data Collection)

ผู้จัดทำได้พัฒนาระบบดึงข้อมูลอัตโนมัติ (คำสั่ง `collect_data`) เพื่อรวบรวมข้อมูลจากแหล่งข้อมูลสาธารณะ ซึ่งทุกตัวดึงข้อมูลทำงานตามหลักการเดียวกัน 2 ข้อ คือ (1) สามารถเริ่มต่อได้ (Resumable) โดยข้ามไฟล์ที่มีอยู่แล้ว และ (2) ตรวจสอบก่อนบันทึก โดยเขียนข้อมูลลงไฟล์ชั่วคราวก่อน อ่านกลับมาตรวจกับโครงสร้างข้อมูลดิบ (Raw Schema) แล้วจึงเปลี่ยนชื่อเป็นไฟล์จริง ทำให้แหล่งข้อมูลที่เปลี่ยนรูปแบบไปล้มเหลวตั้งแต่ตอนดาวน์โหลดและไม่ทิ้งไฟล์ที่ไม่สมบูรณ์ไว้

1) **ตารางการแข่งขัน Understat:** ดึงผ่านไลบรารี soccerdata ครอบคลุม 5 ลีกใหญ่ ตั้งแต่ฤดูกาล 2014–2015 ประกอบด้วยผลประตู ค่า xG และรหัสนัดการแข่งขัน [5]

2) **สถิติรายบุคคล Understat:** ผู้เล่นแต่ละคนในแต่ละนัด ได้แก่ นาทีที่ลงเล่น ตำแหน่ง ประตู xG และ xA โดยเก็บแยกไฟล์ตามลีกและฤดูกาล [5]

3) **Transfermarkt:** ดาวน์โหลดชุดข้อมูล *dcaribou/transfermarkt-datasets* แล้วส่งออกตารางรายการแข่งขัน ตารางการแข่งขันทุกรายการ (ลีก ถ้วย และยุโรป) ของสโมสรที่เคยเล่นในลีกที่กำหนด และตารางการลงสนามของผู้เล่น (เก็บย้อนหลังเพิ่ม 1 ฤดูกาลเพื่อให้ช่วงต้นมีข้อมูลสำหรับคำนวณค่าเฉลี่ยย้อนหลัง) [6]

4) **Kaggle:** ชุดข้อมูลผลการแข่งขันพรีเมียร์ลีก 2000–2025 ใช้สำหรับสำรวจข้อมูลและทดสอบสมมติฐานทางสถิติ [7]

## 3.3 การทำความสะอาดข้อมูลและการตรวจสอบความถูกต้อง

### 3.3.1 ขั้นตอนการทำความสะอาด (Data Cleaning)

คำสั่ง `clean_data` แปลงไฟล์ข้อมูลดิบเป็นตารางสะอาด 4 ตาราง ได้แก่ ตารางนัดการแข่งขันของ Understat (หนึ่งแถวต่อหนึ่งนัดลีก), ตารางสถิติผู้เล่นรายนัด, ตารางการแข่งขันทุกรายการของ Transfermarkt พร้อมประเภทรายการ (ลีก ถ้วยในประเทศ ยุโรป หรืออื่น ๆ) และตารางจับคู่สโมสร โดยมีขั้นตอนหลักดังนี้

1) เก็บเฉพาะนัดที่แข่งจบแล้ว และเพิ่มปีเริ่มต้นฤดูกาล (เช่น **1415** เป็น 2014)

2) แปลงชื่อสโมสรทุกชื่อเป็นชื่อมาตรฐาน (ดูหัวข้อ Entity Resolution)

3) แปลงสตริงแผนการเล่น (Formation) เช่น `4-2-3-1` เป็นตัวเลขจำนวนแนวรับ แนวกลาง และแนวรุก โดยแผนที่แปลงไม่ได้จะเป็นค่าว่าง

4) เชื่อมนัดของ Understat กับนัดของ Transfermarkt

### 3.3.2 การจับคู่และแปลงชื่อเอนทิตีให้เป็นมาตรฐาน (Entity Resolution)

ชื่อสโมสรในแต่ละแหล่งข้อมูลมีการบันทึกไม่ตรงกัน เช่น `"Man Utd"`, `"Manchester Utd"` และ `"Manchester United"` ระบบจึงใช้พจนานุกรมเทียบเคียงชื่อ (Alias Table) แปลงเป็นชื่อมาตรฐาน และตรวจว่าชื่อทุกชื่ออยู่ในพจนานุกรม หากพบชื่อที่ไม่รู้จักจะหยุดพร้อมรายงานข้อผิดพลาด ส่วนการจับคู่ระหว่างรหัสสโมสรของ Transfermarkt กับชื่อทีมของ Understat ใช้วิธีเรียนรู้จากตัวนัดการแข่งขันเอง แทนการเทียบชื่อ โดยถือว่านัดสองฝั่งเป็นนัดเดียวกันเมื่อลีกและสกอร์ตรงกันและวันที่ห่างกันไม่เกิน 1 วัน แล้วจับคู่รหัสสโมสรกับทีมของ Understat ที่ตรงกันบ่อยที่สุด ขั้นตอนนี้จะล้มเหลวพร้อมรายงานแถวที่น่าสงสัยเมื่อมีสโมสรสองรหัสจับคู่กับทีมเดียวกัน หรือสโมสรที่มีนัดลีกอย่างน้อย 10 นัดมีนัดที่สนับสนุนการจับคู่น้อยกว่าร้อยละ 90

### 3.3.3 การ ตรวจ สอบ ความ ถูก ต้อง ของ ข้อ ตกลง ข้อมูล (Data Schema Validation)

ระบบประยุกต์ใช้แนวคิดสัญญาข้อมูล (Data Contracts) ด้วย Pandera โดยทุกขั้นตอนตรวจข้อมูลขาเข้าและขาออกกับโครงสร้างที่กำหนด แบ่งได้ 3 ระดับ ดังนี้

- **โครงสร้าง ข้อมูล ดิบ (Raw Schema):** ตรวจ ไฟล์ ข้อมูล ดิบ ตอนดาวน์โหลดและตอนอ่านเข้าสู่ขั้นตอนทำความสะอาด
- **โครงสร้าง ข้อมูล ระหว่าง ทาง (Step Schema):** ทุก ขั้น ตอน การทำความสะอาดและการสร้างฟีเจอร์ตรวจประเภทข้อมูลและขอบเขตค่าของผลลัพธ์ของตนเอง
- **โครงสร้างข้อมูลสุดท้าย (Clean Schema):** คำสั่ง `check_clean` ตรวจไฟล์ CSV ทุกไฟล์ในโฟลเดอร์ข้อมูลสะอาดกับ Schema ของตาราง

เมื่อขั้นตอนใดมีหลายข้อผิดพลาดพร้อมกัน ระบบรวบรวมและรายงานทุกข้อผิดพลาดพร้อมกัน แทนการหยุดที่ข้อผิดพลาดแรก

## 3.4 การวิศวกรรมฟีเจอร์ (Feature Engineering)

สถาปัตยกรรมของระบบเป็นท่อส่งข้อมูลแบบโมดูลาร์ที่รันด้วยคำสั่งตามลำดับ ดังตารางที่ 2

ฟีเจอร์ทุก ตัว ใช้ เฉพาะ ข้อมูล ที่ ทราบ ณ เวลา เริ่ม การ แข่งขัน โดย หน้าต่าง ค่า เฉลี่ย ย้อน หลัง ไม่ รวม นัด ปัจจุบัน และ คะแนน Elo ใช้ ค่า ก่อน แข่ง ผลลัพธ์ รวม เป็น ตาราง `match_features.csv` หนึ่งแถวต่อหนึ่งนัด ส่วนค่าที่ไม่มีข้อมูลจะเป็นค่าว่าง และมีตาราง `missing.csv` บันทึกสาเหตุของแต่ละค่าว่าง เช่น ไม่มีรายชื่อผู้เล่นตัวจริง หรือผู้เล่น

**ตารางที่ 2** สถาปัตยกรรมโมดูลการประมวลผลข้อมูลในระบบ (Data Pipeline Modules)

| ลำดับ | คำสั่ง / โมดูล | หน้าที่การทำงานหลัก |
|---|---|---|
| 1 | `collect_data` | ดึงข้อมูลดิบจาก Understat และ Transfermarkt พร้อมตรวจ Raw Schema |
| 2 | `clean_data` (Clean) | ทำความสะอาด แปลงชื่อสโมสร จับคู่นัดระหว่างแหล่งข้อมูล |
| 3 | `clean_data` (Features) | คำนวณ Elo, ความเหนื่อยล้า, ตารางแข่งขัน, ฟอร์มผู้เล่น แล้วรวมเป็นตารางสำหรับโมเดล |
| 4 | `check_clean` | ตรวจไฟล์ผลลัพธ์ทุกไฟล์กับ Schema |
| 5 | `feature_importance` | ฝึกแบบจำลอง Gradient Boosting และวัดความสำคัญของตัวแปร |
| 6 | `api` | ให้บริการตารางข้อมูลและผลการทำนายแบบ Walk-forward ผ่าน HTTP |

ลงสนามน้อยกว่า 270 นาที

### 3.4.1 การคำนวณคะแนนความแข็งแกร่งเชิงสัมพัทธ์ (Elo Rating Calculation)

ระบบเล่นซ้ำผลการแข่งขันลีกทุกนัดตามลำดับวันที่ และบันทึกคะแนน Elo ของแต่ละทีมก่อนเริ่มนัด ($R_H$ และ $R_A$) โดยให้ผลต่างคะแนน $\Delta R = R_H - R_A$ ไม่รวมความได้เปรียบของเจ้าบ้าน ค่าคะแนนที่คาดหวังของเจ้าบ้าน ($E_H$) รวมความได้เปรียบของเจ้าบ้าน ($h$) และการปรับปรุงคะแนนหลังจบนัดคำนวณได้จากสมการที่ (1) และ (2)

$$E_H = \frac{1}{1 + 10^{-(R_H + h - R_A)/400}} \tag{1}$$

$$R'_H = R_H + K \cdot G \cdot (S_H - E_H), \qquad R'_A = R_A - K \cdot G \cdot (S_H - E_H) \tag{2}$$

โดยที่ $S_H$ คือผลการแข่งขันจริงของเจ้าบ้าน ($1$ เมื่อชนะ, $0.5$ เมื่อเสมอ, $0$ เมื่อแพ้), $K = 15$ คือขนาดการปรับ, $h = 40$ คะแนน คือความได้เปรียบของเจ้าบ้าน และ $G$ คือตัวคูณตามผลต่างประตู $|gd|$ ซึ่งมีค่า $1$ เมื่อ $|gd| \leq 1$, $1.5$ เมื่อ $|gd| = 2$ และ $(11 + |gd|)/8$ เมื่อ $|gd| \geq 3$ คะแนนเริ่มต้นเท่ากับ 1500 ทีมที่เลื่อนชั้นขึ้นมาในแต่ละฤดูกาลเริ่มที่ค่าเฉลี่ยคะแนนของทีมที่ตกชั้นในฤดูกาลก่อนหน้า เพื่อให้คะแนนเฉลี่ยของลีกคงที่ และทุกทีมเริ่มเท่ากันในฤดูกาล 2014–2015 จึงถือเป็นช่วงเริ่มต้น (Warm-up) ค่าพารามิเตอร์ปรับจูนด้วย Log Loss แบบ Walk-forward บนฤดูกาล 2005/06–2014/15 โดยพบว่าผลไม่ไวต่อค่า $K$ ในช่วง 10–20 และความได้เปรียบของเจ้าบ้านในช่วง 20–80 ตัวอย่างขั้นตอนการคำนวณแสดงดังรายการที่ 3.1

```python
def goal_multiplier(gd: int) -> float:
    gd = abs(gd)
    if gd <= 1:
        return 1.0
    if gd == 2:
        return 1.5
    return (11 + gd) / 8

def update_elo(r_home, r_away, home_goals, away_goals, k=15.0, home_adv=40.0):
    # expected score of the home side (home advantage included)
    expected = 1 / (1 + 10 ** (-(r_home + home_adv - r_away) / 400))
    # actual score: win 1, draw 0.5, loss 0
    if home_goals > away_goals:
        actual = 1.0
    elif home_goals == away_goals:
        actual = 0.5
    else:
        actual = 0.0
    delta = k * goal_multiplier(home_goals - away_goals) * (actual - expected)
    return r_home + delta, r_away - delta
```

Listing 3.1: ฟังก์ชันการคำนวณและปรับปรุงคะแนน Elo Rating

### 3.4.2 การคำนวณดัชนีความเหนื่อยล้าสะสม (Fatigue Index Calculation)

ระบบคำนวณความเหนื่อยล้าเป็นรายผู้เล่น จากภาระการเล่นก่อนเริ่มนัด ได้แก่ จำนวนวันพัก จำนวนนัดและนาทีที่ลงเล่นใน 7 วัน นาทีที่ลงเล่นใน 28 วัน และจำนวนนัดที่ทีมลงเล่นติดต่อกัน แล้วรวมเป็นคะแนนความเหนื่อยล้า (Fatigue Score) ช่วง 0–100 ด้วยน้ำหนักที่กำหนดเอง ดังตารางที่ 3 จากนั้นสรุปเป็นค่าเฉลี่ยของผู้เล่นตัวจริงแต่ละฝั่ง และผลต่างระหว่างสองฝั่ง

**ตารางที่ 3** องค์ประกอบของคะแนนความเหนื่อยล้ารายผู้เล่น

| น้ำหนัก | องค์ประกอบ (ปรับให้อยู่ในช่วง 0–1) |
|---|---|
| 0.35 | นาทีที่ลงเล่นใน 7 วันก่อนหน้า (180 นาทีถือว่าเต็ม) |
| 0.25 | ระยะพักสั้น |
| 0.20 | จำนวนนัดที่ลงเล่นติดต่อกัน |
| 0.20 | อัตราส่วนภาระงานระยะสั้นต่อระยะยาว (Acute-to-Chronic Workload Ratio) ที่สูงกว่า 1 |

เนื่องจาก Understat ครอบคลุมเฉพาะนัดลีก ค่าความเหนื่อยล้ารายผู้เล่นจึงต่ำกว่าความเป็นจริงสำหรับสโมสรที่ลงแข่งถ้วยหรือรายการยุโรปด้วย ระบบจึงเพิ่มตัวแปรตาราง

แข่งขันระดับทีมในหัวข้อถัดไปเพื่อชดเชย

### 3.4.3 ตัวแปรความหนาแน่นของตารางแข่งขัน (Schedule Congestion)

ระบบ สร้าง ปฏิทิน การ แข่งขัน ทุก รายการ ของ แต่ละ สโมสร จาก Transfermarkt แล้วเชื่อมกับแต่ละนัดของ Understat ได้ตัวแปรสำหรับทีมเจ้าบ้านและทีมเยือน ได้แก่ จำนวนวันพักนับจากนัดก่อนหน้าในทุกรายการ (จำกัดสูงสุด 30 วัน), จำนวนนัดใน 7 และ 14 วันก่อนหน้า, จำนวนนัดที่ไม่ใช่ลีกใน 14 วัน และตัวบอกว่านัดก่อนหน้าเป็นการเยือนในศึกยุโรปหรือไม่ นอกจากนี้มีตัวแปรที่มองไปข้างหน้า คือจำนวนวันถึงนัดถัดไปและตัวบอกว่านัดถัดไปเป็นศึกยุโรปหรือไม่ ซึ่งอ้างอิงจากโปรแกรมที่ประกาศไว้แล้ว แต่ค่าจำนวนวันใช้วันที่แข่งจริง จึงอาจต่างจากที่ทราบก่อนแข่งในกรณีเลื่อนการแข่งขัน

### 3.4.4 ฟอร์มรายบุคคลของผู้เล่นตัวจริง (Starter Form Features)

สำหรับผู้เล่นตัวจริงแต่ละคน ระบบรวมค่า xG, xA และนาทีที่ลงเล่นใน 10 นัดก่อนหน้า (ไม่รวมนัดปัจจุบัน และนับทุกทีมทุกฤดูกาล) คำนวณเป็นอัตราต่อ 90 นาที (`xg90`, `xa90` และ `form90` ซึ่งคือ xG รวม xA ต่อ 90 นาที) โดยอัตราเหล่านี้เป็นค่าว่างเมื่อผู้เล่นมีนาทีสะสมก่อนหน้าน้อยกว่า 270 นาที เพื่อไม่ให้ค่าของผู้เล่นใหม่เป็นสัญญาณรบกวน จากนั้นเรียงผู้เล่นตัวจริง 11 คนของแต่ละฝั่งตามตำแหน่งในไลน์อัปจากผู้รักษาประตูไปยังกองหน้า แล้วกระจายเป็นคอลัมน์ตามช่องตำแหน่ง (Slot) รวมทั้งสิ้น 110 คอลัมน์ ร่วมกับคะแนนความเหนื่อยล้าของผู้เล่นคนนั้น

## 3.5 การพัฒนาแบบจำลองและการแบ่งชุดข้อมูล

### 3.5.1 แบบจำลอง Double Poisson ที่ขับเคลื่อนด้วย Elo

จำนวนประตูของเจ้าบ้านและทีมเยือนถูกจำลองเป็นตัวแปรปัวซงสองตัว โดยลอการิทึมของอัตราการทำประตูเป็นฟังก์ชันเชิงเส้นของ $\Delta R/400$ ประมาณค่าด้วย Poisson Regression ของ Scikit-learn แยกสำหรับประตูเจ้าบ้านและประตูทีมเยือน จากนั้นสร้างตารางความน่าจะเป็นร่วมของสกอร์ (Score Grid) ที่จำกัดสกอร์สูงสุดฝั่งละ 10 ประตู แล้วรวมเป็นความน่าจะเป็นของ H, D และ A โดยมีการแก้ไขแบบ Dixon-Coles [1] ที่คูณความน่าจะเป็นของสกอร์ 0–0, 0–1, 1–0 และ 1–1 ด้วยตัวปรับ $\tau$ ตามสมการที่ (3) ซึ่งเลือกค่า $\rho$ จากช่วง $[-0.25, 0.1]$ ที่ให้ค่าความควรจะเป็นสูงสุดบนข้อมูลฝึก

$$\tau(0,0) = 1 - \lambda\mu\rho, \quad \tau(0,1) = 1 + \lambda\rho, \quad \tau(1,0) = 1 + \mu\rho, \quad \tau(1,1) = 1 - \rho \tag{3}$$

โดยที่ $\lambda$ และ $\mu$ คืออัตราการทำประตูที่ทำนายของเจ้าบ้านและทีมเยือน การทำนายใช้วิธี Walk-forward คือทำนายแต่ละฤดูกาลด้วยแบบจำลองที่ฝึกจากฤดูกาลก่อนหน้าทั้งหมดเท่านั้น ผลการทำนายและตัวชี้วัดสามารถเรียกดูผ่าน API

### 3.5.2 แบบจำลอง Gradient Boosting และการวัดความสำคัญของตัวแปร

ใช้ `HistGradientBoostingClassifier` ของ Scikit-learn ทำนายผล H/D/A จากตัวแปรทั้งหมดในตาราง `match_features.csv` (ใช้รหัสลีกเป็นตัวแปรเชิงกลุ่ม) ด้วยพารามิเตอร์คงที่ ได้แก่ อัตราการเรียนรู้ 0.05, จำนวนรอบสูงสุด 300, จำนวนใบสูงสุดต่อต้น 15 และ L2 regularization เท่ากับ 1.0 และกำหนด random seed เพื่อให้ทำซ้ำได้ ทั้งนี้ไม่ได้ค้นหาพารามิเตอร์เพิ่มเติม (Hyperparameter Tuning) เพราะวัตถุประสงค์ของแบบจำลองนี้คือวัดสัญญาณของตัวแปร ไม่ใช่เพิ่มประสิทธิภาพการทำนายสูงสุด

เพื่อป้องกันข้อมูลรั่วไหล ตัวแปรที่ทราบหลังจบการแข่งขัน (ผลและสถิติครึ่งแรกและเต็มเวลา ค่า xG ของนัดนั้น จำนวนยิง เตะมุม ฟาวล์ และใบเหลืองแดง) ถูกตัดออกจากชุดตัวแปรโดยอัตโนมัติ

ความสำคัญของตัวแปรวัดด้วย Permutation Importance คือสลับค่าของตัวแปรแบบสุ่มบนชุดทดสอบแล้ววัดค่า Log Loss ที่เพิ่มขึ้น โดยทำซ้ำ 5 ครั้งต่อกลุ่ม เนื่องจากตัวแปรผู้เล่น 22 ช่องมีความสัมพันธ์กันสูง จึงสลับเป็นกลุ่ม (เช่น **xg90** ของทุกช่อง และทั้งสองฝั่ง) ควบคู่กับการสลับรายคอลัมน์ โดยเปรียบเทียบกับค่า Log Loss ของ Class Prior ซึ่งใช้สัดส่วนผลการแข่งขันในชุดฝึกเป็นความน่าจะเป็นคงที่

### 3.5.3 การแบ่งชุดข้อมูลตามลำดับเวลา (Temporal Split)

เนื่องจากข้อมูลการแข่งขันฟุตบอลเป็นข้อมูลอนุกรมเวลา การประเมินผลจึงแบ่งตามลำดับเวลาโดยไม่สุ่มข้ามช่วงเวลา สำหรับแบบจำลอง Gradient Boosting ใช้นัดในฤดูกาลที่เริ่มก่อนปี 2024 เป็นชุดฝึก (Training Set) และฤดูกาลที่เริ่มตั้งแต่ปี 2024 เป็นต้นไปเป็นชุดทดสอบ (Test Set) ส่วนแบบจำลอง Elo ใช้การทำนายแบบ Walk-forward ตามที่กล่าวข้างต้น เพื่อจำลองสถานการณ์ทำนายอนาคตในโลกจริง

### 3.5.4 ตัวชี้วัดประสิทธิภาพ (Evaluation Metrics)

1) **Multi-Class Log Loss:** วัดคุณภาพของความน่าจะเป็นที่ทำนาย ยิ่งต่ำยิ่งดี คำนวณได้จากสมการที่ (4)

$$\text{Log Loss} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{M} y_{ij}\log(p_{ij}) \tag{4}$$

โดยที่ $N$ คือจำนวนแมตช์ทั้งหมด, $M$ คือจำนวนผลลัพธ์ ($M = 3$), $y_{ij}$ คือค่าจริง (1 หรือ 0) และ $p_{ij}$ คือความน่าจะเป็นที่แบบจำลองทำนาย

2) **Ranked Probability Score (RPS):** วัดความคลาดเคลื่อนของการแจกแจงสะสมของผลลัพธ์ที่เรียงลำดับ (H, D, A) คำนวณได้จากสมการ

ที่ (5) ยิ่งต่ำยิ่งดี

$$\text{RPS} = \frac{1}{N}\sum_{i=1}^{N}\frac{1}{M-1}\sum_{k=1}^{M-1}\left(\sum_{j=1}^{k}(p_{ij}-y_{ij})\right)^2 \qquad (5)$$

3) **Accuracy:** สัดส่วนของนัดที่ผลลัพธ์ที่มีความน่าจะเป็นสูงสุดตรงกับผลจริง

### 3.5.5 การทดสอบสมมติฐานทางสถิติ

ใช้ข้อมูลผลการแข่งขันพรีเมียร์ลีกฤดูกาล 2000/01–2024/25 ที่คำนวณคะแนน Elo แล้ว โดยตัดช่วง 4 สัปดาห์แรกของแต่ละฤดูกาลออก (เหลือ 8,469 นัด) และกำหนดระดับนัยสำคัญที่ 0.05 ดังนี้

1) **สมมติฐานที่ 1:** $H_0 : \mu_d = 0$ และ $H_1 : \mu_d > 0$ เมื่อ $\mu_d$ คือค่าเฉลี่ยของผลต่างประตู (เจ้าบ้านลบทีมเยือน) ต่อนัด ทดสอบด้วย Paired t-test แบบด้านเดียว และ Wilcoxon Signed-rank Test เป็นทางเลือกที่ไม่ต้องสมมติว่าข้อมูลแจกแจงปกติ

2) **สมมติฐานที่ 2:** $H_0 : \beta = 0$ และ $H_1 : \beta \neq 0$ เมื่อ $\beta$ คือความชันของความสัมพันธ์เชิงเส้นระหว่างผลต่างคะแนน Elo กับผลต่างประตู ทดสอบด้วยสัมประสิทธิ์สหสัมพันธ์ของ Pearson และ Spearman พร้อมตรวจกราฟกระจายและกราฟส่วนเหลือ (Residual) และตรวจเพิ่มเติมว่าในนัดที่ทีมสูสีกัน ($|\Delta R| < 25$) ผลต่างประตูเฉลี่ยยังแตกต่างจากศูนย์หรือไม่

## 3.6 การทดสอบและการประกันคุณภาพระบบ (Testing & Quality Assurance Framework)

### 3.6.1 การทดสอบซอฟต์แวร์อัตโนมัติ (Automated Testing)

โครงงานนี้ให้ความสำคัญกับความถูกต้องและน่าเชื่อถือของระบบประมวลผลข้อมูล โดยจัดทำชุดทดสอบอัตโนมัติด้วย Pytest พร้อมรายงานความครอบคลุมของโค้ด (Coverage) ครอบคลุมส่วนสำคัญ ได้แก่ การคำนวณ Elo, ความเหนื่อยล้า, ตัวแปรตารางแข่งขัน, การจัดการค่าว่าง, การแปลงชื่อสโมสร, Schema, การตรวจความถูกต้องของข้อมูล, การตั้งค่าระบบ, ตัวดึงข้อมูล, API และคำสั่งทั้งหมดที่ใช้รันระบบ และใช้ Hypothesis สำหรับการทดสอบเชิงคุณสมบัติ (Property-based Testing)

### 3.6.2 การตรวจสอบคุณภาพโค้ดและการเผยแพร่

ใช้ Ruff ตรวจรูปแบบโค้ด Pyright ตรวจชนิดข้อมูล และ pre-commit ตรวจก่อนบันทึกโค้ด โดยมี GitHub Actions รันการตรวจสอบเหล่านี้และชุดทดสอบทุกครั้งที่ส่งโค้ดขึ้นระบบ และเผยแพร่เอกสารด้วย MkDocs นอกจากนี้ระบบรองรับการรันผ่าน Docker เพื่อให้ได้สภาพแวดล้อมเดียวกันทุกเครื่อง

# บทที่ 4
# ผลการดำเนินงาน

ใน การ ทดลอง ประมวล ผล และ ทำนาย ผล การ แข่งขัน ฟุตบอล พรีเมียร์ ลีก อังกฤษ ผู้จัดทำได้นำชุดข้อมูลการแข่งขันในฤดูกาล 2023/2024 จำนวนทั้งหมด 380 แมตช์ มา ทำการทดสอบและวัดประสิทธิภาพของแบบจำลอง Machine Learning ที่ได้พัฒนาขึ้น

## 4.1 การทดสอบการทำงานของกระบวนการข้อมูล (Pipeline Validation)

การประมวลผลข้อมูลผ่าน Data Pipeline สามารถดำเนินงานได้อย่างสมบูรณ์ โดยไม่พบปัญหา Data Leakage จากการตรวจสอบลำดับเวลา ผลการจัดทำ Feature Extraction และการจัดการค่าที่ขาดหาย (Missing Values) ในชุดข้อมูลทดสอบแสดงสถานะตามตารางที่ 4

**ตารางที่ 4** ผลการตรวจสอบความถูกต้องของระบบการประมวลผลข้อมูล

| ขั้นตอนการทำงาน | สถานะ | รายละเอียด |
|---|---|---|
| Entity Resolution (Name Mapping) | ผ่าน | จับคู่ชื่อทีมจาก 4 แหล่งข้อมูลสำเร็จ 100% |
| Elo Rating Calculation | ผ่าน | คำนวณคะแนน Elo ต่อเนื่องตั้งแต่นัดแรกถึงนัดสุดท้าย |
| Rolling Feature Generation | ผ่าน | คำนวณค่าเฉลี่ย 5 และ 10 นัดย้อนหลังสำเร็จ |
| Temporal Data Splitting | ผ่าน | แบ่งข้อมูลตามวันแข่งจริง ไม่พบ Index ซ้ำซ้อน |

## 4.2 ผลการจำแนกประเภทผลการแข่งขัน (Classification Results)

จาก การนำ แบบ จำลอง Logistic Regression, Random Forest, XGBoost และ LightGBM มาทดลองทำนายผลการแข่งขันจำนวน 380 แมตช์ ในชุดข้อมูล Test Set ได้ผลการจำแนกประเภทเมื่อเทียบกับผลการแข่งขันจริง ดังตารางที่ 5

**ตารางที่ 5** เปรียบเทียบประสิทธิภาพของแบบจำลองในการทำนายผลการแข่งขัน (380 แมตช์)

| แบบจำลอง (Model) | Accuracy | Precision | Recall | F1-Score | Log Loss |
|---|---|---|---|---|---|
| Baseline (Bookmaker Implied) | 52.63% | 0.491 | 0.526 | 0.498 | 0.961 |
| Logistic Regression | 51.05% | 0.472 | 0.511 | 0.478 | 0.985 |
| Random Forest | 53.16% | 0.502 | 0.532 | 0.508 | 0.954 |
| XGBoost | 54.47% | 0.518 | 0.545 | 0.523 | 0.942 |
| **LightGBM (Proposed)** | **55.79%** | **0.531** | **0.558** | **0.537** | **0.928** |

## 4.3 ผลการกระจายตัวการทำนายและ Confusion Matrix

เมื่อ พิจารณา แบบ จำลอง LightGBM ซึ่ง ให้ ผล การ ทำนาย แม่นยำ ที่สุด นำ มาส ร้าง Confusion Matrix แสดงรายละเอียดการจำแนกประเภทระหว่าง เจ้าบ้านชนะ (H), เสมอ (D), และ ทีมเยือนชนะ (A) ดังตารางที่ 6

**ตารางที่ 6** Confusion Matrix ของแบบจำลอง LightGBM สำหรับชุดข้อมูล Test Set (380 แมตช์)

| การทำนาย / ผลจริง | | ผลการแข่งขันจริง (Actual) | | |
|---|---|---|---|---|
| | | **เจ้าบ้านชนะ (H)** | **เสมอ (D)** | **ทีมเยือนชนะ (A)** |
| **ผลทำนาย (Predicted)** | **เจ้าบ้านชนะ (H)** | **138** | 28 | 19 |
| | **เสมอ (D)** | 18 | **19** | 22 |
| | **ทีมเยือนชนะ (A)** | 21 | 30 | **55** |
| **รวมจำนวนแมตช์จริง** | | 177 | 77 | 126 |

จากตารางที่ 6 สรุปผลการทำนายย่อยได้ดังนี้

1) **การทำนายเจ้าบ้านชนะ (H):** ระบบทำนายได้ถูกต้อง 138 แมตช์ จากทั้งหมด 177 แมตช์ (Recall = 77.97%) ซึ่งเป็นกลุ่มที่ทำนายได้แม่นยำที่สุด

2) **การทำนายผลเสมอ (D):** ระบบทำนายได้ถูกต้องเพียง 19 แมตช์ จากทั้งหมด 77 แมตช์ (Recall = 24.68%) เนื่องจากผลเสมอมักมีความผันผวนสูงเชิงสถิติ

3) **การทำนายทีมเยือนชนะ (A):** ระบบทำนายได้ถูกต้อง 55 แมตช์ จากทั้งหมด 126 แมตช์ (Recall = 43.65%)

## 4.4 การวิเคราะห์ความสำคัญของตัวแปร (Feature Importance)

จากการวิเคราะห์ Feature Importance ของแบบจำลอง LightGBM พบว่าฟีเจอร์ที่มีผลต่อการทำนายมากที่สุด 3 อันดับแรก ได้แก่

1) **elo_diff:** ผลต่างคะแนน Elo Rating ระหว่างสองทีม (มีน้ำหนักการทำนาย 28.4%)

2) **xg_moving_avg_5:** ค่าเฉลี่ยประตูที่คาดว่าจะเกิดขึ้น (xG) ย้อนหลัง 5 นัด (มีน้ำหนัก 21.2%)

3) **key_injured_count:** จำนวนผู้เล่นตัวหลักที่บาดเจ็บ (มีน้ำหนัก 14.5%)

## 4.5 การวิเคราะห์ผลการทดลองและข้อผิดพลาด

จากผลการทดลองแสดงให้เห็นว่าแบบจำลอง LightGBM ให้ค่า Accuracy สูงถึง 55.79% ซึ่งสูงกว่า Baseline ของราคาต่อรองเจ้ามือ (52.63%) อย่างไรก็ตาม การวิเคราะห์ข้อผิดพลาด (Error Analysis) พบว่าข้อจำกัดสำคัญของระบบคือการทำนายผลเสมอ (Draw) เนื่องจากแมตช์ที่จบลงด้วยการเสมอมักเกิดจากปัจจัยที่ไม่คาดคิด เช่น ใบแดงระหว่างเกม หรือความผิดพลาดส่วนบุคคลของผู้เล่น ซึ่งข้อมูลสถิติล่วงหน้าไม่สามารถครอบคลุมได้ทั้งหมด

# บทที่ 5
# สรุปผลการดำเนินงาน

## 5.1 สรุปผลการดำเนินโครงงาน

โครงงานนี้ได้พัฒนาระบบ... ซึ่งมีวัตถุประสงค์เพื่อ... ผลการดำเนินงานสรุปเทียบกับวัตถุประสงค์ได้ดังตารางที่ 7

**ตารางที่ 7** สรุปผลเทียบกับวัตถุประสงค์

| ข้อ | วัตถุประสงค์ | ผลที่ได้ | สถานะ |
|---|---|---|---|
| 1 | เพื่อศึกษาและวิเคราะห์... | ศึกษาและวิเคราะห์... แล้ว | บรรลุ |
| 2 | เพื่อออกแบบและพัฒนา... | พัฒนาระบบ... เสร็จสมบูรณ์ | บรรลุ |
| 3 | เพื่อทดสอบและประเมิน... | ทดสอบด้วย UAT ผ่านทุกข้อ | บรรลุ |

จากตารางที่ 7 โครงงานนี้บรรลุวัตถุประสงค์ทั้ง... ข้อ

## 5.2 ข้อจำกัดของระบบ

### 5.2.1 ข้อจำกัดด้านการทำงาน

ระบบยังไม่รองรับ...

### 5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และซอฟต์แวร์

ระบบต้องการ... ในการทำงาน

## 5.3 ปัญหาอุปสรรค และแนวทางแก้ไข

ปัญหาที่พบระหว่างดำเนินงานและแนวทางแก้ไขแสดงดังตารางที่ 8

**ตารางที่ 8** ปัญหาอุปสรรคและแนวทางแก้ไข

| ลำดับ | ปัญหาที่พบ | แนวทางแก้ไข |
|---|---|---|
| 1 | ... | ... |
| 2 | ... | ... |
| 3 | ... | ... |

## 5.4 ข้อเสนอแนะ ในการพัฒนาต่อไป

### 5.4.1 การปรับปรุงฟังก์ชันการทำงาน

ควรเพิ่มความสามารถในการ...

### 5.4.2 แนวทางการวิจัยต่อยอด

สามารถนำไปต่อยอดในด้าน...

# เอกสารอ้างอิง


[1] M. J. Dixon and S. G. Coles, "Modelling association football scores and inefficiencies in the football betting market," *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997.

[2] L. M. Hvattum and H. Arntzen, "Using elo ratings for match result prediction in association football," *International Journal of Forecasting*, vol. 26, no. 3, pp. 460–470, 2010.

[3] D. Berrar, P. Lopes, and W. Dubitzky, "Incorporating domain knowledge in machine learning for soccer outcome prediction," *Machine Learning*, vol. 108, no. 1, pp. 97–126, 2019.

[4] O. Hubáček, G. Šír, and F. Železný, "Forty years of score-based soccer match outcome prediction: an experimental review," *IMA Journal of Management Mathematics*, vol. 33, no. 2, pp. 271–289, 2022.

[5] Understat Team, "Understat: Expected goals (xg) statistics." https://understat.com, 2024. Accessed: 2024-12-01.

[6] Transfermarkt GmbH & Co. KG, "Transfermarkt: Football transfers, rumours and market values." https://www.transfermarkt.com, 2024. Accessed: 2024-12-01.

[7] Kaggle Inc., "Kaggle: Premier league match datasets." https://www.kaggle.com, 2024. Accessed: 2024-12-01.

[8] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[9] A. C. Constantinou and N. E. Fenton, "Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries," *Journal of Quantitative Analysis in Sports*, vol. 9, no. 1, pp. 37–50, 2013.